

SCIENCES
DU
COMPORTEMENT

collection dirigée par F. BRESSON et M. de MONTMOLLIN

11

68 8 1878 II
M. PÊCHEUX

analyse
automatique
du discours

Publié avec le concours du
Centre national de la Recherche scientifique

308 103
DUNOD

DANS LA MÊME COLLECTION

1. *Psychologie et épistémologie génétique. Hommage à J. PIAGET.*
2. H. SINCLAIR de ZWART. — *Acquisition du langage et développement de la pensée.*
3. R. B. ZAJONC. — *Psychologie sociale expérimentale.*
4. *Problèmes actuels de la recherche en Ergonomie.* — Actes du IV^e Congrès d'Ergonomie de langue française.
5. A. W. SCHESTAKOW. — *L'enseignement programmé et les machines à enseigner en U.R.S.S.*
6. J. LEPLAT. — *Attention et incertitude dans les travaux de surveillance et d'inspection.*
7. *La simulation du comportement humain.* — Actes d'un symposium O.T.A.N., 1967.
8. *La recherche en enseignement programmé.* — Actes d'un colloque O.T.A.N., 1968.
9. A. LÉVY-SCHOEN. — *L'étude des mouvements oculaires.*
10. F. LONGEOT. — *Psychologie différentielle et théorie opératoire de l'intelligence.*
11. M. PÊCHEUX. — *Analyse automatique du discours.*

En préparation :

P. CAZAMIAN, G. DEVÈZE, G. FAURE, Y. CHICLI. — *Opinion et comportement en matière de sécurité.*

L'ergonomie et la psychologie industrielle en Union Soviétique, ouvrage collectif sous la direction de D. OCHANINE.

Collection SCIENCES DU COMPORTEMENT
dirigée par François BRESSON et Maurice de MONTMOLLIN

Col 8° 1878¹¹

II

ANALYSE AUTOMATIQUE DU DISCOURS

PAR

M. PÊCHEUX

Chargé de Recherches
au Centre national de la Recherche scientifique

OUVRAGE PUBLIÉ AVEC LE CONCOURS
DU CENTRE NATIONAL DE LA RECHERCHE SCIENTIFIQUE

DUNOD

PARIS

1969

BIBL. S.
GENEVIEVE

308.103

B86

ANALYSE AUTOMATIQUE DU DISCOURS

© DUNOD, 1969

Toute reproduction, même partielle, de cet ouvrage est interdite. Une copie ou reproduction par quelque procédé que ce soit, photographique, microfilm, bande magnétique, disque ou autre, constitue une contrefaçon passible des peines prévues par la loi du 11 mars 1957 sur la protection des droits d'auteur.

AVANT PROPOS

L'ouvrage de Michel PÊCHEUX marque une étape, et cela de plusieurs manières. D'abord parce qu'il constitue le résultat « opérationnel » d'une élaboration et d'une mise au point dont j'ai eu le plaisir de suivre l'évolution au cours d'exposés et de discussions avec A. CULIOLI et J. B. GRIZE. Ensuite parce que cet outil, qui commence à fonctionner effectivement ⁽¹⁾, n'est encore qu'un prototype et qu'il engendrera vraisemblablement de nouveaux perfectionnements : un groupe actif s'est constitué à l'initiative de M. PÊCHEUX et prépare l'étape suivante ⁽²⁾. Enfin cet ouvrage est aussi une étape dans le développement des travaux contemporains sur le langage parce qu'il ouvre une voie nouvelle à « l'analyse du contenu » et témoigne de la convergence, qui ne fait que s'esquisser ailleurs, entre sémantique et syntaxe au sens linguistique de ces termes. Publier cet ouvrage qui, pourra paraître difficile au premier abord par la nouveauté du sujet et la technicité nécessaire de l'exposé, ce n'est pas, je crois, faire preuve d'audace : on s'apercevra vite que la voie ainsi ouverte est fructueuse et qu'elle apportera rigueur et efficacité, là où l'on se contentait, faute de mieux, d'un aimable impressionnisme ; et l'on sera alors reconnaissant à M. PÊCHEUX, comme à ceux auxquels il a confronté ses idées, d'avoir frayé le chemin et fourni l'outil indispensable.

F. BRESSON

⁽¹⁾ Le Centre d'Études et de Traduction Automatique de Grenoble (CETA) s'est chargé de réaliser certains algorithmes exposés au chapitre II. Des linguistes de ce même organisme travaillent actuellement à la mise au point d'une Grammaire de Reconnaissance du français dont l'une des applications sera l'automatisation de l'enregistrement de la séquence linguistique (M. PÊCHEUX).

⁽²⁾ Ce groupe comprend actuellement : F. BENOIT, F. BRESSON, F. BUCNIET, A. CULIOLI, M. DUPRAZ, S. FISHER, C. FUCHS, J. B. GRIZE, C. HAROCHÉ, P. HENRY, H. FAUCHARD, J. ROUAULT, F. SOUBLIN et C. VERKEN. Par ailleurs, l'auteur tient à exprimer ici sa reconnaissance envers tous ceux qui par leurs suggestions et leurs critiques ont contribué à l'élaboration de ce travail (M. PÊCHEUX).

TABLE DES MATIÈRES

CHAPITRE PREMIER

ANALYSE DE CONTENU ET THÉORIE DU DISCOURS

I.	Linguistique et analyse de texte : leurs rapports de voisinage	1
A)	<i>Les méthodes non-linguistiques</i>	3
	1. La méthode du décompte fréquentiel	3
	2. L'analyse par catégories thématiques	4
B)	<i>Les méthodes para-linguistiques</i>	5
II.	Orientations conceptuelles pour une théorie du discours	8
A)	<i>Des conséquences théoriques induites par certains concepts saussuriens</i> ..	8
	1. Les implications de l'opposition saussurienne entre langue et parole	9
	2. Les implications du concept saussurien d'institution	13
B)	<i>Les conditions de production du discours</i>	16
	1. Les éléments structurels appartenant aux conditions de production	16
	2. Esquisse d'une représentation formelle des processus discursifs	23
C)	<i>Pour l'analyse du processus de production du discours</i>	28
	1. L'effet métaphorique	29
	2. De la surface discursive à la structure du processus de production	33

CHAPITRE II

DESCRIPTION D'UN DISPOSITIF

D'ANALYSE AUTOMATIQUE DU PROCESSUS DISCURSIF

I. Règles pour l'enregistrement codé de la surface discursive	39
A) De la surface discursive au graphe des énoncés	40
1. Les marques d'arrêt : définition de la phrase	40
2. Les dépendances fonctionnelles dans la phrase	42

3. Les dépendances fonctionnelles entre les phrases	44
4. La structure de la proposition	46
5. L'enregistrement des dépendances fonctionnelles	51
a) La concaténation comme structure élémentaire	51
b) L'expansion	53
c) Le principe de saturation	60
d) Les structures à plusieurs sources	64
B) <i>L'enregistrement de la structure de l'énoncé</i>	69
1. Le syntagme nominal	71
2. Le syntagme verbal	73
3. Les transformations de l'énoncé	77
4. Problèmes particuliers de l'enregistrement : quelques exemples	78
5. Régularisation de l'enregistrement	84
II. L'analyse automatique du matériel enregistré	87
A) <i>Analyse paradigmatique des énoncés</i>	88
1. Partition de $\mathcal{E}_x$ en catégories (Alg. 1)	88
2. Valeur de la proximité paradigmatique	92
3. Calcul de la proximité de deux énoncés dans l'ensemble $\mathcal{E}_x$ (Alg. 2)	93
B) <i>Constitution des domaines sémantiques et analyse de leurs dépendances</i>	95
1. Analyse des similitudes	95
a) Formation des ψ -classes	95
b) Formation des chaînes de similitude	96
2. Formation des domaines	99
a) Groupe opérateur	99
b) Catégorie de chaînes	99
c) Homogénéité de deux chaînes dans une même catégorie : définition du domaine sémantique (Alg. 4 et Alg. 5)	99
3. Analyse de la dépendance entre les domaines sémantiques	104
a) Dépendance entre deux énoncés (Alg. 6)	104
b) Dépendance entre deux séquences	106
c) Dépendance entre deux domaines (Alg. 7)	106
Conclusion provisoire : Perspectives d'utilisation de l'analyse automatique du discours	109
1. Le champ de l'investigation sociologique	111
2. Le champ de l'histoire des sciences	112

ANNEXE I. Exemple d'enregistrement d'une surface discursive	113
ANNEXE II. Test de la congruence entre deux ensembles d'énoncés $\mathcal{E}_x$ et $\mathcal{E}_y$	118
ANNEXE III. Exemple d'analyse d'un corpus $\mathcal{C}_x$	122
ANNEXE IV. Étude des marques de détermination dans F (par Catherine FUCHS)	128
ANNEXE V. Définition des principaux symboles utilisés	135
BIBLIOGRAPHIE	140

CHAPITRE I

ANALYSE DE CONTENU ET THÉORIE DU DISCOURS

I. LINGUISTIQUE ET ANALYSE DE TEXTE : LEURS RAP- PORTS DE VOISINAGE

Jusqu'aux récents développements de la science linguistique, dont on peut marquer l'origine dans le « Cours de linguistique générale », étudier un langage, c'était le plus souvent étudier des *textes*, et poser à leur propos des questions de nature variée relevant à la fois de la pratique scolaire qu'on appelle encore l'explication de texte ⁽¹⁾ et de l'activité du *grammairien*, sous des modalités normatives ou descriptives; on se demandait simultanément : « de quoi parle ce texte? », « Quelles sont les principales "idées" contenues dans ce texte? », et en même temps « Ce texte est-il conforme aux normes de la langue dans laquelle il est présenté? » ou bien « Quelles sont les normes propres à ce texte? ». Toutes ces questions étaient posées simultanément parce qu'elles renvoyaient les unes aux autres : plus précisément, les questions concernant les usages sémantiques et syntaxiques mis en évidence par le texte aidaient à répondre aux questions concernant le sens du texte (ce que l'auteur a « voulu dire »). En d'autres termes, la science classique du langage prétendait être à la fois *science de l'expression* et *science des moyens de cette expression*, et l'étude grammaticale et sémantique était un moyen au service d'une fin, à savoir la compréhension du texte, de la même façon que, dans le texte lui-même, les « moyens d'expression » étaient au service de la fin visée par le producteur du texte (à savoir : se faire comprendre).

⁽¹⁾ C'est-à-dire la philologie selon Saussure, dans la mesure où elle veut avant tout « fixer, interpréter, commenter les textes » (Saussure, 1915, 3^e éd. 1962, p. 13).

Dans ces conditions, si l'homme entend ce que signifie son semblable, c'est qu'ils sont l'un et l'autre à quelque degré « grammairiens », cependant que le spécialiste du langage ne peut faire œuvre scientifique que parce que, d'abord, il est, comme tout homme, apte à s'exprimer.

Or le déplacement conceptuel introduit par F. de Saussure consiste précisément à briser cette homogénéité complice entre la pratique et la théorie du langage : à partir du moment où la langue doit être pensée comme un système, elle cesse d'être comprise comme ayant la fonction d'exprimer du sens ; elle devient un objet dont une science peut décrire le fonctionnement. (En reprenant la métaphore du jeu d'échec, dont Saussure fait usage pour penser l'objet de la linguistique, on dira qu'il ne faut pas chercher ce que signifie une partie, mais quelles sont les règles qui rendent possible toute partie, ayant eu lieu ou non.)

La conséquence de ce déplacement est, comme l'on sait, la suivante : le « texte » ne peut en aucune manière être l'objet pertinent pour la science linguistique, puisqu'il ne fonctionne pas ; ce qui fonctionne, c'est la langue, c'est-à-dire un ensemble de systèmes autorisant des combinaisons et des substitutions réglées sur des éléments définis, et les mécanismes mis en cause sont de dimension inférieure au texte : la langue, comme objet de science, s'oppose à la parole, comme résidu non-scientifique de l'analyse. « En séparant la langue de la parole, on sépare du même coup : 1) ce qui est social de ce qui est individuel, 2) ce qui est essentiel de ce qui est accessoire et plus ou moins accidentel » (Saussure, 1915, 3^e éd., 1962, p. 30).

Ainsi l'étude du langage, qui avait d'abord prétendu au statut de science de l'expression et de ses moyens, voulant traiter les phénomènes de grande dimension, se replia sur la position qui est aujourd'hui encore le lieu de la linguistique. Mais, comme il est de règle dans l'histoire de la science, le repli par lequel la linguistique constituait sa scientificité laissait à découvert le terrain qu'elle abandonnait, et la question à laquelle la linguistique a dû refuser de répondre continue à se poser, motivée par des intérêts à la fois théoriques et pratiques :

- « Que veut dire ce texte ? »
- « Quelle signification contient ce texte ? »
- « En quoi le sens de ce texte diffère-t-il de celui de tel autre texte ? ».

Telles sont bien les différentes formes de la même question à laquelle plusieurs réponses ont été fournies par ce qu'on appelle l'analyse de contenu, et parfois aussi l'analyse de texte.

Nous nous proposons d'examiner les différents types de réponse que l'on peut discerner dans les pratiques actuelles d'analyse : la manière dont

le terrain laissé libre par la linguistique est abordé dans chaque cas sera le moyen de notre classification.

A) Les méthodes non-linguistiques

Il existe d'abord des méthodes d'analyse qui, en apparence, sont sans rapport avec la linguistique : elles sont apparues les premières et se sont développées à peu près en même temps que le déplacement ci-dessus décrit s'opérait, ce qui explique qu'elles l'aient ignoré, par défaut de recul. Ces méthodes se donnent donc pour tâche de répondre à la question sous sa forme pour ainsi dire « pré-saussurienne » : elles se placent en dehors de la linguistique actuelle, ce qui ne veut pas dire qu'elles ne reposent pas sur des concepts d'origine linguistique — simplement, ces concepts sont décalés par rapport à la théorie linguistique actuelle.

1. LA MÉTHODE DU DÉCOMPTE FRÉQUENTIEL

Nous désignons par là le processus consistant à recenser le nombre d'occurrences d'un même signe linguistique (mot ou lexie le plus souvent) à l'intérieur d'une séquence de dimension fixée, et à définir une fréquence que l'on peut comparer à d'autres, ce qui fournit un test de comparabilité entre plusieurs items de la même séquence, ou entre plusieurs séquences parallèles pour le même item. Le grand avantage de cette méthode fut de développer des instruments statistiques adéquats au traitement de l'information (la relation rang/fréquence⁽¹⁾ est le plus important des résultats ainsi obtenus).

Le rapport au domaine linguistique est ici réduit au minimum : on peut dire que le seul concept d'origine linguistique est celui de la bi-univocité du rapport signifiant-signifié, ce qui autorise à noter la présence du même contenu de pensée à chaque fois que le même signe apparaît. Mais ce concept appartient à un champ théorique pré-saussurien, et la linguistique actuelle repose en grande partie sur l'idée qu'un terme n'a de sens dans une langue que parce qu'il a plusieurs sens, ce qui revient à nier que le rapport du signifiant au signifié soit bi-univoque.

Une manière différente de formuler en définitive la même critique consiste à remarquer que même si on multipliait les décomptes fréquentiels, on ne rendrait pas compte de l'organisation du texte, des réseaux de relations entre ses éléments : tout se passe comme si la surface du texte était une population dans laquelle on effectuerait ainsi des recensements différen-

(1) Loi de Estoup-Zipf-Mandelbrot.

tiels ; on obtient bien une description, aussi fine qu'on le désire, de la population, mais les *effets de sens* qui constituent le contenu du texte sont négligés : on paye l'objectivité de l'information recueillie par la difficulté d'en faire l'usage qu'on prévoyait (1).

2. L'ANALYSE PAR CATÉGORIES THÉMATIQUES

La méthode que nous venons de décrire se situe à un niveau infra-linguistique : dans la mesure où elle se donne pour objet une sorte de *démographie* des textes, elle vise non pas le fonctionnement d'un système d'éléments, mais la pure existence de tel ou tel matériau linguistique, ce qui rend d'incontestables services à la théorie linguistique, mais ne répond pas à la question du sens contenu dans le texte, ni à celle de la différence de sens d'un texte à l'autre.

L'analyse de contenu classique — telle par exemple qu'elle est décrite par D. P. Cartwright (in Festinger et Katz, trad. française, p. 481) — tente au contraire d'apporter une réponse sur ce point : ce qui est visé dans le texte, c'est bien une série de *significations* que le codeur détecte par les *indicateurs* qui leur sont reliés ; en d'autres termes, le rapport fonctionnel expression de la signification/moyens de cette expression reprend ici toute son importance. Ainsi, l'analyse se situe cette fois à un niveau *supra-linguistique*, puisqu'il s'agit d'accéder au *sens* d'un segment de texte, en traversant sa structure linguistique ; coder ou caractériser un segment, c'est le placer dans une des classes d'équivalence définies sur les significations par le tableau d'analyse, en fonction du *jugement du codeur* sur la présence ou l'absence, ou sur l'intensité de présentation de tel prédicat considéré.

Le jugement s'étaye donc sur des *indicateurs* dont la pertinence linguistique n'est pas fixée (mot, phrase, « thème »...), ce qui exige complémentarément des qualités psychologiques telles que la finesse, la sensibilité, la souplesse de la part du codeur pour saisir ce qui importe, et cela seulement (Festinger et Katz, trad. française, 1963, p. 529). C'est dire du même coup que cette méthode suppose fondamentalement une *acculturation des codeurs*, un *apprentissage de la lecture*. En laissant de côté le problème de la fidélité intercodeurs, dont on connaît l'importance, nous désignerons le point qui nous semble ici l'essentiel : dans cette perspective, l'analyse ne peut pas être

(1) On peut remarquer toutefois que la méthode d'analyse des co-occurrences (contingency analysis) permet de repérer un type particulier de relations entre les éléments (à savoir leur présence simultanée dans la même unité de texte) (Sofa-Pool, 1959, p. 61 sq.).

une suite d'opérations objectives à résultat univoque (et un codeur qui voudrait simuler cette objectivité ne ferait qu'un travail routinier et mécanique sans validité analytique) ; pourtant, « si le codage doit être l'œuvre d'une équipe de codeurs, il est nécessaire qu'ils appliquent tous les mêmes définitions et le même système de référence au cours de leurs opérations » (*ibid.*, p. 530), il faut supposer l'existence d'un consensus explicite ou implicite (1) des codeurs sur les modalités de leur lecture : en d'autres termes, un texte n'est analysable qu'à l'intérieur du système commun de valeurs qui a un sens pour les codeurs et constitue leur mode de lecture ; or la méthode impose, avec le rapport expression/moyens d'expression, les conséquences de ce rapport, à savoir le chevauchement entre la fonction théorique de l'analyste et la fonction pratique du locuteur (cf. p. 2). Le risque limite est donc que l'analyse ainsi conçue reproduise dans ses résultats la grille de lecture qui l'a rendue possible (quel que soit par ailleurs le degré de probité, de sensibilité et de fidélité des codeurs) par un phénomène de participation en reflet entre l'objet et la méthode qui se donne pour tâche d'appréhender cet objet (2).

B) Les méthodes para-linguistiques

À côté des méthodes précédemment décrites, qui sont non-linguistiques en tant qu'elles évitent le niveau spécifique du signe, et relèvent de méthodologies psychologiques ou sociologiques, il en existe d'autres, d'apparition plus récente, qui, au contraire, se réfèrent *ouvertement* à la linguistique moderne (3), et apportent une autre réponse à la question du *sens* contenu dans un texte. Or il y a ici un paradoxe, dont il faut rendre raison : comment, en effet, des disciplines comme l'ethnologie, la critique littéraire ou l'étude des systèmes de signes propres aux civilisations dites « de masse » peuvent-elles faire appel à la linguistique pour répondre à une question qui se pose précisément sur le terrain que la linguistique a délaissé en se constituant ?

(1) Selon que l'accord est ou non obtenu par une discussion collective ou un procédé tel que le Round Robin.

(2) Le passage de l'artisanat à l'industrie ne change pas fondamentalement la question : la méthode du General Inquirer (Philip J. Stone, M.I.T. Press) consiste à relever dans le corpus les occurrences de mots et de phrases correspondant à des catégories préalablement introduites dans un programme de reconnaissance. Bien entendu, il existe plusieurs programmes, parmi lesquels l'analyste choisit en fonction de ses besoins — c'est-à-dire, le plus souvent, en fonction des présupposés théoriques qui gouvernent sa lecture.

(3) Plus précisément, soit à ses concepts propres (par exemple l'opposition paradigme-syntagme), soit à ses instruments (par exemple grammaires génératives, systèmes transformationnels).

Voici la solution que nous proposons, concernant le paradoxe énoncé : les différentes disciplines énumérées reconnaissent le fait théorique fondamental qui marque la naissance de la science linguistique, à savoir le passage de la fonction au fonctionnement ; par ailleurs, elles ont déchiffré cet événement non pas comme une fermeture, rendant impossibles certaines questions, mais comme le signe d'une possibilité nouvelle offerte à elles, à savoir la possibilité d'effectuer une deuxième fois le même déplacement (de la fonction au fonctionnement), mais cette fois au niveau du texte. En d'autres termes, puisqu'il existe des systèmes syntaxiques, on fait l'hypothèse qu'il existe de la même façon des systèmes mythiques, des systèmes littéraires, etc., autrement dit que les textes, comme la langue, fonctionnent ; l'homogénéité épistémologique que l'on suppose ainsi entre les faits de langue et les phénomènes de la dimension du texte garantit ainsi l'emploi des mêmes instruments conceptuels ; par exemple, le rapport paradigme-syntagme s'étendra aux différents niveaux de fonctionnement, donc d'analyse : on vise l'idéal de la scientificité linguistique, en transposant l'instrument linguistique. Est-ce dire pour autant qu'il est atteint ? Ici se manifeste la résistance propre au niveau et à la dimension de l'objet : la disjonction entre la théorie de la langue et la pratique du locuteur semble acquise, mais celle entre la théorie du mythe et la pratique du mythe est encore problématique. On peut même se demander si elle est pensable, à lire ce qu'écrit un spécialiste — et non des moindres — à ce propos :

« Il n'existe pas de terme véritable à l'analyse mythique, pas d'unité secrète qu'on puisse saisir au bout du travail de décomposition. Les thèmes se dédoublent à l'infini... par conséquent, l'unité du mythe n'est jamais que tendancielle et projective, elle ne reflète jamais un état ou un moment du mythe... Comme les rites, les mythes sont in-terminables. Et, en voulant imiter le mouvement spontané de la pensée mythique, notre entreprise, elle aussi trop brève et trop longue, a dû se plier à ses exigences et respecter son rythme. Ainsi le livre sur les mythes est-il, à sa façon, un mythe » (Levi-Strauss, 1964, p. 13).

Il semble bien que nous retrouvions ici « l'harmonie pré-établie » entre le producteur du mythe et son analyste, qui nous était déjà apparue (cf. p. 2) entre l'homme qui parle et le grammairien ; c'est dire que le « fonctionnement » du texte voisine encore avec sa fonction et donc que le déplacement n'est pas tout à fait accompli.

Il faut tirer toutes les conséquences du fait que ce qui est analysé n'existe pas en général par le désir de l'analyste, et l'éclaircissement de ce point semble être une des conditions d'existence d'une pratique sémiologique

scientifique⁽¹⁾. Les difficultés méthodologiques concernant la constitution et la fermeture du « corpus » trouvent ici leur origine ; si, en effet, l'objet de l'analyse n'est pas conceptuellement défini comme l'élément d'un processus dont il faut construire la structure, cet objet reste objet de désir, ce qui implique deux conséquences : la première, c'est que la constitution de l'objet dépend de ce qui, dans l'esprit de l'analyste, amène celui-ci à la poser ; la seconde, c'est que l'analyste feint de le rencontrer comme un donné naturel, ce qui dégage sa responsabilité.

Le problème concerne donc avant tout le mode d'accès à l'objet, et c'est autour de ce point que s'articulent les orientations conceptuelles que nous présentons ci-après (cf. p. 16).

Expliquons-nous par un contre-exemple : nous venons de montrer qu'en face du mythe l'analyste ne dispose pas de norme permettant de définir ce qui appartient ou non au corpus : or, en présence d'un texte juridique ou scientifique, cette difficulté ne semble pas se poser dans la mesure où il existe dans ce cas une institution (scientifique, juridique, etc.) à laquelle on peut référer les textes. On doit donc marquer la différence entre l'analyse documentaire, effectuée à l'intérieur d'une référence institutionnelle à des fins répondant en général à celles de l'institution, et l'analyse que nous appellerons « non-institutionnelle », telle que nous venons de l'évoquer à propos du mythe : la convergence méthodologique par laquelle certains dispositifs de documentation automatique se trouvent appliqués en analyse « non-institutionnelle » peut donc susciter quelque étonnement. En effet, l'analyse documentaire suppose fondamentalement que les classes d'équivalence soient définies a priori par la norme institutionnelle elle-même ; parlant des modalités de la mise en mémoire de l'information nécessaire à l'analyse d'un document, J. C. Gardin écrit : « Quel que soit le parti adopté, il reste que l'on doit d'abord établir les relations en question, c'est-à-dire constituer d'une manière ou d'une autre une « classification » où la place de chaque mot-clé reflète les rapports sémantiques qu'il entretient avec d'autres termes (exemple : « lobe temporal », partie du « télencéphale ») ou groupe de termes (exemple : « ataxie », espèce particulière de « trouble du comportement moteur ») » (Gardin, 1964, p. 42).

On comprend dès lors l'importance du préliminaire indispensable à toute analyse, que G. Mounin énonce clairement : « (l'analyste) constitue pour chaque sorte d'objets, le code de symboles qui noteront la présence ou l'absence de tous les traits distinctifs du type d'objet à décrire et classer. Le codage est donc précédé d'une analyse technologique destinée à établir

(1) La relation psychanalytique constituerait sur ce point un cas particulier, dans la mesure où ce qui est « analysé » existe aussi par et pour le désir de l'analyste.

le recensement de tous les traits distinctifs nécessaires à la description d'objets de ce type, c'est-à-dire le cadre exhaustif où tiendra la définition de chaque objet » (Mounin, 1963, p. 114).

C'est donc parce qu'il existe déjà un discours *institutionnellement garanti* sur l'objet que l'analyste peut rationaliser le système de traits sémantiques qui caractérisent cet objet : le système d'analyse aura donc l'âge théorique (le niveau de développement) de l'institution qui le norme, et permettra de définir la position d'un contenu particulier par rapport à cette norme : les travaux de W. Ackermann (1966) par exemple mettent en évidence la possibilité de mesurer l'adéquation progressive d'un groupe de sujets aux normes scientifiques qu'on leur impose à travers une institution d'enseignement.

Au terme de cette analyse, plusieurs questions se posent, et nous les formulerons ainsi :

1) Si l'on tient pour acquis que toute science traitant du signe ne peut se constituer qu'en abandonnant le terrain de la *fonction* d'expression et du sens, pour se situer sur celui du *fonctionnement*, quel type de *fonctionnement* peut-on assigner à l'objet dont il est ici question ?

2) En quoi le concept d'institution importe-t-il à la construction du concept de cet objet ?

3) Si l'on entend par *texte* tout objet linguistique organisé soumis à l'analyse, peut-on conserver ce concept pour désigner l'objet d'une pratique analytique tenant compte des réponses aux deux précédentes questions ?

II. ORIENTATIONS CONCEPTUELLES POUR UNE THÉORIE DU DISCOURS

A) Des conséquences théoriques induites par certains concepts saussuriens

Dans le « Cours de linguistique générale », au chapitre III, on rencontre deux *formes de définition* du concept de langue.

La première forme consiste à énoncer les propriétés de l'objet défini : « La langue... est la partie sociale du langage, extérieure à l'individu, qui à lui seul ne peut ni la créer ni la modifier » (Saussure, *op. cit.*, p. 31). Cette définition a pour effet d'opposer la langue, concept scientifiquement utilisable, à la parole, comme partie du langage propre à l'individu, en tant qu'il peut la créer et la modifier.

La deuxième forme de définition consiste à définir l'objet par son rapport

avec d'autres objets, situés sur le même plan : « ...la langue est une institution sociale; mais elle se distingue par plusieurs traits des autres institutions politiques, juridiques, etc. Pour comprendre sa nature spéciale, il faut faire intervenir un nouvel ordre de faits. La langue est un système de signes exprimant des idées, et par là comparable à l'écriture, à l'alphabet des sourds-muets, aux rites symboliques, aux formes de politesse, aux signaux militaires, etc. Elle est seulement le plus important de ces systèmes. On peut donc concevoir une science qui étudie la vie des signes au sein de la vie sociale; elle formerait une partie de la psychologie sociale, et par conséquent de la psychologie générale; nous la nommerons *séméiologie* » (Saussure, *ibid.*, p. 33).

Par cette définition, Saussure opère une double division : il oppose un système *séméiologique* (« le plus important » : la langue) à l'ensemble de tous les systèmes *séméiologiques*, qui sont pensés comme ayant un statut scientifique potentiellement équivalent, et entrant dans le champ de la théorie régionale du signifiant. Mais une autre opposition est évoquée par Saussure, au moyen du terme d'*institution* : elle lui permet de séparer les systèmes institutionnels juridique, politique, etc., de la série des systèmes institutionnels *séméiologiques*, et de les exclure purement et simplement du champ de la théorie régionale en question.

Ainsi, la langue est pensée par Saussure comme un objet scientifique homogène (appartenant à la région du « *séméiologique* »), dont la spécificité s'étaye sur deux exclusions théoriques :

- l'exclusion de la *parole* dans l'inaccessible de la science linguistique;
- l'exclusion des *institutions* « *non-séméiologiques* » hors de la zone de pertinence de la science linguistique.

Élucidons maintenant les conséquences qui résultent des deux définitions présentées.

1. LES IMPLICATIONS DE L'OPPOSITION SAUSSURIENNE ENTRE LANGUE ET PAROLE

Cette opposition appartient à la tradition linguistique post-saussurienne : « Entre les deux termes, la langue et la parole, l'antinomie est totale. La parole est un *acte*, donc une manifestation *actualisée* de la faculté de langage. Elle présuppose un contexte, une situation concrète et déterminée. La langue, par contre, est un système *virtuel* qui ne s'actualise que dans et par la parole. Il n'en reste pas moins que les deux principes sont interdépendants : la langue n'est que le résidu d'innombrables actes de parole, tandis que ceux-ci

ne sont que l'application, l'utilisation des *moyens d'expression* ⁽¹⁾ fournis par la langue. Il s'ensuit que la parole est un acte ou une activité individuelle qui s'oppose nettement au caractère *social* de la langue » (Ullmann, 1952, p. 16).

Ce texte met en lumière les conséquences de l'opération d'exclusion effectuée par Saussure : même s'il ne l'a pas explicitement voulu, c'est un fait que cette opposition autorise la réapparition triomphale du sujet parlant comme *subjectivité en acte*, unité active d'intentions qui se réalisent par les moyens mis à sa disposition ; en d'autres termes, tout se passe comme si la linguistique scientifique (ayant pour objet la langue) libérait un résidu qui est le concept philosophique de sujet libre, pensé comme l'envers indispensable, le corrélat nécessaire du système. La parole, comme usage de la langue, apparaît comme un *chemin de la liberté humaine* ; avancer sur le chemin étrange qui conduit des phonèmes au discours, c'est passer *gradatim* de la nécessité du système à la contingence de la liberté, comme le suggère ce texte de Jakobson, que corrigent, il est vrai, beaucoup d'indications :

« Ainsi existe-t-il dans la combinaison des unités linguistiques une échelle ascendante de liberté. Dans la combinaison de traits distinctifs en phonèmes, la liberté du locuteur individuel est nulle ; le code a déjà établi toutes les possibilités qui peuvent être utilisées dans la langue en question. La liberté de combiner les phonèmes en mots est circonscrite, elle est limitée à la situation marginale de la création de mots. Dans la formation des phrases à partir de mots, la contrainte que subit le locuteur est moindre. Enfin, dans la combinaison de phrases en énoncés, l'action des règles contraignantes de la syntaxe s'arrête et la liberté de tout locuteur particulier s'accroît substantiellement, encore qu'il ne faille pas sous-estimer le nombre des énoncés stéréotypés » (Jakobson, 1963, p. 47).

Dans la mesure donc où la langue se définit par l'ensemble des *règles universellement présentes* dans la « communauté » linguistique, on conçoit que les mécanismes qui la caractérisent aient été d'abord recherchés au niveau des combinaisons et substitutions élémentaires hors desquelles toute parole est impossible parce qu'elles en sont les indispensables moyens, donc *en bas de l'échelle*, à un niveau en toute hypothèse *inférieur à la phrase*. Or, les développements récents de certaines recherches linguistiques (et avant tout l'apparition des grammaires génératives) semblent repousser cette limite et tendent à constituer une *théorie linguistique de la phrase*, sans pour autant sortir du système de la langue : alors que Saussure pensait

(1) C'est nous qui soulignons.

que la langue ne crée rien, le fonctionnement d'une grammaire générative met en évidence une *forme de créativité non-subjective à l'intérieur même de la langue*.

Faut-il penser que la science linguistique va ainsi progressivement étendre son emprise et parvenir à rendre compte de toute « l'échelle » en utilisant des instruments combinatoires de plus en plus puissants ?

Il semble qu'il y ait ici une difficulté fondamentale, tenant à la nature de l'horizon théorique de la linguistique, jusque dans ses formes actuelles : on peut l'énoncer en disant qu'il n'est pas sûr que l'objet théorique permettant de penser le *langage* soit un et homogène, mais que peut-être la conceptualisation des phénomènes appartenant « au haut de l'échelle » nécessite un déplacement de la perspective théorique, un « changement de terrain » faisant intervenir des concepts extérieurs à la région de la linguistique actuelle. Le problème désormais classique de la « normalité de l'énoncé » est à nos yeux un indice exemplaire de cette difficulté : les conditions actuelles du fonctionnement d'une grammaire générative supposent un type de locuteur que nous appellerons *neutralisé*, c'est-à-dire lié à la normalité universelle des « énoncés canoniques », où la position des classes d'équivalence (par exemple : sujet animé + objet inanimé) est *a priori* fixée comme une *propriété* de la langue. C'est donc par rapport à cette normalité supposée dans la langue que « l'énoncé anomal » se trouve défini. Or cette thèse semble à bien des égards extrêmement fragile, comme le montre l'exemple suivant : s'interrogeant pour savoir si la phrase appartient à l'ordre de la parole ou à celui de la langue, Saussure écrit :

« Il faut attribuer à la langue, non à la parole, tous les types de syntagmes construits par des formes régulières... il en est exactement de même des phrases ou des groupes de mots établis sur des patrons réguliers ; des combinaisons comme *la terre tourne*, *que vous dit-il ?* etc., répondent à des types généraux, qui ont à leur tour leur support dans la langue sous forme de souvenirs concrets » (Saussure, *op. cit.*, p. 173).

Soit donc la phrase « la terre tourne » : un linguiste pré-copernicien, connaissant par miracle les grammaires génératives et les travaux actuels des sémanticiens, aurait certainement posé une incompatibilité entre les parties constitutives de la phrase et déclaré l'énoncé anomal.

C'est dire que la phrase ne peut pas toujours être dite normale ou anormale par seule référence à une *norme* universelle inscrite dans la langue, mais que cette phrase doit être référée au *mécanisme discursif* spécifique qui l'a rendue possible et nécessaire, dans un contexte scientifique donné. En d'autres termes, il semble indispensable de mettre en question l'identité implicitement établie par Saussure entre l'universel et l'extra-individuel, en

montrant la possibilité de définir un niveau intermédiaire entre la singularité individuelle et l'universalité, à savoir le niveau de la *particularité* définissant des « contrats » linguistiques spécifiques de telle ou telle région du système, c'est-à-dire des faisceaux de normes plus ou moins localement définis, et inégalement aptes à diffuser les uns sur les autres; ainsi que l'écrit Jakobson : « Sans aucun doute, pour toute communauté linguistique, pour tout sujet parlant, il existe une unité de la langue, mais ce code global représente un système de sous-codes en communication réciproque; chaque langue embrasse plusieurs systèmes simultanés dont chacun est caractérisé par une fonction différente » (Jakobson, *op. cit.*, p. 213).

Certes, le concept de « champ sémantique » représente bien un pas dans cette direction, puisqu'il vise les contraintes sémantiques entre les éléments morphématiques, leurs rapports *in praesentia* et *in absentia* dans une aire de signification donnée. Toutefois, il ne rend pas compte des effets séquentiels liés à la discursivité. Autrement dit, le concept de champ sémantique recouvre bien une des deux significations du mot « rhétorique » (c'est-à-dire la rhétorique comme savoir portant sur « le choix des mots », leurs « alliances réciproques », etc.), mais non l'autre signification (c'est-à-dire la rhétorique comme savoir portant sur la « disposition », « l'ordre et l'enchaînement des idées », etc.) : en termes empruntés à la logique, on peut dire que la normalité locale qui contrôle la production d'un type de discours donné concerne non seulement la nature des prédicats qui sont attribués à un sujet, mais aussi les transformations que ces prédicats subissent au fil du discours et qui conduisent celui-ci vers sa fin, aux deux sens du mot.

Nous proposerons de désigner par le terme de *processus de production* l'ensemble des mécanismes formels qui produisent un discours de type donné, dans des « circonstances » données.

Il résulte de ce qui précède que l'étude des processus discursifs suppose deux ordres de recherches :

— l'étude des variations spécifiques (sémantiques, rhétoriques et pragmatiques) liées aux processus de production particuliers considérés, sur le « fond invariant » de la langue (essentiellement : la syntaxe, comme source de contraintes universelles). Nous précisons plus loin les concepts et la méthodologie utilisés ⁽¹⁾.

— L'étude de la liaison entre les « circonstances » d'un discours — que nous appellerons désormais ses *conditions de production* ⁽²⁾ — et son processus de production. Cette perspective est représentée dans la théorie linguistique actuelle par le rôle assigné au *contexte* ou à la *situation*, comme

⁽¹⁾ Cf. p. 28.

⁽²⁾ Cf. p. 16.

arrière-fond spécifique des discours, rendant possible leur formulation et leur compréhension : c'est cet aspect de la question que nous allons tenter d'éclaircir maintenant, à travers un examen critique du concept saussurien d'*institution*.

2. LES IMPLICATIONS DU CONCEPT SAUSSURIEN D'INSTITUTION

Selon Saussure, la langue est une institution sociale parmi d'autres, ce qui entraîne qu'on puisse énoncer la différence spécifique qui la place dans la série des institutions comme une espèce à l'intérieur d'un genre : tout semble clair une fois précisé que cette différence spécifique s'appelle le *séméiologique*. Toutefois, on rencontre dans le Cours de Linguistique Générale un autre type de différence, qui remet encore une fois en cause les « autres » institutions et dont l'évaluation critique est pour nous fondamentale.

Saussure écrit en effet : « Les autres institutions humaines — les coutumes, les lois, etc. — sont toutes fondées, à des degrés divers, sur les rapports naturels des choses; il y a en elles une convenance nécessaire entre les moyens employés et les fins poursuivies... La langue, au contraire, n'est limitée en rien dans le choix de ses moyens » (Saussure, *op. cit.*, p. 110).

Nous retrouvons ici l'indication du renversement que nous décrivions en commençant, et qui consiste à montrer que la langue ne peut être définie par une « convenance nécessaire » (une harmonie téléologique) entre les moyens et les fins : or, pour bien faire entendre la nouveauté de ce qu'il énonce, Saussure fait appel aux propriétés fonctionnelles des autres institutions, comme à une *évidence*; en d'autres termes, c'est parce que Saussure continue à penser les institutions en général comme des moyens adaptés à des fins qu'il peut faire ressortir le cas unique de la langue, pour laquelle il n'est pas de moyen prédestiné par nature.

Il n'est certes pas question de faire reproche à Saussure d'avoir ignoré ce que les sociologues de son temps commençaient à discerner : nous noterons simplement que, dans la Grande Encyclopédie Française de 1901, Mauss et Fauconnet définissaient la sociologie comme la science des institutions en précisant : « Les institutions sont l'ensemble des actes et des idées toutes instituées que les individus trouvent devant eux et qui s'imposent plus ou moins à eux » (cité in Gurwitsch, 1958, p. 9), définition que Saussure aurait pu accepter pour caractériser la langue, « partie sociale du langage ».

De fait, il est indéniable que l'un des résultats les plus décisifs de la sociologie contemporaine consiste précisément à savoir distinguer la *fonction apparente* d'une institution et son *fonctionnement implicite*; les normes des comportements sociaux ne sont pas plus transparentes à leurs « acteurs »

que les normes de la langue ne le sont au locuteur; « le sens objectif de leur conduite... les possède parce qu'ils en sont dépossédés » (Bourdieu, 1965, p. 20). C'est dire que, rétrospectivement, Saussure nous semble ici affecté de la nécessaire illusion du non-sociologue, qui consiste à considérer les institutions en général comme des fonctions à finalité explicite⁽¹⁾.

Ceci n'est pas sans conséquences à l'égard de la théorie des processus discursifs.

Soit en effet le discours d'un député à la Chambre. Du strict point de vue saussurien, le discours est, en tant que tel, de l'ordre de la *parole* où se manifeste la « liberté du locuteur », encore que, bien entendu, il relève de l'ordre de la *langue* en tant que séquence syntaxiquement correcte. Mais le même discours est saisi par le sociologue comme une *partie* d'un mécanisme en fonctionnement, c'est-à-dire comme appartenant à un système de normes ni purement individuelles, ni globalement universelles, mais relevant de la structure d'une idéologie politique, et donc correspondant à une certaine *place* à l'intérieur d'une formation sociale donnée.

Autrement dit, un discours est toujours prononcé à partir de *conditions de production* données : par exemple, le député appartient à un parti politique participant au gouvernement, ou à un parti d'opposition; il est le porte-parole de tel ou tel groupe représentant tel ou tel intérêt, ou bien il est « isolé », etc. Il est donc, bon gré mal gré, situé à l'intérieur du *rapport de forces* existant entre les éléments antagonistes d'un champ politique donné : ce qu'il dit, ce qu'il annonce, promet ou dénonce, n'a pas le même statut selon la place qu'il occupe, la même déclaration peut être une arme redoutable ou une comédie ridicule selon la position de l'orateur et de ce qu'il représente, par rapport à ce qu'il dit : un discours peut être un acte politique direct ou un geste vide, pour « donner le change », ce qui est une autre forme d'action politique. On peut évoquer ici le concept d'« énoncé performatif », introduit par J. L. Austin, pour souligner la relation nécessaire entre un discours et sa place dans un mécanisme institutionnel extra-linguistique.

Si l'on poursuit l'analyse du discours politique — qui ne sert ici que de représentant exemplaire des divers types de processus discursifs —, on voit qu'il doit être par ailleurs référé aux *rapports de sens* dans lesquels il est produit : ainsi tel discours renvoie à tel autre, à l'égard duquel il est une réponse directe ou indirecte, ou dont il « orchestre » les termes principaux, ou dont il anéantit les arguments. En d'autres termes, le processus discursif n'a pas, en droit, de début : le discours s'étaye toujours sur du discursif

(1) On pourrait retrouver la trace de l'opposition : fonction apparente/fonctionnement implicite chez Merton (fonction manifeste/fonction latente) et aussi chez Durkheim.

préalable auquel il fait jouer le rôle de matière première, et l'orateur sait que lorsqu'il *évoque* tel événement ayant déjà fait l'objet d'un discours, il ressuscite dans l'esprit de ses auditeurs le discours où cet événement était allégué, avec les « déformations » qu'introduit la situation présente, et dont il peut tirer parti.

Ceci implique que l'orateur éprouve d'une certaine manière la place de l'auditeur à partir de sa propre place d'orateur : son habileté à imaginer, à devancer l'auditeur est parfois décisive, s'il sait prévoir en temps voulu là où cet auditeur « l'attend »⁽¹⁾. Cette anticipation de *ce que l'autre va penser* semble constitutive de tout discours, à travers des variations qui sont définies à la fois par le champ des possibles de la pathologie mentale appliquée au comportement verbal⁽²⁾, et par les modes de riposte que le fonctionnement de l'institution autorise à l'auditeur : un sermon et une conversation à bâtons rompus « fonctionnent » différemment sur ce point. Dans certains cas, l'auditeur ou l'auditoire peuvent *bloquer* le discours, ou au contraire *l'étayer*, par des interventions directes ou indirectes, verbales ou non verbales.

Par exemple, le député à la Chambre peut être interrompu par un adversaire qui, situé en une autre « place » (c'est-à-dire dont le discours répond à d'autres conditions de production), tentera d'attirer l'orateur sur son terrain, de l'obliger à répondre sur un sujet scabreux pour lui, etc. Il existe, d'autre part, un système de signes non-linguistiques tels que, dans le cas du discours parlementaire, les applaudissements, les rires, le tumulte, les sifflets, les « mouvements divers », qui rendent possibles des interventions indirectes de l'auditoire sur l'orateur; ces comportements sont, le plus souvent, des *gestes* (des actes au niveau du symbolique), mais peuvent déborder vers des interventions physiques directes; malheureusement, une théorie du geste comme acte symbolique fait défaut⁽³⁾, dans l'état actuel de la théorie du signifiant, ce qui laisse nombre de problèmes non résolus : lorsque, par exemple, les « anarchistes » lançaient des bombes au milieu des Assemblées, quel était l'élément dominant, du geste symbolique signifiant l'interruption la plus brutale qui soit, ou de la tentative de destruction physique visant tel ou tel personnage politique estimé nuisible?

(1) Robert PAGES (in « Image de l'émetteur et du récepteur dans la communication », *Bulletin de Psychologie de l'Université de Paris*, avril 1955) remarque que l'émetteur se guide, « s'ajuste » dans son discours par des présuppositions visant « un public relativement déterminé ». Dans certains cas, ajoute-t-il, l'émetteur est informé de « l'écho » rencontré par ses émissions antérieures chez le récepteur et modifie au fur et à mesure ses présuppositions.

(2) Cf. en particulier sur ce point les travaux de L. IRIGUAY, *Langage*, n° 5, p. 84 sq.

(3) Notons pourtant que, dans un numéro récent consacré aux « pratiques et langages gestuels » (*Langages*, n° 10, juin 1968), certains éléments de cette théorie se trouvent réunis.

Parmi les questions que nous venons d'évoquer, beaucoup resteront ici sans réponse. Notre propos n'est pas, en effet, d'amorcer une *sociologie des conditions de production du discours*, mais de définir les éléments théoriques permettant de penser les processus discursifs dans leur généralité : nous énonçons, à titre de proposition générale, que les *phénomènes linguistiques de dimension supérieure à la phrase peuvent effectivement être conçus comme un fonctionnement*, mais à la condition d'ajouter immédiatement que *ce fonctionnement n'est pas intégralement linguistique, au sens actuel de ce terme*, et qu'on ne peut le définir qu'en référence au *mécanisme de mise en place des protagonistes et de l'objet du discours*, mécanisme que nous avons appelé les « conditions de production » du discours.

Nous faisons l'hypothèse qu'à un état donné des conditions de production correspond une structure définie du processus de production du discours à partir de la langue, ce qui signifie que, si l'état des conditions est fixé, l'ensemble des discours susceptibles d'être engendrés dans ces conditions manifeste des invariants sémantico-rhétoriques, stables dans l'ensemble considéré et caractéristiques du processus de production mis en jeu. Ceci suppose qu'il est impossible d'analyser un discours comme un texte, c'est-à-dire comme une séquence linguistique fermée sur elle-même, mais qu'il est nécessaire de le référer à l'ensemble des discours possibles à partir d'un état défini des conditions de production, comme nous le montrerons dans la suite.

Nous proposerons donc d'abord un schéma formel permettant d'aboutir à une définition opérationnelle de l'état des conditions de production d'un discours; nous décrirons ensuite les requis théoriques et méthodologiques nécessaires à la représentation du processus de production qui correspond à un état donné.

B) Les conditions de production du discours

1. LES ÉLÉMENTS STRUCTURELS APPARTENANT AUX CONDITIONS DE PRODUCTION


Deux familles de schémas sont en compétition à propos de la description *extrinsèque* du comportement linguistique en général (par opposition à l'analyse *intrinsèque* de la chaîne parlée) :

— un schéma « réactionnel » qui relève des théories psycho-physiologiques et psychologiques du comportement (schéma « stimulus-réponse » ou « stimulus-organisme-réponse »);

— un schéma « informationnel » qui relève des théories sociologiques et psycho-sociologiques de la communication (schéma « émetteur-message-récepteur »).

Le premier schéma semble encore largement dominer la pensée actuelle : « ...les préférences de la majorité, écrivent S. Moscovici et M. Plon (1966, p. 720), vont vers une saisie du fondement du langage dans l'organisation du système nerveux qui est sa matrice matérielle, non pas dans cette communication dont on dit qu'elle est sa fonction. Pour cette raison, disons qu'une progression théorique sous l'angle psycho-sociologique n'est pas suffisante, mais qu'un changement des options actuelles est nécessaire, qui situerait la psychologie sociale à côté des autres disciplines psychologiques en vue de comprendre le langage. »

Soit en effet l'application du schéma *S-O-R* au comportement verbal :




Cette représentation présente l'inconvénient d'annuler la place du producteur de (S) et du destinataire de (R) : cette annulation est parfaitement légitime lorsque la stimulation est *physique* (par exemple, une variation d'intensité lumineuse) et la réponse *organique* (par exemple, une variation de la réponse E.E.G.); dans ce cas, en effet, l'expérimentateur est seulement le constructeur d'un montage qui fonctionne indépendamment de lui, aux artefacts expérimentaux près. Dans une expérience sur le « comportement verbal » au contraire, l'expérimentateur est une *partie du montage*, quelle que soit la modalité de sa *présence*, physique ou non, dans les conditions de production du discours-réponse : autrement dit, le stimulus n'est stimulus qu'en référence à la situation de « communication verbale » où se scelle le pacte provisoire entre l'expérimentateur et son sujet. Les mêmes auteurs déjà cités écrivent à ce propos : « ...l'attitude skinnerienne revient à exclure, dans l'examen du comportement humain, en général, et du comportement linguistique en particulier, l'action de règles, de normes que les individus établissent entre eux. Par là, elle aboutit aussi à minimiser la dimension symbolique qu'acquiert le langage, de par son association avec ces règles et le rôle, non négligeable, qu'il joue dans leur constitution » (*Ibid.*, p. 718). C'est dire que le schéma *S-O-R* implique trop « d'oubli » théoriques dans le domaine qui nous occupe pour être conservé sous cette forme.

Le schéma « informationnel » présente au contraire l'avantage de mettre en scène les protagonistes du discours, ainsi que son « référent ». Faisant

l'inventaire des « facteurs constitutifs de tout procès linguistique », Jakobson écrit : « Le destinataire envoie un message au destinataire. Pour être opérant, le message requiert d'abord un *contexte* auquel il renvoie (c'est ce qu'on appelle aussi, dans une terminologie quelque peu ambiguë, le "réfèrent"), contexte saisissable par le destinataire, et qui est soit verbal, soit susceptible d'être verbalisé; ensuite, le message requiert un *code*, commun, ou tout au moins en partie, au destinataire et au destinataire (ou, en d'autres termes, à l'encodeur et au décodeur du message); enfin, le message requiert un *contact*, un canal physique ou une connexion psychologique entre le destinataire et le destinataire, contact qui permet d'établir et de maintenir la communication » (Jakobson, 1963, p. 213-214).

Le schéma devient alors :



avec, respectivement :

A : le « destinataire »,

B : le « destinataire »,

R : le « réfèrent »,

$(\mathcal{L})$: le code linguistique commun à A et à B ,

$\rightarrow$: le « contact » établi entre A et B ,

D : la séquence verbale émise par A en direction de B .

Remarquons que, à propos de « D », la théorie de l'information, sous-jacente à ce schéma, conduit à parler de *message* comme transmission d'information : ce que nous avons dit précédemment nous fait préférer ici le terme de *discours* qui implique qu'il ne s'agit pas nécessairement d'une transmission d'information entre A et B , mais, plus généralement, d'un « effet de sens » entre les points A et B .

On peut désormais énoncer les différents éléments structurels des conditions de production du discours.

Il est bien clair, tout d'abord, que les éléments A et B désignent autre chose que la présence physique d'organismes humains individuels. Si ce que nous avons dit précédemment a un sens, il en résulte que A et B désignent des places déterminées dans la structure d'une formation sociale, places dont la sociologie peut décrire le faisceau de traits objectifs caractéristiques : ainsi, par exemple, à l'intérieur de la sphère de la production économique, les places du « patron » (directeur, chef d'entreprise, etc.), du cadre, du

contremaître, de l'ouvrier sont marquées par des propriétés différentielles repérables.

Notre hypothèse est que ces places sont *représentées* dans les processus discursifs où elles sont mises en jeu. Toutefois, il serait naïf de supposer que la place comme faisceau de traits objectifs fonctionne comme telle à l'intérieur du processus discursif; elle y est représentée, c'est-à-dire *présente, mais transformée*; en d'autres termes, ce qui fonctionne dans le processus discursif, c'est une série de formations imaginaires désignant la place que A et B s'attribuent chacun à *soi* et à *l'autre*, l'image qu'ils se font de leur propre place et de la place de l'autre. S'il en est bien ainsi, il existe dans les mécanismes de toute formation sociale des règles de projection, établissant les rapports entre les *situations* (objectivement définissables) et les *positions* (représentations de ces situations). Ajoutons qu'il est fort probable que cette correspondance ne soit pas biunivoque, de sorte que des différences de situation peuvent correspondre à une même position, et qu'une même situation peut se représenter selon plusieurs positions, et ceci non pas au hasard, mais selon des lois que seule une investigation sociologique pourra révéler.

Ce que nous pouvons dire, c'est seulement que tout processus discursif suppose l'existence de ces formations imaginaires, que nous désignerons ici de la manière suivante :

Expression désignant les formations imaginaires	Signification de l'expression	Question implicite dont la « réponse » sous-tend la formation imaginaire correspondante
A {	$I_A(A)$	« Qui suis-je pour lui parler ainsi ? »
	$I_A(B)$	« Qui est-il pour que je lui parle ainsi ? »
B {	$I_B(B)$	« Qui suis-je pour qu'il me parle ainsi ? »
	$I_B(A)$	« Qui est-il pour qu'il me parle ainsi ? »

Nous venons d'esquisser la manière dont la position des protagonistes du discours intervient à titre de conditions de production du discours. Il convient maintenant d'ajouter que le « référent » (R dans le schéma ci-dessus, le « contexte », la « situation » dans laquelle apparaît le discours) appartient également aux conditions de production. Soulignons à nouveau qu'il s'agit d'un *objet imaginaire* (à savoir le point de vue d'un sujet) et non de la réalité physique.

On posera donc :

	Expression désignant les formations imaginaires	Signification de l'expression	Question implicite dont la « réponse » sous-tend la formation imaginaire correspondante
A	$I_A(R)$	« Point de vue » de A sur R .	« De quoi lui parle-t-il ainsi ? »
B	$I_B(R)$	« Point de vue » de B sur R .	« De quoi me parle-t-il ainsi ? »

Enfin, nous avons indiqué plus haut ⁽¹⁾ que tout processus discursif supposait, de la part de l'émetteur, une *anticipation des représentations du récepteur*, sur laquelle se fonde la stratégie du discours.

On formera donc les expressions :

$$A \begin{cases} I_A(I_B(A)) \\ I_A(I_B(B)) \\ I_A(I_B(R)) \end{cases} \quad B \begin{cases} I_B(I_A(B)) \\ I_B(I_A(A)) \\ I_B(I_A(R)) \end{cases}$$

exprimant la manière dont A se représente les représentations de B , et réciproquement, à un moment donné du discours.

Il est à noter que, puisqu'il s'agit, par hypothèse, d'*anticipations*, ces valeurs *précèdent* les éventuelles « réponses » de B , venant sanctionner les

⁽¹⁾ Cf. p. 15.

décisions anticipatrices de A : les anticipations de A à l'égard de B , par exemple, doivent donc être pensées comme dérivées de $I_A(A)$, $I_A(B)$ et $I_A(R)$.

Nous symboliserons cette dérivation par les expressions suivantes qui, actuellement, nous servent seulement à expliciter nos hypothèses sur la nature spécifique de la dérivation dans chaque cas :

$$I_A(I_B(A)) = f(I_A(B)) \cdot (I_A(A))$$

$$I_A(I_B(B)) = g(I_A(A)) \cdot (I_A(B))$$

$$I_A(I_B(R)) = h(I_A(R)) \cdot (I_A(B))$$

On voit dans chaque cas que l'anticipation de B par A dépend de la « distance » que A suppose entre A et B : ainsi se trouvent formellement différenciés les discours où il s'agit pour l'orateur de *transformer l'auditeur* (tentative de persuasion, par exemple), et ceux où *l'orateur et son auditeur s'identifient* (phénomène de complicité culturelle, « clin d'œil » manifestant l'accord, etc.).

Il résulte de ce qui précède que l'état n des conditions de production du discours $\mathcal{D}_n$ que A adresse à B à propos de R — que nous noterons $I^n_x(A, B)$ — sera représenté par le vecteur suivant ⁽¹⁾ :

$$I^n_x(A, B) = \begin{bmatrix} I^n_A(A) \\ I^n_A(B) \\ I^n_A(R) \\ I^n_A(I^n_B(A)) \\ I^n_A(I^n_B(B)) \\ I^n_A(I^n_B(R)) \end{bmatrix}$$

⁽¹⁾ Remarquons qu'il existe un certain nombre de traits rhétoriques (syntaxiques et sémantiques) susceptibles de renvoyer explicitement à tel ou tel de ces éléments ou instances de I^n_x .

Par exemple :

$I^n_A(I^n_B(A))$: « Vous allez penser que je suis indiscret ».

$I^n_A(I^n_B(R))$: « "Quelle chose étrange", diriez-vous... ».

Cela ne signifie pas pour autant que tout fragment de la séquence discursive puisse être référé de façon univoque à une instance déterminée.

D'autre part, nous laissons ici de côté la question de savoir si des expressions de degré supérieur ont ou non une signification à l'égard du problème considéré.

Ceci appelle plusieurs remarques :

Tout d'abord, en ce qui concerne la nature des éléments appartenant au vecteur ci-dessus, il a déjà été indiqué qu'il s'agit de *représentations imaginaires* des différentes instances du processus discursif : nous précisons désormais nos hypothèses à ce sujet en ajoutant que les diverses formations résultent elles-mêmes de processus discursifs antérieurs (relevant d'autres conditions de production) ayant cessé de fonctionner, mais ayant donné naissance à des « prises de position » implicites qui assurent la possibilité du processus discursif envisagé. Par opposition à la thèse « phénoménologique » qui poserait l'*appréhension perceptive* du référent, de l'autre et de soi-même comme *condition pré-discursive du discours*, nous supposons que la perception est toujours traversée par du « déjà entendu » et du « déjà dit », à travers lesquels se constitue la substance des formations imaginaires énoncées; les concepts de *pré-supposition* et d'*implication*, présentés et utilisés par O. Ducrot⁽¹⁾, mettent en jeu le même genre d'hypothèse : à propos de la situation qui, écrit cet auteur, « ne peut plus être conçue de façon simplement chronologique ou géographique, comme une localisation spatio-temporelle », il ajoute : « La "situation de discours", à laquelle renvoient les présuppositions, comporte, comme partie intégrante, certaines connaissances que le sujet parlant prête à son auditeur. Elle concerne donc l'image que se font les uns des autres les participants du dialogue »⁽²⁾.

Par ailleurs, il est clair que, dans un état donné des conditions de production d'un discours, les éléments qui constituent cet état ne sont pas simplement juxtaposés, mais entretiennent entre eux des rapports susceptibles de varier selon la nature des éléments mis en jeu : il semble possible d'avancer que tous les éléments de I_x^n n'ont pas une efficacité nécessairement égale, mais que, selon un système de règles qui reste à définir, l'un des éléments peut devenir *dominant* à l'intérieur des conditions d'un état donné. I_x^n apparaît ainsi comme une séquence ordonnée, éventuellement de type vectoriel, où certains termes ont la propriété de déterminer la nature, la valeur et la place des autres termes.

En effet, soit par exemple une série de discours caractérisés par ce seul fait qu'il y a question de « la liberté » : selon qu'il s'agit d'un professeur de philosophie s'adressant à ses élèves, d'un directeur de prison commentant le règlement à l'usage des détenus, ou d'un thérapeute adressant la parole à son patient, on assiste à un *déplacement de l'élément dominant* dans les conditions de production du discours : soit A l'émetteur et B le

(1) O. DUCROT, « Logique et linguistique », *Langages*, n° 2.

(2) *Ibid.*, p. 20-21.

récepteur; dans le discours thérapeutique, tel qu'il est conçu par la psychiatrie classique, c'est l'image que le patient se fait de soi-même qui est l'enjeu du discours, soit $I_B(B)$. Dans la relation pédagogique, c'est la représentation que les élèves se font de ce que leur désigne le professeur qui domine le discours, soit $I_B(I_A(R))$, dans son rapport à $I_A(R)$. Enfin, dans le discours du directeur de prison, tout est conditionné par l'image que les détenus se formeront du représentant du règlement à travers son discours, soit $I_B(A)$, puisqu'il s'agit pour les uns de savoir « jusqu'où on pourra aller avec lui », et pour l'autre de le leur signifier.

Dans cette perspective, l'objet d'une sociologie du discours serait donc de repérer les liens entre les *rapports de force* (extérieurs à la situation de discours) et les *rapports de sens* qui se manifestent dans celle-ci, en mettant systématiquement en évidence les *variations de dominance* que nous venons d'évoquer.

2. ESQUISSE D'UNE REPRÉSENTATION FORMELLE DES PROCESSUS DISCURSIFS

Ainsi que nous l'avons annoncé précédemment⁽¹⁾, nous faisons l'hypothèse que les conditions de production d'un discours $\mathcal{D}_x$ à l'état n étant données, soit I_x^n , il est possible de leur faire correspondre un processus de production de $\mathcal{D}_x$ à l'état n , processus que nous désignerons par Δ_x^n .

Mais on a vu, d'autre part, qu'un état donné des conditions de production devait être compris comme résultant de processus discursifs sédimentés⁽²⁾ : on voit qu'il est donc impossible de définir une origine des conditions de production, puisque cette *origine*, proprement *impensable*, supposerait une *récurSION infinie*. Par contre, il est possible de s'interroger sur les transformations des conditions de production à partir d'un état donné de ces conditions.

Nous traiterons donc successivement de deux questions :

- la question de la correspondance entre I_x^n et Δ_x^n ,
- la question de la transformation $I_x^n \rightarrow I_x^{n+1}$.

Les opérations abstraites que nous allons introduire sur les éléments précédemment définis rendent possible, selon nous, l'ébauche d'une description formelle des processus discursifs. La formulation que nous en donnons

(1) Cf. p. 16.

(2) Cf. p. 22.

ci-dessous reste incomplète et provisoire; notre présent but est seulement de montrer la possibilité générale d'une telle théorie, et de situer le cas particulier auquel se réduit la partie actuelle de notre travail, par rapport aux phénomènes plus complexes que nous laissons pour l'instant de côté.

RÈGLE 1

Le processus de production d'un discours D_x (à l'état n) résulte de la composition des conditions de production de D_x (à l'état n) avec un système linguistique $\mathcal{L}$ donné.

Nous conviendrons de désigner cette opération de composition par le symbole $\circ$, et nous écrirons :

$$\Gamma_x^n \circ \mathcal{L} \rightarrow \Delta_x^n$$

L'interprétation que l'on peut donner de cette règle est la suivante : Γ_x^n fonctionne comme un principe de sélection-combinaison sur les éléments de la langue $\mathcal{L}$, et constitue à partir d'eux le système de liaisons sémantiques qui représente la matrice du discours D_x à l'état n , c'est-à-dire les *domaines sémantiques* et les *dépendances entre ces domaines*. Ajoutons que l'effectuation de cette opération présente en fait plusieurs niveaux hiérarchisés : comme nous le montrerons dans la suite ⁽¹⁾, la constitution de l'énoncé — phrase élémentaire — ne répond pas aux mêmes lois sémantiques, rhétoriques et pragmatiques que la disposition des énoncés dans la séquence discursive.

A partir de prémisses théoriques assez différentes de celles exposées ici, le travail de L. Doležal (1964) manifeste, par les buts qu'il se propose, une convergence intéressante à noter : « Utilisant les unités élémentaires du code et les règles du code, écrit-il, la source de l'information linguistique — le codeur — produit des messages concrets — les discours — qui sont une représentation des ensembles d'événements extra-linguistiques et qui transmettent l'information de ces événements. »

Nos considérations théoriques antérieures doivent avertir le lecteur des divergences que nous enregistrons ici : les concepts d'*information*, de *message* et d'*événement extra-linguistique*, en particulier, relèvent de pré-supposés empiristes dont nous pensons avoir signalé en temps utile les difficultés. Toutefois, l'entreprise de L. Doležal reste à beaucoup d'égards éclairante pour notre propos; il poursuit, en effet : « L'unité fondamentale qu'on obtient comme résultat du processus de codage est la phrase; une phrase

⁽¹⁾ Cf. p. 34.

ou une suite de phrases constitue le message linguistique, le discours... il faut établir et spécifier l'ensemble des règles dont l'application permet de ranger, pendant le processus de codage, les mots en phrases et les phrases en message » (*ibid.*, p. 52).

Ajoutons que l'auteur cité émet explicitement l'hypothèse du caractère stationnaire des « paramètres de la langue », que nous reprenons à notre compte.

RÈGLE 2

Tout processus de production Δ_x^i , composé avec un état déterminé n des conditions de production d'un discours D_x , induit une transformation de cet état.

Nous conviendrons de désigner cette composition par le symbole $*$, et nous écrirons :

$$\Gamma_x^n * \Delta_x^i \rightarrow \Gamma_x^{n+1}$$

Cette règle met en évidence l'effet de transformation qu'induit la présence d'un processus particulier dans le champ discursif sur l'état des conditions de production : il est clair, tout d'abord, que le discours que A adresse à B modifie l'état de B , dans la mesure où B peut comparer ses « anticipations » de A au discours de A .

Mais nous avons, d'autre part, souligné ⁽¹⁾ que tout orateur était un auditeur virtuel de son propre discours, ce qui implique que ce qui est dit par A transforme également les conditions de production propres à A , en lui permettant de « poursuivre » son discours; les « troubles du comportement narratif », caractérisés par la perte du fil du récit, l'incessant retour au début, etc., pourraient être interprétés comme une perturbation de ce mécanisme.

Ces deux règles appellent quelques commentaires. En premier lieu, on voit que la première règle correspond à l'émission de la séquence discursive, alors que la seconde concerne sa réception, c'est-à-dire qu'elles jouent respectivement un rôle comparable à ce qu'on appelle souvent l'*encodage* et le *décodage*. Il est à noter toutefois que l'opposition langage/réalité, qui sert fréquemment de fondement à ces deux concepts, ne fonctionne pas ici et que la « symétrie » entre le codage et le décodage, souvent invoquée comme une nécessité, disparaît également.

En deuxième lieu, la seconde règle (« règle de décodage ») comporte,

⁽¹⁾ Cf. p. 15.

déterminer la structure du processus de production (Δ_x) qui correspond à Γ_x , c'est-à-dire l'ensemble des *domaines sémantiques* mis en jeu dans $\mathcal{D}_x$, ainsi que les *relations de dépendance* existant entre ces domaines. »

Nous supposons qu'il est possible de définir empiriquement un ensemble d'émetteurs identifiables quant à l'état des conditions de production de $\mathcal{D}_x$ (et non pas, bien entendu, pour tout discours en général). Ainsi qu'il a été indiqué précédemment ⁽¹⁾, la constitution de cet ensemble repose à la fois sur le contrôle des *variables sociologiques objectives* caractéristiques de la « place » du destinataire, et sur celui des *formations imaginaires* propres à la situation de $\mathcal{D}_x$, dont un jeu préalable de questions indirectes aura pour fonction de vérifier le contenu.

C) Pour une analyse du processus de production du discours

« La linguistique structurale classique, écrit T. Todorov (1966, p. 5), présentait ainsi, en gros, sa démarche : il existe un corpus de faits de langue; il faut trouver des notions et des relations qui en permettent une description non contradictoire, exhaustive et simple. La théorie de la grammaire générative inverse le rapport; elle se demande : quelles règles linguistiques applique-t-on inconsciemment ou consciemment pour produire des phrases correctes d'une langue donnée? L'analyse cède sa place à la synthèse; on manie donc un système de règles au lieu d'un système d'éléments. »

Supposons que les résultats de cette *révolution copernicienne*, qui organise la langue autour du « sujet parlant », soient directement applicables à la théorie du discours : cela signifierait que l'objectif primordial est de se donner un ensemble de règles permettant d'engendrer *du discours*, et que l'on peut, sans inconvénient, se dispenser d'analyser *les effets de surface de la séquence discursive*, ce qui serait une préoccupation *protéologique* dépassée. Or notre hypothèse est, on l'a vu, que ce transfert de résultats entre le « sujet parlant » (*neutralisé* par rapport aux conditions de production du discours) et un hypothétique « sujet du discours » est illicite : ce que nous avons dit précédemment suppose en effet qu'il n'y a *pas de sujet psychologique universel* supportant le processus de production de tous les discours possibles, au sens où le sujet représenté par une grammaire générative est apte à engendrer toutes les phrases grammaticalement correctes d'une langue. En d'autres termes, nous pensons que la *continuité méthodologique* que l'on suppose parfois ici est actuellement suspecte, dans la mesure où elle implique,

⁽¹⁾ Cf. p. 18, sqq.

pour passer du sujet de la langue au sujet du discours, l'existence de règles *sélectives* fonctionnant au niveau du « vocabulaire terminal », lesquelles règles renvoient en fait à une *analyse* des éléments morphématiques en *traits sémantiques* dont on s'accorde en général à reconnaître le caractère hautement problématique. Cela signifie qu'en définitive *on ne peut éviter ici le détour par une analyse*, mais qu'elle reste le plus souvent implicite et non systématique : elle repose en effet généralement sur une *conception atomistique des significations*, de sorte que les lexèmes ou les morphèmes sont arbitrairement analysés comme des unités décomposables en « sèmes » existant en soi ⁽¹⁾, et les propriétés combinatoires sont déduites à partir de règles de compatibilité intersèmes tout aussi arbitrairement posées ⁽²⁾. Il semble par ailleurs qu'en ce domaine le principe : « pas d'éléments, mais des relations et des règles » soit singulièrement occulté.

Dans ces conditions, et puisque aussi bien le détour par une analyse paraît inévitable actuellement, nous considérons qu'il est préférable d'en poser explicitement les principes : nous dirons donc que la série des *surfaces* discursives $\mathcal{D}_{x1}, \dots, \mathcal{D}_{xm}$ constitue une *trace* du processus de production Δ_x du discours $\mathcal{D}_x$, c'est-à-dire de la « structure profonde » commune à $\mathcal{D}_{x1}, \dots, \mathcal{D}_{xm}$. Notre entreprise consiste donc à remonter de ces « effets de surface » à la structure invisible qui les détermine : ce n'est qu'ensuite qu'une théorie générale des processus de production discursifs deviendra *réalisable*, en tant que *théorie de la variation réglée des « structures profondes »*.

1. L'EFFET MÉTAPHORIQUE

Considérons la question suivante :

Soit deux termes x et y appartenant à une même catégorie grammaticale dans une langue donnée $\mathcal{L}$. Existe-t-il au moins un discours à l'intérieur duquel x et y puissent être substitués l'un à l'autre sans changer l'interprétation de ce discours?

Posons $S(x, y)$, l'opération de substitution respectant la contrainte indiquée et $\mathcal{D}_x$ une suite de termes engendrée par Δ_x dans la langue $\mathcal{L}$, correspondant à un état Γ_x parmi l'ensemble des états possibles.

⁽¹⁾ Cette opération est souvent appelée « analyse componentielle ».

⁽²⁾ Il est à remarquer que, sur ce point, Chomsky lui-même reste plus discret et plus prudent que nombre de théoriciens s'inspirant de sa pensée. Il reste d'autre part toujours possible d'envisager la constitution d'une sémantique qui ne serait pas taxinomique.

Trois cas sont logiquement possibles, à savoir :

- 1) $\sim \exists D_m S(x, y)$.
 x et y ne sont jamais substituables l'un à l'autre.
- 2) $\exists D_m S(x, y)$ et $\sim \forall D_m S(x, y)$.
 x et y sont parfois substituables l'un à l'autre, mais pas toujours.
- 3) $\forall D_m S(x, y)$.
 x et y sont toujours substituables l'un à l'autre.

Considérons les cas 2) et 3) où la substitution est possible :

- 2) représente le cas où x et y sont substituables en fonction d'un contexte donné.

Par exemple : x = brillant
 y = remarquable

x et y sont substituables dans certains contextes.

Par exemple : ce mathématicien est (x/y)
 ou bien : la démonstration de ce mathématicien est (x/y).

Mais il existe d'autres contextes pour lesquels x et y ne sont pas substituables.

Par exemple : la lumière *brillante* du phare l'aveugla;
 ou bien : cette courbe comporte un point *remarquable*.

- 3) représente au contraire le cas où x et y sont substituables *quel que soit le contexte*; nous proposons comme exemple :

x = refréner
 y = réprimer,

couple à propos duquel l'existence d'un contexte empêchant la substitution paraît problématique. Remarquons cependant que, pour être certaine, la décision de classer le couple *refréner/réprimer* en 3) devrait s'appuyer sur un examen de tous les contextes discursifs possibles pour une langue donnée. Autrement dit, si le couple x/y appartient à 2), il est possible de le savoir *en un temps fini*, ce qui n'est évidemment pas le cas pour 3).

Nous désignerons la possibilité de substitution 2) par le terme de *synonymie locale* ou *contextuelle*, par opposition à la possibilité 3) que nous appellerons *synonymie non-contextuelle*.

On voit que, en présence d'un ensemble fini de discours correspondant à un même I_m , on doit, par prudence, considérer que toutes les synonymies sont contextuelles, jusqu'à ce qu'il s'avère éventuellement que certaines d'entre elles sont conservées à travers toutes les variations étudiées de I : la synonymie non-contextuelle apparaîtrait ainsi comme une limite vers laquelle tend une synonymie contextuelle vérifiée sur des conditions de production de plus en plus nombreuses, ce qui renvoie à la question des *intersections sémantiques non-vides*. Nous faisons, quant à nous, l'hypothèse que les synonymies contextuelles sont la règle, et que les synonymies non-contextuelles sont exceptionnelles, si l'on se réfère à la théorie saussurienne de la valeur :

« Dans l'intérieur d'une même langue, tous les mots qui expriment des idées voisines se limitent réciproquement : des synonymes comme *redouter*, *craindre*, *avoir peur* n'ont de valeur propre que par leur opposition; si *redouter* n'existait pas, tout son contenu irait à ses concurrents » (Saussure, *op. cit.*, p. 160).

Remarquons que, en fait, il est possible d'envisager des synonymies contextuelles entre deux groupes de termes ou expressions produisant le même effet de sens par rapport à un contexte donné.

Nous appellerons *effet métaphorique* le phénomène sémantique produit par une substitution contextuelle, pour rappeler que ce « glissement de sens » entre x et y est constitutif du « sens » désigné par x et y ; cet effet est caractéristique des systèmes linguistiques « naturels », par opposition aux codes et aux « langues artificielles » où le sens est fixé par rapport à une méta-langue « naturelle » : en d'autres termes, un système « naturel » ne comporte pas de méta-langue à partir de laquelle ses termes pourraient se définir : il est à lui-même sa propre méta-langue.

On voit dès lors qu'il est fondamentalement nécessaire de disposer d'une série de séquences représentatives d'un I_x donné pour pouvoir mettre en évidence les *points d'ancrage sémantique* qui se définissent par le recoupement des métaphores.

Expliquons-nous sur ce point par un exemple dont le caractère *empiriquement invraisemblable* ne doit pas masquer la signification théorique :

Soit un état I_x , et un corpus C_x de discours strictement représentatifs de cet état, $C_x = D_{x1}, D_{x2}, \dots, D_{xn}$.

Désignons par une lettre chacun des mots composant les discours considérés (à chaque mot différent correspond une lettre différente, et réciproquement).

Soient les séquences de ces n discours :

$\mathcal{D}_{x1}$	a	g	d	b	h		y
$\mathcal{D}_{x2}$	j	g	d	b	h		y
$\mathcal{D}_{x3}$	j	k	d	b	h		y
$\mathcal{D}_{x4}$	j	k	m	b	h		y
$\mathcal{D}_{x5}$	j	k	m	x	h		y
$\mathcal{D}_{x6}$	j	k	m	x	w		y
$\mathcal{D}_{x_{n-1}}$	j	k	m	x	w		y
$\mathcal{D}_{xn}$	j	k	m	x	w		z

On voit que chaque discours $\mathcal{D}_{xi}$ est supposé différer du précédent $\mathcal{D}_{x(i-1)}$ par une seule substitution, l'ensemble du contexte étant chaque fois conservé. On a donc une série d'effets métaphoriques (a/j , g/k , d/m , etc.) dont l'effet est de maintenir un ancrage sémantique à travers une variation de la surface du texte, puisque à la limite $\mathcal{D}_{xn}$ ne contient plus aucun des termes appartenant à $\mathcal{D}_{x1}$ et lui est pourtant, par définition, sémantiquement équivalent.

Cet exemple, purement fictif, et d'ailleurs parfaitement impossible, a pour seule fonction de mettre en évidence ce que nous entendons par conservation de l'invariant à travers la variation morphématique : le même système de représentations se réinscrit à travers des variantes qui le répètent de proche en proche : c'est cette répétition de l'identique à travers des formes nécessairement diverses qui caractérise à nos yeux le mécanisme d'un processus de production ; la « structure profonde » apparaît ainsi comme un tissu d'éléments solidaires, s'étayant et s'assurant lui-même à travers les effets métaphoriques qui permettent d'engendrer une série quasi infinie de « surfaces » tout en astreignant celles-ci à des limites de fonctionnement au-delà desquelles la « structure profonde » éclaterait (1).

(1) Le mot « surface », introduit par Chomsky (structure de surface/structure profonde), doit ici être référé à son contexte géométrique, à savoir : la surface comme juxtaposition de lignes discursives $\mathcal{D}_{x1}$, ..., $\mathcal{D}_{xn}$. Il s'agit donc moins de référer la séquence linéaire aux opérations sous-jacentes dont elle serait la trace, que de rapporter chaque

Dans ces conditions, la confrontation réciproque des formes variées de la surface permet, en multipliant la présence du discours à lui-même, de manifester la structure invariante du processus de production pour un état donné, structure dont les variations sont le symptôme.

Nous allons désormais exposer comment cette confrontation peut être effectivement réalisée.

2. DE LA SURFACE DISCURSIVE A LA STRUCTURE DU PROCESSUS DE PRODUCTION

Considérons l'exemple théorique qui vient d'être exposé : nous l'avons utilisé simplement pour représenter l'effet métaphorique tel que nous le définissons, en indiquant que la réalisation d'un tel exemple était impossible. Il importe donc de préciser maintenant les déterminations qui avaient été provisoirement laissées de côté dans cette représentation abstraite.

Nous mettrons ainsi successivement en évidence :

- L'impossibilité concrète de l'hypothèse-limite concernant l'existence de deux discours appartenant à la même structure de production et ne possédant aucun terme commun.
- Les conséquences, qui résultent de ce premier point, concernant la notion de *contexte*, et l'élaboration théorique que cette notion nécessite.
- L'existence d'un effet de dominance à l'intérieur de la production d'une séquence discursive donnée, dont le résultat est de découper des zones de pertinence à l'intérieur de la séquence, en fonction d'un Δ_x donné.

En ce qui concerne le premier point, il est clair que l'hypothèse proposée est déjà quasiment impossible à soutenir à propos de deux discours quelconques, étant donné l'existence dans la langue d'un petit nombre de mots-opérateurs très fréquents, dont l'usage n'est pas sémantiquement lié à un contexte donné. Par ailleurs, et ceci est, pour notre propos, plus fondamental, il semble que les lois sémantico-rhétoriques régissant les glissements de sens dans un Δ_x imposent de place en place certains blocages, de sorte que certaines métaphores n'existent dans le discours qu'à l'état « endormi », auquel cas la substitution qui donne un sens au terme employé ne fonctionne pas à l'intérieur du discours (ainsi, par exemple, le « lever du soleil » repré-

ligne discursive à l'ensemble des autres lignes qui lui sont parallèles, pour un état donné de conditions de production. Le profond ne serait pas, dès lors, sous la surface, mais dans le rapport que chaque surface (en sens de Chomsky) entretient avec ses variations, dans la surface (en sens « géométrique » que nous lui donnons).

sente une métaphore endormie dans la mesure où l'état actuel des lois de substitution n'autorise pas de forme commutable avec « lever » (1). Dans cette mesure, on peut donc supposer, à travers la série des séquences discursives, l'existence de *butées* manifestées par la répétition de certains termes *autour desquels s'effectuent les déplacements métaphoriques*.

Cela revient à dire que l'on ne passe pas nécessairement d'une séquence discursive à une autre par une seule substitution, mais que les deux séquences sont en général reliées l'une à l'autre par une série d'effets métaphoriques. Mais si l'on admet que plusieurs effets métaphoriques peuvent fonctionner entre tel discours donné et le reste du corpus, cela signifie du même coup que le contexte d'une substitution n'est pas nécessairement le discours dans son entier, ce qui nous conduit à poser le problème de la segmentation des contextes à l'intérieur de la séquence discursive. Dans l'article déjà cité, Jakobson écrit : « Tout signe est composé de signes constituants et/ou apparaît en combinaison avec d'autres signes. Cela signifie que toute unité linguistique sert en même temps de contexte à des unités plus simples et/ou trouve son propre contexte dans une unité linguistique plus complexe. D'où il suit que tout assemblage effectif d'unités linguistiques les relie dans une unité supérieure » (Jakobson, 1963, p. 48). Et il ajoute : « Le destinataire perçoit que l'énoncé donné (message) est une *combinaison* de parties constitutives (phrases, mots, phonèmes) sélectionnées dans le répertoire de toutes les parties constitutives possibles (code) » (*ibid.*). Si l'on prenait ce texte à la lettre, on pourrait supposer que du *phonème* au *discours*, on est en présence de signes linguistiques dont la dimension augmente, mais qui restent liés à la même *règle de combinaison*. S'il en était ainsi, on voit qu'il serait impossible de définir le *contexte d'une substitution*, faute de connaître la dimension du signe à laquelle il convient de s'arrêter.

Cette difficulté est levée à condition de reconnaître à la phrase un statut tout à fait particulier : celui de frontière séparant la linguistique de la théorie du discours. Benveniste fournit sur ce point des précisions importantes : « Avec la phrase une limite est franchie, nous entrons dans un nouveau domaine... Nous pouvons segmenter la phrase, nous ne pouvons pas l'employer à intégrer... Du fait que la phrase ne constitue pas une classe d'unités distinctives, qui seraient membres virtuels d'unités supérieures, comme le sont les phonèmes ou les morphèmes, elle se distingue foncièrement des autres entités linguistiques. Le fondement de cette différence est que la

(1) Le « discours implicite » exigé, on l'a vu (cf. p. 22), par l'orateur de la part de l'auditeur n'est pas davantage *présent dans les termes* à l'intérieur du discours de l'orateur, ce qui fonde pour ce dernier la possibilité d'engendrer les *figures de style*, en jouant sur les attentes de l'autre.

phrase contient des signes, mais n'est pas elle-même un signe » (Benveniste, 1966, p. 128).

Nous emploierons pour notre compte le terme d'*énoncé* pour distinguer la phrase élémentaire en tant qu'elle est l'objet unique sur lequel opère le mécanisme du discours. Il résulte de ce qui précède qu'il n'y a pas entre les énoncés de relations de combinaison/substitution permettant de construire à partir d'eux le discours comme unité supérieure, puisque l'énoncé est déjà de l'ordre du discours : « La phrase appartient bien au discours, écrit encore Benveniste; c'est même par là qu'on peut la définir : la phrase est l'unité du discours » (Benveniste, *ibid.*, p. 130).

En d'autres termes, une substitution a toujours pour contexte l'énoncé, considéré comme combinaison-substitution de lexèmes, tandis qu'on ne peut pas dire qu'un énoncé ait un contexte, au même sens du mot, puisque les énoncés peuvent être liés par une relation de *dépendance fonctionnelle*, c'est-à-dire que la *contiguïté syntagmatique entre les éléments* — principe fondamental de l'analyse linguistique du signe à ses divers niveaux — cède le pas à la *liaison fonctionnelle logique-rhétorique* qui n'est plus astreinte à la connexité : deux énoncés peuvent être en relation fonctionnelle à travers un espace discursif neutre à l'égard de cette relation.

On voit dès lors que notre problème revient à savoir mettre en rapport les propriétés internes des énoncés (comme combinaison de signes) et leurs propriétés externes (comme éléments fonctionnels dans le discours), afin de déterminer les cas où l'*interprétation sémantique* — au sens que la logique assigne à cette expression — est identique pour deux énoncés donnés. Nous poserons que, pour qu'il y ait effet métaphorique entre deux termes x et y appartenant à deux énoncés E_a et E_b , eux-mêmes respectivement situés dans deux discours $\mathcal{D}_{x_i}$ et $\mathcal{D}_{x_j}$ représentatifs d'un même Δ_x , il faut que E_a et E_b aient une *interprétation sémantique identique*, ce que nous noterons

$$\mathcal{I}(E_a) = \mathcal{I}(E_b)$$

c'est-à-dire :

a) que les lexèmes de E_a et de E_b fournissent un *contexte commun de substitution* pour x et y , condition que nous appellerons « condition de proximité paradigmatique » entre E_a et E_b .

b) que les énoncés E_a et E_b aient une *position fonctionnelle* identique à l'égard de deux autres énoncés E_c et E_d appartenant respectivement à $\mathcal{D}_{x_i}$ et $\mathcal{D}_{x_j}$ et ayant eux-mêmes une *interprétation sémantique identique*, soit

$$\mathcal{I}(E_c) = \mathcal{I}(E_d) \quad (1).$$

(1) Ces points seront traités de manière plus détaillée au chapitre II, p. 95.

Illustrons ce qui précède par un exemple; soit les énoncés suivants :

$E_1 = E'_1$ = le shérif avançait prudemment en direction du saloon

$E_2 = E'_2$ = l'orage grondait

E_3 = un coup de feu traversa la nuit

E_4 = un éclair traversa la nuit

E_5 = la foudre traversa la nuit

$E_6 = E'_6$ = la balle le frôla

$E_7 = E'_7$ = la grange était en flammes.

— Soit les opérateurs inter-énoncés suivants :

φ_1 = « soudain » (relation temporelle entre un énoncé-état et un énoncé-événement).

φ_2 = « : » (relation explicative).

— Soient deux processus de production F_x et F_y tels que :

$$C_x \left\{ \begin{array}{l} D_{x1} \\ \vdots \\ D_{xe} \quad E_1 \xrightarrow{\varphi_1} E_3 \xrightarrow{\varphi_2} E_6 \\ \vdots \\ D_{xk} \quad E'_1 \xrightarrow{\varphi_1} E_4 \xrightarrow{\varphi_2} E'_6 \\ \vdots \\ D_{xn} \end{array} \right.$$

$$C_y \left\{ \begin{array}{l} D_{y1} \\ \vdots \\ D_{yf} \quad E_2 \xrightarrow{\varphi_1} E_4 \xrightarrow{\varphi_2} E_7 \\ \vdots \\ D_{yh} \quad E'_2 \xrightarrow{\varphi_1} E_5 \xrightarrow{\varphi_2} E'_7 \\ \vdots \\ D_{ym} \end{array} \right.$$

Posons enfin les *équivalences d'interprétation sémantique* suivantes, supposées obtenues par une phrase antérieure de l'analyse :

$$\mathcal{I}(E_1) = \mathcal{I}(E'_1)$$

$$\mathcal{I}(E_6) = \mathcal{I}(E'_6)$$

$$\mathcal{I}(E_2) = \mathcal{I}(E'_2)$$

$$\mathcal{I}(E_7) = \mathcal{I}(E'_7)$$

On voit tout d'abord que E_3 , E_4 , E_5 remplissent les uns par rapport aux autres la « condition de proximité paradigmatisée », car les termes :

un coup de feu

un éclair

la foudre

sont substituables dans le contexte

« ...traversa la nuit ».

D'autre part, E_3 et E_4 ont une interprétation sémantique identique dans C_x , en raison de $\mathcal{I}(E_1) = \mathcal{I}(E'_1)$. Il en résulte l'effet métaphorique M_1 dans C_x :

$$M_1 = \begin{array}{l} \text{un coup de feu} \\ \text{un éclair} \end{array}$$

De la même manière, E_4 et E_5 ont une interprétation sémantique identique dans C_y , en raison de $\mathcal{I}(E_2) = \mathcal{I}(E'_2)$. Il en résulte l'effet métaphorique M_2 dans C_y :

$$M_2 = \begin{array}{l} \text{un éclair} \\ \text{la foudre} \end{array}$$

Il est à noter que les relations d'interprétation sémantique ne sont pas transitives, puisque

$$\begin{array}{l} \mathcal{I}(E_3) = \mathcal{I}(E_4) \\ \text{et } \mathcal{I}(E_4) = \mathcal{I}(E_5) \end{array} \quad \text{n'impliquent pas } \mathcal{I}(E_3) = \mathcal{I}(E_5)$$

En effet, l'application des règles d'interprétation énoncées ci-dessus met en évidence que $\mathcal{I}(E_3) \neq \mathcal{I}(E_5)$, puisque la « condition de proximité paradigmatisée » entre E_3 et E_5 est remplie, mais non la condition d'identité des positions fonctionnelles. En effet, $\mathcal{I}(E_1) \neq \mathcal{I}(E'_1)$ et $\mathcal{I}(E_6) \neq \mathcal{I}(E'_6)$.

Il reste enfin à exposer ce que nous entendons par l'effet de dominance à l'intérieur de la production d'une séquence discursive donnée; nous avons jusqu'ici raisonné dans les termes suivants : « Soit un état F_x donné, comment déterminer Δ_x par l'analyse d'un ensemble de discours le représentant? ». Cela supposerait que chaque élément de la surface discursive renvoie nécessairement à Δ_x avec une nécessité égale, et donc que tous les discours

correspondant au même état de production sont strictement parallèles, c'est-à-dire absolument isomorphes, compte tenu des effets métaphoriques qui les différencient.

Or, c'est là, remarquera-t-on, une éventualité hautement improbable : le parallélisme est de place en place rompu par les distorsions « individuelles » du discours, lequel semble ainsi « échapper » au processus de production, par une « création infinie », une « variété sans limite » qui serait le propre de la parole ⁽¹⁾.

Nous pensons qu'il est possible de rendre compte de ce phénomène sans abandonner nos présupposés théoriques antérieurs, fondés sur la *détermination* du processus discursif par ses conditions de production et le refus de la notion idéologique de « création infinie ». Nous introduirons sur ce point le concept de *dominance*, en précisant que toute situation de production du discours peut être caractérisée par le *processus de production dominant* Δ_x qu'elle induit, mais que les *séquences discursives concrètes* qui manifestent Δ_x résultent nécessairement de l'interaction du processus dominant avec des *processus secondaires*, dont l'enchevêtrement produit toutes les apparences de l'aléatoire, de l'infiniment imprévisible, face à l'ignorance totale où nous sommes encore actuellement concernant les mécanismes de cette interaction.

Nous sommes désormais à même de formuler plus correctement notre objectif actuel, en disant : étant donné un état dominant des conditions de production du discours, il lui correspond un processus de production dominant que l'on peut mettre en évidence par la confrontation des différentes surfaces discursives empiriques relevant de ce même état dominant : les points de recoupement définis par les effets métaphoriques permettront ainsi d'extraire les *domaines sémantiques* déterminés par le processus dominant, et les *relations de dépendance logique-rhétorique* impliquées entre ces domaines, le reste du matériel discursif empiriquement rencontré tombant hors de la zone de pertinence du processus dominant.

Ceci suppose, répétons-le, qu'un discours ne présente pas, dans sa matérialité textuelle, une *unité organique à un seul niveau* que l'on pourrait mettre en évidence à partir du discours lui-même, mais que toute forme discursive particulière renvoie nécessairement à la série de ses formes possibles, et que ces renvois de la surface de chaque discours aux surfaces possibles qui lui sont (en partie) juxtaposées dans l'opération d'analyse constituent précisément les *symptômes pertinents* du processus de production dominant régissant le discours soumis à l'analyse.

⁽¹⁾ Nous empruntons ces termes à Benveniste, qui rapporte ainsi de manière évidente le discours à la parole.

CHAPITRE II

DESCRIPTION D'UN DISPOSITIF D'ANALYSE AUTOMATIQUE DU PROCESSUS DISCURSIF

I. RÈGLES POUR L'ENREGISTREMENT CODÉ DE LA SURFACE DISCURSIVE

Nous supposons à partir de maintenant que les conditions que nous avons définies antérieurement sont remplies, c'est-à-dire que la série des $\mathcal{D}$ soumise à l'enregistrement et à l'analyse correspond bien à un même état dominant des conditions de production, induisant un processus de production Δ_x .

On désignera donc par $\mathcal{D}_{x1}, \mathcal{D}_{x2}, \dots, \mathcal{D}_{xn}$ les n discours recueillis empiriquement dans les conditions précédemment définies, en considérant qu'ils sont *représentatifs de l'ensemble des discours possibles* associé aux mêmes conditions : nous montrerons plus loin qu'il existe des moyens formels permettant de décider, pour une valeur donnée de n , si le « corpus » ainsi constitué est suffisamment *systématique*, ou non, pour être représentatif de la structure du Δ_x cherché. Disons simplement, pour l'instant, que nous supposons défini un corpus de dimension n tel que la probabilité de pouvoir constituer à partir des éléments de ce corpus une surface $\mathcal{D}_{x1}$, extérieure au corpus et appartenant à l'ensemble des discours possibles représentatifs de Δ_x , soit supérieure à une valeur fixée antérieurement.

On voit ainsi que le problème consiste à analyser toute surface $\mathcal{D}_{x1}$ donnée en *éléments minimaux* liés entre eux selon des lois propres à Δ_x .

Ce qui a été exposé au précédent chapitre suppose que nous définissions deux niveaux d'analyse :

1. le niveau d'analyse des *énoncés* dans le D, liés entre eux par des relations fonctionnelles caractéristiques du Δ_x considéré;
2. le niveau d'analyse des *lexèmes* dans l'énoncé, liés entre eux par des lois de combinaison/commutation caractéristiques du Δ_x considéré.

Or il est clair que cette double analyse ne peut fonctionner qu'à la condition d'une double hypothèse sur l'objet linguistique en général, quel que soit le Δ_x considéré, à savoir :

1. toute séquence linguistique est constituée d'un ensemble structuré d'énoncés en relation, discernables à partir des lois linguistiques générales;
2. tout énoncé linguistique est composé de lexèmes, ayant entre eux des rapports morpho-syntaxiques universellement nécessaires, relevant d'une théorie grammaticale de l'énoncé.

Tout se passe donc comme si nous avions à poser d'abord des *propriétés invariantes* par rapport à la variété des processus de production, propriétés qui puissent servir de cadre de référence aux variations que nous voulons mettre en évidence. Nous parlerons donc d'abord des conséquences qu'entraîne l'existence de cet invariant à l'égard de l'enregistrement de la surface discursive, considéré comme étape préparatoire indispensable à l'analyse du discours.

Nous ne prétendons pas fournir ici davantage qu'une *esquisse* de ce processus d'enregistrement, sachant bien que nous laissons au linguiste un grand nombre de décisions que nous ne pouvons prendre à sa place. C'est seulement la *direction générale* que nous voulons ici indiquer et défendre, dans la mesure où elle conditionne la deuxième phase de l'analyse qui est, du point de vue de l'étude du processus discursif, le véritable enjeu.

A) De la surface discursive au graphé des énoncés

1. LES MARQUES D'ARRÊT : DÉFINITION DE LA PHRASE

Une surface discursive peut être considérée, quant à sa forme immédiate, comme une séquence linguistique limitée par deux *blancs sémantiques*, c'est-à-dire deux silences (réels ou virtuels) correspondant au changement des conditions que représentent l'accès au rôle de locuteur et la sortie hors de ce même rôle. On voit que le cadrage du discours entre ces deux « blancs »

est un effet du contrôle des conditions de production, de sorte que le phénomène est hors de notre champ actuel ⁽¹⁾.

Mais d'autre part, la séquence linguistique est ponctuée d'arrêts que la notation écrite du discours code par le « point » (le « point-virgule » et les « deux-points » ayant aussi parfois ce rôle).

Quel rapport convient-il d'établir entre cet *arrêt* et le *silence* que nous venons de mentionner? Il est clair d'emblée qu'il est impossible de les identifier : dans cette hypothèse en effet, la phrase, comme espace entre deux arrêts dans un discours, serait elle-même un discours sans rapport avec ce qui le précède et ce qui le suit. Il suffit, sur cette question, de faire référence aux difficultés induites par le traitement « phrase par phrase » auquel les méthodes actuelles de traduction automatique sont encore assujetties et dont elles tentent précisément de se libérer.

Nous poserons donc en principe que le « point » n'est pas un *blanc sémantique*, une sorte de « remise à zéro » périodique du mécanisme sémantique à l'intérieur du discours, mais qu'il joue le rôle d'un *opérateur polyvalent* susceptible de masquer la juxtaposition, l'opposition, la conséquence, etc., entre deux phrases.


On sait que l'ensemble du signifiant non-verbal (la mimique, les gestes, le ton, etc.), qui accompagne le discours oral, intervient dans cette ponctuation pour distinguer l'arrêt de la phrase et le silence de fin de discours, et pour qualifier la valeur que l'on donne à l'arrêt : l'arrêt représente donc bien un effet de sens entre les deux phrases, dont le récepteur est supposé pouvoir résoudre l'ambiguïté. Certains signes comme les « deux-points », certains termes ou syntagmes placés en général aussitôt après l'arrêt dans la notation écrite fonctionnent à cet égard comme réducteurs d'ambiguïté, comme nous le verrons plus loin ⁽²⁾.

Si donc nous considérons ici provisoirement la phrase comme un *sous-système muni de relations spécifiques*, cela tient seulement aux nécessités de l'exposition : nous montrerons ensuite les conséquences de ce que nous venons d'évoquer, à savoir l'absorption du niveau de la phrase dans celui du discours, ce qui exclut, répétons-le, l'idée d'une construction du discours comme juxtaposition de phrases, pensées comme des *signes* régis par la règle de combinaison/commutation ⁽³⁾.

⁽¹⁾ Le blanc sémantique final renvoie à l'achèvement de droit (et non de fait) du discours, et donc à des règles internes de fermeture.

⁽²⁾ Cf. p. 44-45.

⁽³⁾ Cf. p. 34.



2. LES DÉPENDANCES FONCTIONNELLES DANS LA PHRASE

Il existe une théorie classique de la phrase, comme séquence entre deux marques d'arrêt, fondée sur la notion de proposition : si l'on appelle proposition la partie d'une phrase qui ne comporte qu'un verbe à un mode personnel, on dira que toute phrase comporte une *proposition principale* et un nombre variable de propositions « coordonnées » ou « subordonnées » à la principale par des « mots de liaison » de nature grammaticalement variable, et que nous regrouperons sous le terme d'*opérateurs de dépendance interpropositionnelle*.

Par exemple :

- || Il est malade, (mais) il n'est pas mort.
- || Il ronfle (pendant qu') il dort.

Convenons que dans la relation $p_1 \varphi_a p_2$, la proposition p_1 est dite *dominer directement* la proposition p_2 . On dira alors que la proposition principale peut dominer directement une ou plusieurs autres propositions, et qu'elle-même n'est pas dominée directement à l'intérieur de la phrase.

Notons toutefois dès maintenant que la règle de dépendance est réursive puisque une proposition p_3 peut être dominée par une proposition p_2 , qui est elle-même directement dominée par une proposition p_1 , de sorte que p_2 joue le rôle d'une principale par rapport à p_3 , encore qu'elle dépende de p_1 dans la phrase considérée.

Soit par exemple la phrase suivante :

- || Le bois est plus léger que l'eau puisqu'il remonte à la surface lorsqu'on l'enfonce dans l'eau.

Appelons a , b et c les propositions qu'elle contient :

- a = le bois est plus léger que l'eau
- b = le bois remonte à la surface
- c = on enfonce le bois dans l'eau

et

- φ_1 = puisque
- φ_2 = lorsque.


La séquence se réécrit donc textuellement :

$$a \varphi_1 b \varphi_2 c,$$

mais étant donné que φ_1 porte à la fois sur b et c — ou, plutôt, sur la relation binaire $b \varphi_2 c$ —, on écrira

$$a \varphi_1 (b \varphi_2 c)$$

ce que l'on peut représenter par le schéma



utilisé en logique combinatoire.

Remarquons que b est l'origine de φ_2 comme a est celle de φ_1 , ce qui traduit que b est une proposition principale par rapport à c , de la même façon que a est une proposition principale par rapport à $(b \varphi_2 c)$; nous étudierons plus loin ⁽¹⁾ les propriétés formelles de cette écriture. Il suffit de noter pour l'instant qu'elle permet d'indiquer des *emboitements de dépendance* correspondant à la « structure profonde » de la phrase. L'enregistrement des dépendances fonctionnelles correspondant à la structure de surface d'une phrase suppose donc des interventions préalables dans cette surface.

Tout d'abord, l'ordre canonique des dépendances doit être rétabli à partir des indices fournis par les opérateurs, en tenant compte des « mises en facteur » qui ne sont pas repérables directement dans la surface : ceci suppose donc une recherche linguistique particulière sur les rapports entre la nature des opérateurs et leur position relative, ainsi que sur le rôle des *anaphoriques* ⁽²⁾ pronominaux comme indices de dépendance entre les propositions qu'ils connectent. Il doit ainsi être possible de définir des règles combinatoires éliminant certaines possibilités d'écriture, de manière à ce que la surface d'une phrase fournisse des solutions peu nombreuses — idéalement, une seule — au problème de l'emboîtement des dépendances.

Exemple de rétablissement de l'ordre canonique :

- || Quand je l'ai trouvé, l'homme était déjà mort, je l'affirme.
- || J'affirme (que) (l'homme était déjà mort (quand) j'ai trouvé l'homme).

D'autre part, les morphèmes non-connexes représentant des opérateurs doivent être regroupés :

- || Il était si bon que tout le monde le vénérât.
- || Il était bon (si ... que — au point que) tout le monde le vénérât.

⁽¹⁾ Cf. p. 51 sqq.

⁽²⁾ Nous désignons par *anaphorique* ce que la littérature anglo-saxonne entend par le terme de « Shifter ».

Par ailleurs, certaines propositions latentes doivent être rétablies à partir d'indices fournis par la surface. Par exemple :

|| J'ai vu l'express de Bordeaux et l'autorail du Mans.

→ || J'ai vu l'express de Bordeaux (*et*) j'ai vu l'autorail du Mans.

Signalons que cette décomposition soulève une difficulté, signalée par Chomsky dans son article « Syntaxe logique et sémantique : une pertinence linguistique » (Chomsky, 1966, p. 48-49) : il montre en effet que la phrase

|| L'homme est grand et mince.
peut être décomposée en

|| L'homme est grand (*et*) l'homme est mince
alors que le groupe « noir et blanc » est indécomposable dans la phrase

|| Le drapeau est noir et blanc
ce qui suppose la définition de *règles de décomposition*.

Enfin, certaines expressions constituent des propositions latentes qui doivent être « libérées » par une transformation pour pouvoir apparaître dans le système des dépendances ⁽¹⁾. Par exemple :

|| Il lui a demandé de répondre sitôt la lettre reçue.

→ || Il lui a demandé [(*que*) il réponde (*sitôt que*) il a reçu la lettre].

Ce problème est lié à celui de transformation de l'énoncé, que nous examinerons plus loin ⁽²⁾.

3. LES DÉPENDANCES FONCTIONNELLES ENTRE LES PHRASES

Nous avons montré que la règle de dépendance était *réursive*, ce qui sous-entendait que la *notion de proposition principale*, substantialisée par la grammaire classique, devait en fait toujours être pensée en référence à la partie du système de dépendance considéré : une proposition est *principale par rapport* à un certain nombre de propositions qui dépendent d'elle. Il suffit dès lors de prendre le *discours* comme référence et les *marques d'arrêt* comme *opérateurs* pour concevoir une généralisation de la notion de dépendance au-delà de la phrase.

Considérons en effet la phrase :

|| La voiture démarre (*car*) le feu est vert.

⁽¹⁾ Nous appellerons T , l'ensemble de ces transformations.

⁽²⁾ Cf. p. 77.

Il est clair qu'on peut la transformer en une séquence de deux phrases liées par un opérateur de dépendance équivalent à *car*, soit :

|| La voiture démarre (.) + (En effet) le feu est vert.

« En effet » est un syntagme figé qui vient qualifier la *marque d'arrêt* représentée par (.).

L'enregistrement doit donc extraire des propositions les éléments qui jouent le rôle d'opérateurs, y compris les propositions qui fonctionnent en fait comme opérateurs de dépendance, par exemple :

|| Il est peut-être arrivé (.) + (Toujours est-il que) je ne l'ai pas vu.

Il est important de noter que cette *qualification* de la marque d'arrêt peut aller de l'*absence pure et simple*

|| Six heures sonnent (.) Elle ne viendra pas.

à la *phrase explicative*

|| Six heures sonnent (.) + (Il est clair qu') elle ne viendra pas.

en passant par des adverbes et locutions adverbiales

|| Six heures sonnent (.) + (A présent) elle ne viendra pas.

certaines conjonctions,

|| Six heures sonnent (.) + (**Donc**) elle ne viendra pas.

ou la virgule

|| Six heures sonnent (.) elle ne viendra pas.

Ceci suppose une investigation systématique de ces différents signes, permettant de définir leurs classes d'équivalence et leurs règles de fonctionnement. Par exemple, il est nécessaire de pouvoir déterminer si un adverbe fonctionne en tant que qualification de la marque d'arrêt, ou au contraire comme modulation du verbe d'un énoncé; de même pour les phrases déclaratives du type de « il est clair que », « je suppose que » etc. ⁽¹⁾.

On posera donc comme principe général que les relations de dépendance fonctionnelle φ_n doivent être posées entre les propositions du discours, ce qui revient à absorber le niveau de la phrase dans celui du discours, en considérant que la marque d'arrêt — éventuellement qualifiée — n'est pas essentiellement différente des autres opérateurs de dépendance. Cela revient à dire que l'on considère la surface discursive comme un ensemble de propositions muni de relations de dépendance φ_n pour certains couples de cet ensemble : l'assignation de la dépendance entre deux propositions, et son attribution à un opérateur φ_n ne dépend pas de la contiguïté matérielle des

⁽¹⁾ Ce problème est lié à celui de la modalisation de l'énoncé, cf. p. 75.

deux propositions mais résulte de la combinaison de plusieurs critères; nous avons évoqué la position relative des propositions et de leur rapport au terme ou syntagme représentant φ_x dans la surface, ainsi que l'existence de connexions sémantiques révélées par le jeu des « anaphoriques » (1). L'automatisation de cette phase de l'enregistrement nécessitera la position de règles explicitant le fonctionnement combiné de ces divers critères.

4. LA STRUCTURE DE LA PROPOSITION

Traitant de la phrase, nous avons montré que le jeu des dépendances fonctionnelles entre propositions débordait le niveau de la phrase vers le niveau du discours. Nous allons maintenant montrer que les dépendances fonctionnelles existent également à l'intérieur de la proposition et conduisent jusqu'au niveau de ce que nous définirons par le terme d'énoncé; nous aboutirons ainsi à représenter la surface discursive comme un ensemble d'énoncés liés entre eux par des dépendances fonctionnelles; les objets intermédiaires (propositions et phrases) s'y trouvent dès lors absorbés.

Soit une proposition, définie comme la partie d'une phrase ne comportant qu'un verbe à un mode personnel, et telle que les propositions latentes qui pouvaient s'y trouver impliquées en aient été extraites par transformation (2). On peut dès lors la décrire comme constituée par la combinaison d'un groupe *sujet* (ou syntagme nominal sujet) et d'un groupe *prédicat*.

Si l'on reprend les notations classiques, à savoir

SN_1 = syntagme nominal sujet

SN_2 = syntagme nominal objet (direct ou indirect)

SN_3 = syntagme circonstanciel

SV = syntagme verbal

on a

$$P = \begin{cases} SN_1 + SV \\ SN_1 + SV + SN_2 \\ SN_1 + SV + SN_3 \end{cases}$$

Distinguons le complément d'objet direct (suivant le verbe sans préposition) — soit SN_2 —, du complément d'objet indirect (caractérisé par la présence d'une préposition) — soit $p_x^1 + SN_2'$.

(1) Cf. p. 43.

(2) Cf. p. 44.

Notons d'autre part p_x^2 la préposition introduisant ordinairement le complément circonstanciel (1).

Nous obtenons ainsi :

$$P = \begin{cases} (1) & SN_1 + V \\ & \parallel \text{Midi sonne} \\ (2) & SN_1 + V + \quad + SN_2 \\ & \parallel \text{La marchande vend des bonbons} \\ (3) & SN_1 + V + p_x^1 + SN_2' \\ & \parallel \text{Le professeur parle aux élèves} \\ (4) & SN_1 + V + p_x^2 + SN_3 \\ & \parallel \text{Le voyageur est parti avec la valise} \end{cases}$$

à quoi il faut ajouter

$$(5) \quad SN_1 + V + SN_2 + p_x^1 + SN_2' \\ \parallel \text{Ève donna une pomme à Adam}$$

On voit que, à la condition d'indiquer l'absence de complément et de préposition en (1) — soit ϕ —, et de poser un signe — soit $*$ — représentant la place vide de la préposition entre le verbe et le complément d'objet direct en (2), on obtient des patterns homogènes pour les diverses formes (1), (2), (3) et (4) :

$$\begin{aligned} (1) & SN_1 + V + \phi + \phi \\ (2) & SN_1 + V + * + SN_2 \\ (3) & SN_1 + V + p_x^1 + SN_2' \\ (4) & SN_1 + V + p_x^2 + SN_3 \quad (\text{voir note } (2)) \end{aligned}$$

(1) L'existence du complément circonstanciel direct sera traitée comme un cas particulier, soit $SN_1 + V + p_x^0 + SN_3$.

(2) Il existe une autre solution pour l'enregistrement du complément circonstanciel à savoir la combinaison des deux formes suivantes :

$$SN_1 + V + \phi + \phi, \quad SN_1 + \epsilon + p_x^2 + SN_3$$

(cf. p. 49 définition de ϵ).

Soit enfin le cas de (5) : posons un opérateur α tel que
 $(SN_1 + SV + SN_2 + p_1 + SN'_2) \rightarrow (SN_1 + SV + * + SN_2)$
 $(\alpha)(SN_1 + SV + p_1 + SN'_2)$

A la condition de convenir d'une équivalence stricte entre ces deux écritures, on voit que (5) peut entrer dans la catégorie (1) ... (4) précédente, définie par le pattern à 4 places suivant :

groupe sujet + groupe verbe + préposition + groupe complément

Remarquons que, cette fois, le principe de combinaison / substitution fonctionne puisque nous sommes au niveau de constitution de l'énoncé à partir des groupes de lexèmes. Nous utiliserons plus loin ⁽¹⁾ les résultats de ce qui précède.

Considérons les symboles SN_1 et SN_2 : ils représentent des syntagmes nominaux dont le niveau de complexité n'est pas fixé : par exemple, à la place de

|| La marchande vend des bonbons.

on peut avoir

|| La marchande du petit magasin vend des bonbons à l'anis.

avec

SN_1 = la marchande du petit magasin

SN_2 = des bonbons à l'anis

De même

|| Le voyageur distrait est parti avec la valise du monsieur qui était en face de lui dans le compartiment.

à la place de

|| Le voyageur est parti avec la valise.

avec

SN_1 = le voyageur distrait

SN_2 = la valise du monsieur qui était en face de lui (en face du voyageur) dans le compartiment.

⁽¹⁾ Cf. p. 69.

Les grammaires génératives utilisent généralement 3 types de règles de ré-écriture pour rendre compte du mécanisme de l'adjonction au syntagme minimal sujet ou objet, à savoir :

$N \rightarrow N + \text{Adj.}$ adjonction de l'adjectif
 $N \rightarrow N + \text{GRPP}$ adjonction du complément de nom
 $N \rightarrow N + \text{Prop/Rel}$ adjonction de la proposition relative.

Nous nous fonderons ici sur les travaux de Harris (1963) montrant qu'il est possible de restituer l'énoncé latent constitué par l'adjectivation au moyen de la transformation

$N + \text{Adj} \rightarrow N + \text{« is »} + \text{Adj.}$

Nous noterons ϵ la copule qui prend la place du verbe *être* dans cet énoncé latent, et traiterons l'adjectif attribut de N comme le complément d'objet direct du verbe *être*. D'où

$SN_x + \text{Adj.} \rightarrow SN_x + (SN_1 + \epsilon + * + \text{Adj})$

avec

$SN_x = SN_1$ ou SN_2 ou SN'_2 ou SN_3

et

$SN_x \rightarrow SN_1.$

De la même façon

$SN_x + \text{GRPP} \rightarrow SN_x + (SN_1 + \epsilon + p_i + SN_{2/3})$

avec

$SN_x \rightarrow SN_1,$

et enfin

$SN_x + \text{Prop/Rel} \rightarrow SN_x + (SN_1 + V + p_i + SN_{2/3})$

avec

$SN_x \rightarrow SN_1$ ou $SN_x \rightarrow SN_{2/3}.$

Les adjonctions sont ainsi transformées en propositions dont le sujet (éventuellement le complément pour la proposition relative) reprend le terme (sujet ou complément) de la proposition que l'adjonction détermine ⁽¹⁾.

⁽¹⁾ Nous appellerons T_2 l'ensemble de ces transformations.

On définira désormais l'énoncé comme une proposition pour laquelle aucune des trois opérations mentionnées ci-dessus ne peut plus être effectuée.

On conviendra de noter par un opérateur de dépendance δ la détermination de l'énoncé déterminé (ou énoncé central) par l'énoncé déterminant.

Soit

$$E_n \xrightarrow{\delta_1} E_n'$$

exprimant le fait que le sujet de l'énoncé E_n est déterminé par l'énoncé E_n' .

De même, soit

$$E_n \xrightarrow{\delta_2} E_n''$$

exprimant le fait que le complément de l'énoncé E_n est déterminé par l'énoncé E_n'' .

On aboutit ainsi à l'enregistrement suivant :

Exemple :

|| S = La marchande du petit magasin vend des bonbons à l'anis.

E_1 = la marchande + vend + * + des bonbons

E_2 = la marchande + ϵ + de + le magasin

E_3 = le magasin + ϵ + * + petit

E_4 = les bonbons + ϵ + à + l'anis.

D'où

$$S = ((E_1 \delta_1 (E_2 \delta_2 E_3)) \delta_2 E_4).$$

On sait d'autre part que les règles de ré-écriture de l'adjonction sont récursives, c'est-à-dire que l'on a :

$$N \rightarrow N + \text{Adj}_1.$$

$$N \rightarrow (N + \text{Adj}_1) + \text{Adj}_2.$$

$$N \rightarrow ((N + \text{Adj}_1) + \text{Adj}_2) + \text{Adj}_3.$$

etc.

et de même pour le groupe complément et la relative.

La récursion permet de représenter par un nombre fini de règles le processus de génération d'une séquence d'adjonctions de longueur potentiellement infinie, c'est-à-dire aussi grande que l'on voudra; transposée dans la problématique de l'enregistrement, la question devenait : comment enregistrer en un nombre fini de places dans le pattern de l'énoncé des syntagmes

de longueur potentiellement infinie, c'est-à-dire aussi grande que l'on voudra.

La solution apportée est comparable à celle qu'utilisent les grammaires génératives : de même que, dans une grammaire générative, on se donne le droit de ré-itérer une règle autant de fois qu'il le faut, de même ici on s'autorise à écrire autant de lignes d'enregistrement qu'il le faut, en reliant ensuite les lignes (les énoncés) entre eux, selon leur système de dépendance.

5. L'ENREGISTREMENT DES DÉPENDANCES FONCTIONNELLES

Les détails de la structure de l'énoncé seront exposés plus loin ⁽¹⁾, ainsi que certains problèmes particuliers à son enregistrement : nous traiterons auparavant de la représentation formelle du système de dépendances entre les énoncés du discours $\mathcal{D}_x$ donné, en explicitant successivement les différents niveaux de contrainte qui régissent ce système.

a) La concaténation comme structure élémentaire

Soit l'exemple suivant :

|| S_1 = Le voyageur arriva comme le chef de gare sifflait pour avertir le mécanicien que la voie était libre.

Posons

E_1 = le voyageur arriva

E_2 = le chef de gare sifflait

E_3 = le chef de gare avertisse le mécanicien

E_4 = la voie est libre

φ_1 = comme, au moment où

φ_2 = pour que, afin que

φ_3 = que (déclaratif)

On voit qu'on peut écrire S_1 sous la forme

$$S_1 = E_1 \xrightarrow{\varphi_1} E_2 \xrightarrow{\varphi_2} E_3 \xrightarrow{\varphi_3} E_4$$

c'est-à-dire


$$E_1 \xrightarrow{\varphi_1} E_2; \quad E_2 \xrightarrow{\varphi_2} E_3; \quad E_3 \xrightarrow{\varphi_3} E_4$$

Par définition, on posera une représentation parenthétique équivalente, soit


$$S_1 = (E_1 \varphi_1 (E_2 \varphi_2 (E_3 \varphi_3 E_4)))$$

⁽¹⁾ Cf. p. 69.


Remarquons qu'il est possible de représenter S_1 par un schéma, en considérant la forme ci-dessous comme une expression écrite selon les règles de la logique combinatoire, soit



Notons d'autre part qu'il suffit d'appliquer à ce schéma la règle « déplacer chaque pointe de flèche vers l'origine de la flèche suivante (1) » pour reproduire la forme en chaîne initiale, soit



Enfin, on voit que S_1 peut encore être représentée sous la forme d'une « pile » constituée par la suite des relations binaires posées au début, telle que l'extrémité de la relation de niveau n dans la pile soit l'origine de la relation de niveau $n + 1$, la pile étant orientée vers le bas, soit



Il apparaît ainsi que la structure de concaténation est caractérisée par le fait que tout énoncé domine directement un énoncé et un seul, et qu'il est dominé directement par un énoncé et un seul : les énoncés ne sont écrits qu'une fois dans chaque colonne.

(1) On peut représenter ainsi cette transformation :

$$(\overrightarrow{\uparrow}) \xrightarrow{\text{if}} (\uparrow\overrightarrow{})$$

b) L'expansion

Considérons maintenant l'exemple suivant :

S_2 = Lorsqu'il découvrit des traces de pas sur l'île, le naufragé pensa qu'elles étaient récentes puisque ni le vent du large, ni la marée montante ne les avaient encore effacées.

Posons

E_5 = le naufragé découvrit des traces

E_6 = traces « de pas

E_7 = traces « sur l'île

E_8 = le naufragé pensa

E_9 = les traces étaient récentes

E_{10} = le vent n'a pas encore effacé les traces

E_{11} = le vent « du large

E_{12} = la marée n'a pas encore effacé les traces

E_{13} = la marée « montante

et φ_5 = lorsque


φ_3 = que (déclaratif)

φ_7 = puisque

φ_8 = et

On voit qu'il est impossible de représenter S_2 sous la forme d'une chaîne puisque, par exemple, E_8 domine directement E_5 et E_9 .

D'où l'arbre suivant représentant la séquence S_2 :



Représentation parenthétique

Utilisons la définition de la concaténation; nous obtenons :

- 1) $E_8 \xrightarrow{\varphi_5} E_5$; $E_5 \xrightarrow{\delta_2} E_6$; $E_6 \xrightarrow{\delta_1} E_7$
soit $(E_8 \varphi_5 (E_5 \delta_2 (E_6 \delta_1 E_7)))$
- 2) $E_8 \xrightarrow{\varphi_3} E_9$; $E_9 \xrightarrow{\varphi_7} E_{10}$; $E_{10} \xrightarrow{\varphi_8} E_{12}$; $E_{12} \xrightarrow{\delta_1} E_{13}$
soit $(E_8 \varphi_3 (E_9 \varphi_7 (E_{10} \varphi_8 (E_{12} \delta_1 E_{13}))))$
- 3) $E_{10} \xrightarrow{\delta_1} E_{11}$
soit $(E_{10} \delta_1 E_{11})$


Représentons chaque concaténation par son énoncé dominant (l'énoncé le plus à gauche), soit

$$\begin{aligned} E_8 &\rightarrow (E_8 \varphi_5 (E_5 \delta_2 (E_6 \delta_1 E_7))) \\ E_8 &\rightarrow (E_8 \varphi_3 (E_9 \varphi_7 (E_{10} \varphi_8 (E_{12} \delta_1 E_{13})))) \\ E_{10} &\rightarrow (E_{10} \delta_1 E_{11}) \end{aligned}$$

et remplaçons dans l'une des concaténations chaque énoncé par la concaténation qui lui correspond, soit

$$\begin{aligned} S_2 &= (E_8 \varphi_3 (E_9 \varphi_7 ((E_{10} \delta_1 E_{11}) \varphi_8 (E_{12} \delta_1 E_{13})))) \\ &\quad \varphi_5 (E_5 \delta_2 (E_6 \delta_1 E_7)) \end{aligned}$$

Il résulte de ce qui précède que le schéma représentant S_2 selon les règles de la logique combinatoire est de la forme




Alors que dans le schéma de la concaténation les flèches aboutissent toujours à des flèches, ce que nous avons transformé par

$$(\uparrow) \xrightarrow{fa} (\uparrow)$$

certaines flèches sont maintenant issues d'une flèche, et dans ce cas nous appliquerons une deuxième transformation, soit

$$(\uparrow) \xrightarrow{fb} (\uparrow)$$

On voit que, par le jeu de ces deux transformations, on reproduit l'arbre initial



La représentation en « pile » de S_2 , dont nous verrons dans un instant qu'elle peut être obtenue à partir de la forme parenthétique au moyen d'un algorithme, est de la forme

E_8	φ_5	E_5
E_5	δ_2	E_6
E_6	δ_1	E_7
E_8	φ_3	E_9
E_9	φ_7	E_{10}
E_{10}	δ_1	E_{11}
E_{10}	φ_8	E_{12}
E_{12}	δ_1	E_{13}

Remarquons que tous les énoncés de S_2 apparaissent dans la colonne de droite — sauf, évidemment, le premier énoncé E_8 — et qu'ils n'apparaissent qu'une fois. D'autre part, certains énoncés sont absents dans la colonne de gauche, alors que d'autres y figurent plusieurs fois. Enfin, on voit qu'un énoncé ne peut apparaître à gauche que s'il est déjà apparu à droite, selon le sens d'enregistrement de la pile (du haut vers le bas).

En d'autres termes, un énoncé peut dominer directement plusieurs énoncés, et un énoncé peut ne dominer aucun énoncé. On appellera *expansion* le fait qu'un énoncé domine directement deux énoncés ou plus.

Par exemple


$$\begin{bmatrix} E_a & \varphi_x & E_b \\ E_a & \varphi_y & E_c \\ E_a & \varphi_z & E_d \end{bmatrix}$$

représente l'expansion de E_a , que l'on notera

$$(((E_a \varphi_x E_b) \varphi_y E_c) \varphi_z E_d)$$

en notation parenthétique.

Une surface discursive est donc en général constituée par un *complexe de concaténations et d'expansions* ; marquons-le dans S_2 par des liaisons obliques (concaténations) et des relations verticales (expansions) :



Une structure comme celle que nous venons d'examiner, ne comportant que des concaténations et des expansions, est telle qu'elle admet, on l'a vu, trois représentations : en *arbre*, en *expression parenthétique* ou en *pile*.

Nous donnons ci-dessous la description d'un automate effectuant la passage univoque de la représentation parenthétique à la représentation en pile ⁽¹⁾ :

Soit l'expression parenthétique écrite sous la forme

$$\langle c \varphi_1 ((b \varphi_2 d) \varphi_3 a) \rangle$$

On a remplacé les parenthèses extérieures par des guillemets d'ouverture et de fermeture.

Soit une mémoire comportant n cases dénommées m_i de gauche à droite, avec i allant de 1 à n ; on se donne toujours la possibilité de rajouter une $n+1$ ième case à droite, si besoin est.

On désignera par a_i les énoncés de l'expression.

Soit la notation suivante :

- « $m_i = \square$ » signifie « la case m_i est vide ».
- « $m_i = a_j$ » signifie « la case m_i est dans l'état a_j »
- « $m_i \mapsto a_j$ » signifie « la case m_i prend l'état a_j »
- « $\neq$ » signifie « imprimer un blanc sur le ruban de sortie »
- « $\odot$ » signifie « lire le signe suivant ».

On convient de désigner par p l'indice de la mémoire le plus à gauche non-vide :

$$p = (\min | m_j = a_k).$$

⁽¹⁾ Nous remercions ici M. Jastrabski, qui a rédigé le plan de cet automate.

Le tableau qui suit donne les règles de transcodage qui sont posées.

Lecture	Opérations internes (test et mémoire)	Impression
"	$m_1 \mapsto "$ $i \neq 1, m_i \mapsto \square$	
a_i	si $(p = 1)$ et $(m_1 = ")$ alors $m_1 \mapsto a_i$ et $\odot$ si $(p = 1)$ et $(m_1 = a_j)$ alors $\odot$ si $(p \neq 1)$ alors $(m_{p-1} \mapsto a_i)$ et $\odot$	" a_i a_i
φ_k		$\# m_p \varphi_k$
(	$\forall i, (m_i \mapsto m_{i+1})$ et $\odot$	
)	$\forall i, (m_i \mapsto m_{i-1})$ et $\odot$	
"	$\forall i, (m_i \mapsto m_{i-1})$ si $\exists i \neq 0$ tel que $m_i = a_i$ sinon	ERREUR "

Exemple : « c φ_1 ((b φ_2 d) φ_3 a) ».

Lecture	Etat des mémoires					Impression
«	«	☐	☐	☐		
c	c	☐	☐	☐		«
φ_1	c	☐	☐	☐		$\# c \varphi_1$
(	☐	c	☐	☐		
(	☐	☐	c	☐		
b	☐	b	c	☐		b
φ_2	☐	b	c	☐		$\# b \varphi_2$
d	d	b	c	☐		d
)	b	c	☐	☐		
φ_3	b	c	☐	☐		$\# b \varphi_3$
a	b	c	☐	☐		a
)	c	☐	☐	☐		
»	☐	☐	☐	☐		

« $\# c \varphi_1 b \# b \varphi_2 d \# b \varphi_3 a$ »


c) Le principe de saturation

Soit un complexe de concaténations et d'expansions de type S_2 .

Appelons

- AR la représentation en arbre,
 CB la représentation en schéma « combinatoire »,
 PR la représentation parenthétique,
 RB la représentation au moyen de relations binaires.

Nous avons montré jusqu'ici que les transformations suivantes étaient univoques :



Autrement dit, étant donné par exemple une expression sous forme *parenthétique*, il lui correspond un *ensemble ordonné de relations binaires*, appelé « pile ». Dans les cas de la concaténation pure (séquence de type S_1), cet ordre est évidemment redondant par rapport à l'information contenue dans les *relations binaires* elles-mêmes : on peut donc « casser la pile » et stocker ses éléments selon un autre ordre exigé, on le verra ⁽¹⁾, par le dispositif d'analyse; on pourra toujours reconstruire PR à partir du stock de RB.

Nous allons montrer que dans les cas du complexe (concaténations + expansions), au contraire, le stock de RB ne suffit plus pour reconstruire PR de façon univoque : à un même ensemble de relations binaires peuvent correspondre des formes parenthétiques différentes.

Considérons en effet les deux séquences suivantes de type S_2 :

$$S_2^1 = (((a \varphi_1 b) \varphi_2 (c \varphi_3 d)) \varphi_4 e),$$

$$S_2^2 = (((a \varphi_1 b) \varphi_4 e) \varphi_2 (c \varphi_3 d)).$$

Leur transformation en pile ⁽²⁾ fournit respectivement


pour S_2^1	$a \varphi_1 b$	pour S_2^2	$a \varphi_1 b$
	$a \varphi_2 c$		$a \varphi_4 e$
	$c \varphi_3 d$		$a \varphi_2 c$
	$a \varphi_4 e$		$c \varphi_3 d$

⁽¹⁾ Cf. p. 86.


⁽²⁾ Obtenue par l'algorithme ci-dessus, p. 59.

On voit que les piles S_2^1 et S_2^2 contiennent les mêmes éléments ; il faut donc conserver l'ordre de la pile pour reconstituer leurs formes parenthétiques respectives.

De même, alors qu'il serait facile de démontrer que la correspondance entre PR et CB est bi-univoque, on constate que la transformation $\text{CB} \rightarrow \text{AR}$ détermine la même perte d'information sur l'ordre, puisque l'arbre suivant représente également S_2^1 et S_2^2 .




Il faut donc définir un ordre sur les expansions de l'énoncé a pour que la reconstitution de PR soit univoque à partir de RB ou de CB, d'où les groupes suivants, d'un type nouveau que nous appellerons S_3 , où φ_α représente une relation d'ordre entre les énoncés dominés directement par a :




Il résulte de ce qui précède que les stocks d'éléments appartenant aux deux piles représentant respectivement S_3^1 et S_3^2 ne sont pas identiques :

pour S_3^1	$a \varphi_1 b$	pour S_3^2	$a \varphi_1 b$
	$b \varphi_\alpha c$		$b \varphi_\alpha e$
	$a \varphi_2 c$		$a \varphi_4 e$
	$c \varphi_3 d$		$e \varphi_\alpha c$
	$c \varphi_\alpha e$		$a \varphi_2 c$
	$a \varphi_4 e$		$c \varphi_3 d$

On dira que la nouvelle relation de dépendance (φ_3) introduite dans une expansion de la forme



sature cette expansion



On voit que les relations de saturation transforment l'arbre de type S_2 en un réseau (structure de type S_3).

Considérons par exemple la séquence S_3^3 .

S_3^3 = Le roi entra. Le ministre le suivait. Les courtisans s'approchèrent du roi. Celui-ci les considéra longuement.

On a

E_{14} = le roi entra


E_{15} = le ministre suivait le roi

E_{16} = les courtisans s'approchèrent du roi

E_{17} = le roi considéra longuement les courtisans

et $\varphi_1 = (.)$


d'où



E_{14}	φ_1	E_{15}
E_{15}	φ_2	E_{16}
E_{14}	φ_1	E_{16}
E_{16}	φ_3	E_{17}
E_{14}	φ_1	E_{17}

Nous formons l'hypothèse qu'il est toujours au moins possible de poser une relation d'ordre entre les extrémités de deux relations binaires ayant même origine, ce qui n'exclut pas qu'une investigation linguistique ne puisse définir des relations de saturation munies d'un contenu spécifique en fonction des indices de la surface : il est même fort probable que la combinaison des divers critères de dépendance évoqués plus haut ⁽¹⁾ induit par elle-même des effets de saturation, la relation d'ordre (φ_3) n'étant que l'effet minimal, enregistré en l'absence de tout autre indice.

Si l'on reprend en effet la séquence S_2 ⁽²⁾, en considérant la partie suivante :



Avec E_9 = les traces étaient récentes


E_{10} = le vent n'a pas encore effacé les traces

E_{12} = la marée n'a pas encore effacé les traces

et φ_7 = puisque

φ_8 = et

il apparaît qu'on peut introduire une saturation de la forme



en raison de la distributivité de « puisque » par rapport à « et », ce dernier opérateur étant symétrique : $(\varphi_8)^{-1} = \varphi_8$, ce qui autorise à enregistrer

E_{10}	φ_8	E_{12}
et		
E_{12}	φ_8	E_{10}

⁽¹⁾ Cf. p. 45.

⁽²⁾ Cf. p. 53.

La relation de saturation doit donc intervenir sur les expansions, au moins sous la forme d'une relation d'ordre; elle peut par ailleurs intervenir sur des concaténations, en particulier dans le cas des opérateurs symétriques.

Si l'on résume les conséquences de ce qui précède, on dira qu'une structure discursive S_3 , comportant concaténation, expansion et saturation est caractérisée par les propriétés suivantes :

- 1) Un énoncé peut dominer directement plusieurs énoncés (règle d'expansion, entraînant la répétition à gauche).
- 2) Un énoncé peut être directement dominé par plusieurs énoncés (règle de saturation, entraînant une répétition à droite).
- 3) Un énoncé ne peut apparaître à gauche d'une relation binaire que s'il est apparu à droite dans une relation binaire antérieure en fonction de l'orientation de la pile.


Notons que S_3 ne peut pas être représenté en notation parenthétique, que le schéma « combinatoire » est tel que plusieurs points du schéma portent le même nom (ce qui est acceptable du point de vue de la logique combinatoire), enfin que le graphe représentatif de S_3 est un réseau et non un arbre.

d) Les structures à plusieurs sources

Les objets précédemment étudiés, à savoir S_1 , S_2 et S_3 ont en commun une propriété qu'on peut énoncer ainsi :

Pour tout énoncé E_i d'un discours donné, exclusion faite de l'énoncé initial, E_i ne peut apparaître à gauche dans la pile que s'il est déjà apparu à droite.

Un graphe du type ci-dessous se trouve donc jusqu'à présent exclu :



a est ici soit l'énoncé initial (source) du discours, soit un énoncé placé sur la chaîne issue de l'énoncé initial. La relation $e \rightarrow c$ viole en effet la règle énoncée à l'instant : il semble cependant que cette éventualité puisse se rencontrer au moins à titre de cas marginal.

Soit en effet l'exemple suivant :

S_4 = Joseph est un cancre; quand il saura le latin, les poules auront des dents.

Posons

E_1 = Joseph est un cancre


E_2 = Joseph saura le latin

E_3 = Les poules auront des dents


φ_1 = (;

φ_2 = quand

Supposons qu'il s'avère, à la suite de travaux linguistiques ultérieurs sur le système de dépendances ⁽¹⁾ qui si deux phrases sont liées l'une à l'autre, cela implique nécessairement que leurs principales sont en rapport de dépendance, nous écrirons :



Supposons, au contraire, que le critère syntaxique que nous venons d'évoquer soit parfois en conflit avec un autre, par exemple, ici, le critère d'anaphore (« il », sujet de E_2 , représente « Joseph », sujet de E_1) et que ce dernier l'emporte dans le cas présent, en fonction de règles de décision qu'il appartient au linguiste d'établir, on a alors :




Soulignons que ce que nous venons de dire à propos du couple principale/subordonnée est également valable à propos du couple énoncé central/adjonction.


D'autre part, il est vraisemblable, compte tenu de ce qui a été exposé à propos de S_3 , que les cas de conflits analogues à celui que nous venons de

⁽¹⁾ Cf. p. 45.

présenter pourront être résolus par l'application du *principe de saturation*, de sorte qu'une forme S_4 pourrait être ramenée à la forme S_3 :



devenant



Nous supposons que cette opération peut être effectuée systématiquement.

La liste ci-dessous résume sous forme de postulats l'ensemble de nos hypothèses concernant le système de dépendances d'un discours ⁽¹⁾.

— 1 —

On appelle *discours* une séquence linguistique limitée par deux *blancs sémantiques*, et correspondant à des conditions de production discursives définies.

— 2 —

On appelle *phrases* la partie d'un discours limitée par deux *marques d'arrêt consécutives* — ou par un *blanc* et une *marque d'arrêt*, dans le cas de la première phrase.

— 3 —

On appelle *proposition* la partie d'une phrase qui ne comporte qu'un verbe à un mode personnel.

⁽¹⁾ Cf. p. 86.

— 4 —

On appelle *proposition réduite* une proposition qui ne peut pas être dissociée en deux ou plusieurs *propositions* par une transformation de type T_1 ⁽¹⁾.

— 5 —

On appelle *énoncé* une proposition telle qu'on ne puisse plus obtenir à partir d'elle d'énoncés qui lui soient adjoints, par l'une des transformations du type T_2 ⁽²⁾.

— 6 —

Tout énoncé peut être enregistré sous la forme d'un *ensemble ordonné, de dimension fixe*, dont les éléments sont des signes linguistiques appartenant à des classes morpho-syntaxiques définies ⁽³⁾.

— 7 —

Il existe un énoncé vide E_ϕ , représentant le blanc sémantique, tel que

$$E_\phi \xrightarrow{\varphi_0} E_1$$

E_1 étant l'énoncé initial du discours et $\xrightarrow{\varphi_0}$ étant l'opérateur d'ouverture du discours.

— 8 —

Étant donné un énoncé quelconque E_j , différent de E_ϕ , il existe au moins un énoncé E_i tel que

$$E_i \xrightarrow{\varphi_n} E_j$$

$E_i \xrightarrow{\varphi_n} E_j$ est une relation binaire dans laquelle E_j est directement dominé par E_i , au moyen de l'opérateur $\xrightarrow{\varphi_n}$. Inversement, un énoncé quelconque E_j peut dominer m énoncés, avec $m \geq 0$.

⁽¹⁾ Cf. p. 44.

⁽²⁾ Cf. p. 49.

⁽³⁾ Cf. p. 69.

— 9 —

La relation de dépendance ψ_n entre deux énoncés E_i et E_j peut marquer :

- l'adjonction de E_j à E_i , soit

$$E_i \xrightarrow{\delta_1} E_j$$

ou

$$E_i \xrightarrow{\delta_2} E_j$$

- la coordination ou la subordination, indiquée

— soit par la *marque d'arrêt*, avec ou sans *syntagme qualifiant* la marque, avec ou sans *effet d'anaphore* ;

— soit par un *terme* ou *syntagme subordonnant*.

On convient d'écrire alors la relation sous la forme

$$E_i \xrightarrow{\psi_n} E_j.$$

Remarque : L'enregistrement de la relation de dépendance se fonde sur des indices présents dans la surface discursive, à différents niveaux (discours, phrase et proposition) : une classification fonctionnelle de ces indices doit permettre ultérieurement l'automatisation de l'enregistrement de la dépendance.

— 10 —

La structure d'un discours peut être représentée par une « pile » de relations binaires de la forme

$$E_i \xrightarrow{\psi_m} E_j$$

avec

$$\psi = \{\delta_1, \delta_2, \varphi_1 \dots \varphi_n\}.$$

Il est toujours possible de donner à l'enregistrement la forme S_3 (comportant des concaténations, des expansions et des saturations).

— 11 —

L'ensemble non-ordonné des éléments (relations binaires) d'une pile de type S_3 (soit $\mathcal{B}$ cet ensemble) contient suffisamment d'information pour reconstituer la pile initiale, de sorte que l'on peut considérer l'ensemble $\mathcal{B}$ comme représentatif de la structure du discours enregistré.

— 12 —

Toute structure S_3 peut être transcrite par une *superposition* de structures S_1 , c'est-à-dire de concaténations pures.

B) L'enregistrement de la structure de l'énoncé

Nous avons jusqu'à maintenant traité de l'enregistrement des *dépendances fonctionnelles* propres à une structure discursive donnée, en montrant qu'on pouvait les représenter par un ensemble de relations binaires de la forme $E_i \psi_n E_j$, où ψ_n est un opérateur de dépendance (δ_1 ou δ_2 , φ_1 , ..., φ_n), E_i et E_j des énoncés ayant un contenu défini : il reste désormais à préciser les modalités d'enregistrement de ce contenu.

La structure élémentaire de l'énoncé a déjà été exposée ⁽¹⁾, soit

$$SN_1 + SV + \begin{bmatrix} \phi + \phi \\ * + SN_2 \\ p_1 + SN'_2 \\ p_2 + SN_3 \end{bmatrix}$$

Précisons ce schéma : dans un « Essai de classification des catégories verbales » ⁽²⁾, Jakobson écrit : « En vue de classer les catégories verbales, nous devons observer deux distinctions de base :

1. Il faut distinguer entre l'énonciation elle-même (a), et son objet, la matière énoncée (e).

2. Il faut distinguer ensuite entre l'acte ou le *procès* lui-même (C) et l'un quelconque de ses *protagonistes* (T) « agent » ou « patient ». En conséquence, quatre rubriques doivent être distinguées :

- un événement raconté (narrated event) ou *procès de l'énoncé* (C^e),
- un acte de discours ou *procès de l'énonciation* (C^a),
- un protagoniste du procès de l'énoncé (T^e),
- un protagoniste du procès de l'énonciation (T^a), destinataire ou destinataire.

⁽¹⁾ Cf. p. 47.

⁽²⁾ Jakobson, *op. cit.*, p. 154.

Les protagonistes du *procès de l'énonciation* correspondent à A et B dans la structure des conditions de production P_x (1), et sont, en tant que tels, hors du présent schéma, encore qu'ils puissent s'y trouver représentés (ceci est important à l'égard des questions d'aspect et de modalité) : de toute manière, les conditions de l'énonciation sont, comme on le sait, supposées fixes.

Le protagoniste « agent » de l'énoncé est représenté dans le schéma par SN_1 ou *syntagme nominal sujet*. Nous poserons que SN_1 est un constituant indispensable de tout énoncé — le cas des énoncés « météorologiques » (on cite toujours « il pleut », « il neige », etc.) est trop marginal pour mettre cette règle en question (2).

Le protagoniste « patient » de l'énoncé est représenté par SN_2 , SN'_2 , SN_3 et ϕ : en d'autres termes, le *syntagme nominal objet* peut prendre plusieurs formes, y compris celle de l'absence pure et simple. Nous poserons d'autre part que l'*adjectif comme attribut du sujet* peut s'enregistrer à la place de SN_2 , ce qui implique cette conséquence que si toute forme susceptible d'être inscrite à la place SN_1 peut aussi l'être à la place de SN_2 , SN'_2 , SN_3 , l'inverse n'est pas vrai.

SV représente enfin le « *procès de l'énoncé* » dont nous poserons qu'il peut toujours être rétabli lorsqu'il ne sera pas explicitement présent : en particulier, l'apposition sera systématiquement transformée en prédication et enregistrée comme telle :

|| Waterloo, morne plaine
→ || Waterloo + ϵ + * + plaine
|| plaine + ϵ + * + morne

Il va sans dire que nous ne prétendons pas poser comme des « universaux » linguistiques ces divers constituants : notre seul but est ici de montrer la possibilité d'enregistrement du français.

Il résulte de ce qui précède que nous emploierons le terme de « *syntagme nominal* » pour désigner spécifiquement SN_1 , SN_2 , SN'_2 et SN_3 , et que le terme SV « *syntagme verbal* » ne désigne pas le *prédicat* de SN_1 mais seulement ce qui, dans le prédicat, est extérieur au syntagme nominal objet et à son éventuelle préposition introductrice (3).

(1) Cf. p. 21.

(2) Nous poserons dans ce cas l'existence d'un contenu impersonnel de SN_1 : « ça » = « il » impersonnel.

(3) Nous ferons ici grand usage des distinctions et mises au point relevant de la méthodologie linguistique, que M. Culicoli a eu l'amabilité de nous communiquer, spécialement sur les questions du *mode de détermination du SN , des marques attachées au syntagme verbal et de la lexis*.

I. LE SYNTAGME NOMINAL

Le syntagme nominal *sujet* comporte nécessairement un nom (« commun » ou « propre »), ou un terme le représentant. Dans les cas où le syntagme nominal objet est du type SN_2 , le nom peut par ailleurs être remplacé par un adjectif attribut du SN_1 correspondant.

Le *terme tenant lieu de nom* se rapporte à lui par un phénomène d'anaphore qui peut être *externe* :

|| Je déclare la séance ouverte

(le producteur de l'énoncé, c'est-à-dire le protagoniste agent de l'énonciation, est le président de séance, Je = le président X),

ou *interne*

|| L'express entre en gare. { Il
Celui-ci } (= l'express) était à l'heure.

On voit ainsi que les pronoms et autres « *tenant lieu* » renvoient, selon le cas, à l'énonciation ou à un énoncé antérieur, l'énonciation de celui-ci servant de caution pour l'introduction dans un énoncé ultérieur, de ces « *signes vides* », non référentiels par rapport à la « *réalité* », toujours disponibles, et qui deviennent « *pleins* » dès qu'un locuteur les assume dans chaque instance de son discours. Dépourvus de références matérielles, ils ne peuvent pas être mal employés ; n'assertant rien, ils ne sont pas soumis à la condition de vérité et échappent à toute dénégation. Leur rôle est de fournir l'instrument d'une conversion, qu'on peut appeler la conversion du langage au discours » (Benveniste, *op. cit.*, p. 254).

D'autre part, le nom est généralement accompagné d'une *marque de détermination* — absente dans le cas du nom propre et de la plupart des anaphores.

Nous appellerons D_1 et D_2 ces marques, selon que leur association avec le nom forme le *syntagme sujet* ou le *syntagme objet*, soit :

$$SN_1 \rightarrow D_1 + N_1$$

$$SN_2 \rightarrow D_2 + N_2$$

$$SN'_2 \rightarrow D_2 + N'_2$$

$$SN_3 \rightarrow D_2 + N_3$$

On peut, par ailleurs, décomposer la marque *D* en un faisceau de dimensions, à savoir :

- a) le nombre (singulier/pluriel);
- b) le mode de détermination de *N*, selon que
 - la classe *N* est visée
 - || Le chien est un animal fidèle
 - un élément particulier de la classe *N* est pointé par la marque *D* qui joue alors le rôle de flèche désignatrice.
 - || Ce chien est méchant.
 - || Ton chien est malade
 - un élément particulier est extrait de la « classe » *N* sans autre indication
 - || Un chien se mit à aboyer.
 - la « classe » *N* est balayée par *D*
 - || Aucun chien n'a quitté le chenil aujourd'hui
 - || Tous les chiens doivent porter un collier
 - la « classe » *N* est considérée comme l'indice d'un concept
 - || Pendant dix ans il mena une vie de chien.

Remarquons sur ce point que l'analyse formelle du morphème représentant *D* n'est pas toujours suffisante pour identifier le mode de détermination (par exemple « un chien est toujours fidèle » ≠ « un chien se mit à aboyer ») et qu'il faut tenir compte des marques attribuées antérieurement au même *N* selon l'ordre de surface pour déduire le mode de détermination que représente tel morphème (« le », « un », etc.) en un point donné de la surface : cela suppose que le linguiste puisse établir le système de règles permettant (idéalement) d'aboutir, dans chaque cas, à une solution unique.

Il est à noter également que la place de la marque *D* peut être vide, par exemple dans le cas du nom propre ou de l'adjectif. On conviendra d'autre part que cette place est toujours vide dans le cas de la reprise du nom dans une adjonction.

Exemple :

|| La loge de la concierge donne sur la cour
s'enregistrera

$E_1 = (la + loge) + donne + sur + (la + cour)$

$E_2 = (\phi + loge) + \epsilon + de + (la + concierge)$

avec

$E_1, \delta_1, E_2.$

c) Enfin le genre (opposition le/la) est le plus souvent redondant par rapport au lexème nominal. Cependant il y a parfois lieu de tenir compte de cette dimension. Par exemple :

le concierge/la concierge

2. LE SYNTAGME VERBAL

Le syntagme verbal peut être considéré comme le lexème verbal plus une série de déterminations combinées entre elles.

Soit par exemple la phrase

|| N'aurait-il pas été délibérément empoisonné?

On a

empoisonner : lexème verbal

délibérément : modulation adverbiale du lexème

aurait-il : interrogation indiquée par un morphème d'ordre (inversion)

été -é : marque du passé passif

aurait : marque de la supposition

n' ... pas : marque de la négation.

a) L'adverbe est un élément relativement libre par rapport au reste du syntagme : d'une part la place de l'adverbe peut rester vide; d'autre part, il peut se déplacer dans la surface au point qu'il peut, dans certain cas, contrôler la totalité de l'énoncé et le relier à un énoncé précédent : le problème est donc sur ce point de savoir si un adverbe donné fonctionne comme modulation du verbe (une sorte « d'adjectif » du verbe : « délibérément empoisonné » → « empoisonnement délibéré ») ou comme une qualification d'un opérateur de dépendance, du type $\overrightarrow{p_x} = [(.) + \text{adverbe}]$ par exemple, auquel cas l'adverbe marque l'ordre de dépendance entre deux procès d'énoncé, en spécifiant cet ordre comme « simultanéité, antériorité, interruption, connexion concessive, etc. »⁽¹⁾.

Soit par exemple la séquence :

|| Le cycliste roulait prudemment. Soudain, une voiture déboucha de la gauche et le renversa.

⁽¹⁾ R. Jakobson, art. cit. p. 183, à propos du concept d'ordre (« l'ordre caractérise le procès de l'énoncé par rapport à un autre procès de l'énoncé et sans référence au procès de l'énonciation »).

On voit que

prudemment — modulation adverbiale de *roulait*

soudain — qualification de la marque d'arrêt (.), de sorte que l'opérateur entre les deux phrases est $\varphi_x = [(.) + \text{soudain}]$

Les autres déterminations sont au contraire toutes plus ou moins intégrées à la forme du verbe :

b) La personne

« La personne », écrit R. Jakobson ⁽¹⁾ « caractérise les protagonistes du procès de l'énoncé par référence aux protagonistes du procès de l'énonciation. Ainsi la première personne signale l'identité d'un des protagonistes de l'énoncé avec l'agent du procès de l'énonciation, et la seconde personne son identité avec le patient actuel ou potentiel du procès de l'énonciation. »

On sait que, compte tenu des règles d'enregistrement du syntagme nominal, les protagonistes de l'énonciation sont enregistrés lorsque les protagonistes de l'énoncé les désignent ⁽²⁾ : la marque de la personne, intégrée à la forme du verbe, est ainsi toujours redondante par rapport à l'enregistrement du sujet de ce verbe : elle ne sera donc pas enregistrée.

c) Le statut

Le statut définit « la quantité logique du procès » ; on distinguera les statuts affirmatif, négatif, interrogatif et interro-négatif : notons qu'il est possible de représenter le statut par l'enregistrement combiné d'une valeur dans l'opposition *assertion/interrogation* et d'une modalisation de cette valeur (ne ... pas, ne ... jamais, peut-être, toujours, etc. ; ϕ représente ici l'assertion ou l'interrogation non modulée).

d) Le temps

« Le temps caractérise le procès de l'énoncé par référence au procès de l'énonciation. C'est ainsi que le prétérit nous informe que le procès de l'énoncé est antérieur au procès de l'énonciation. » ⁽³⁾

e) La voix

« La voix caractérise la relation qui lie le procès de l'énoncé à son protagoniste, sans référence au procès de l'énoncé ou au locuteur. » ⁽³⁾

f) Le mode

« Le mode caractérise la relation entre le procès de l'énoncé et ses protagonistes par référence aux protagonistes du procès de l'énonciation. » ⁽³⁾

⁽¹⁾ *Ibid.*, p. 182.

⁽²⁾ Cf. p. 71.

⁽³⁾ Jakobson, 1963, p. 183.

Les points d), e) et f) nécessitent de la part du linguiste une élaboration indiquant les différentes valeurs possibles de chaque marque et les combinaisons que la langue tolère.

Nous compléterons cette liste par les marques de la *modalité* et de l'*emphase*.

g) La modalité

On sait que la *logique modale* a introduit des signes spécifiques exprimant les modalités du *possible* et du *nécessaire* dans la proposition logique. Faisant usage d'une analogie, nous poserons que les propositions du type

|| Je peux venir demain.

|| Je dois écrire une lettre.

correspondent à

|| Je viens demain + *modalité du possible*.

|| J'écris une lettre + *modalité du nécessaire*.

Les termes de « possible » et de « nécessaire » renvoient, bien entendu, à des modalités linguistiques, et non pas logiques, de l'énoncé.

Remarquons que la transformation T_1 ⁽¹⁾ qui consiste à rétablir les propositions latentes dans une séquence, par exemple

|| Il lui dit de venir

→ || Il lui dit (que) il vienne.

ne s'applique pas ici. On notera que dans les cas de modalités du *possible* et du *nécessaire*, le sujet (sous-entendu) du verbe à l'infinitif est toujours le même que le sujet (exprimé) du verbe porteur de la modalité, ce qui différencie « pouvoir » et « devoir » de verbes du type « vouloir » qui autorisent la construction

| Je veux que tu...

et à propos desquels il est donc légitime d'appliquer T_1 , à savoir

|| Je veux partir

→ | Je veux (que) je parte.

h) L'emphase

Il existe enfin des tours stylistiques permettant de mettre en relief une partie de l'énoncé ou l'énoncé tout entier, en général à l'aide d'expressions du type « c'est le/un ... qui/que ».

⁽¹⁾ Cf. p. 44.

Nous poserons

α) un degré zéro de l'emphase

- || Jean mange des pommes
- || Un avion tombe.

β) une emphase sur le sujet

- || C'est Jean qui mange des pommes
- || C'est un avion qui tombe.

γ) une emphase sur l'objet

- || Ce sont des pommes que Jean mange

δ) une emphase sur l'énoncé global

- || C'est que Jean mange des pommes
- || C'est qu'un avion tombe

Nous n'avons proposé ici que l'esquisse du tableau des marques dont chaque combinaison assigne une *forme à l'énoncé* : indiquons simplement qu'on appellera « forme de l'énoncé » (notée F_i) le vecteur constitué par l'ensemble ordonné de valeurs que prend chaque marque pour l'énoncé considéré, soit

$$F_i = \langle v(\text{statut}) ; v(\text{temps}) ; v(\text{voix}) ; v(\text{mode}) ; \\ v(\text{modalité}) ; v(\text{emphase}) \rangle$$

Le mot ainsi formé est analytiquement décomposable en fonction du tableau des marques.

Dans ces conditions, la structure de l'énoncé devient

$$D_1 \quad N_1 \quad V \quad ADV \quad F_i \quad p \quad D_2 \quad N_{2/3}$$

Or on a pu constater, d'après ce qui précède, que la forme de l'énoncé (F_i) peut exercer une détermination sur tous les éléments de l'énoncé, et pas seulement sur son syntagme verbal. Que si l'on convient d'appeler « lexis » l'ensemble canoniquement ordonné de ces éléments, on dira qu'un énoncé résulte de l'application d'une forme de l'énoncé sur une lexis donnée soit

$$E_n = F_i (D_1, N_1, V, ADV, p, D_2, N_{2/3})$$

Un énoncé peut donc finalement être enregistré comme un ensemble ordonné de huit termes, chaque terme correspondant à une *catégorie morpho-syntaxique* déterminée (1).

3. LES TRANSFORMATIONS DE L'ÉNONCÉ

Rappelons que nous avons antérieurement posé deux types de transformations :

1. Des transformations de type T_1

- || Il te demande de venir
- || Il demande à toi ($\varphi_n = \text{que}$) tu viennes

2. des transformations de type T_2

- || Le petit chien dort près du feu
- || Le chien dort près du feu δ_1 chien ϵ * petit.

A ces transformations dissociant les propositions nous ajouterons maintenant un troisième groupe (soit T_3), désignant les *transformations portant sur l'énoncé lui-même* ; citons, parmi elles :

— T_{3a} : *nominalisation*.

Par exemple

- || Pierre part en voiture

s'indiquera

- || Départ ϵ de Pierre + Départ ϵ en voiture

et

- || La terre tourne

s'écrit

- || La rotation ϵ de la Terre

ou

- || La rotation ϵ * terrestre.

— T_{3b} : *actif-passif*.

Par exemple

- || Le garçon regarde la vitrine
- || La vitrine est regardée par le garçon.

(1) Voir Annexe IV, p. 128 Sqq.

Remarquons que T_3a combine ses effets avec ceux de T_1 et T_2 . Soit par exemple la phrase

|| Le rideau tombe à la fin du spectacle.

On a, par application de T_2 (libération des adjonctions)

|| Le rideau tombe à la fin δ_2 fin ϵ du spectacle.

Or, au moyen de la transformation T_3a de l'énoncé, on obtient

|| fin ϵ de le spectacle $\rightarrow$ le spectacle est fini

d'où la possibilité de construire

|| Le rideau tombe (lorsque) le spectacle est fini

ce qui représente la libération d'une proposition latente dans la proposition initiale, par un effet qu'on peut ainsi rapporter à une transformation T_1 faisant correspondre

à $(-p_x) +$ complément

et lorsque $(-p_n) +$ énoncé résultant de la transformation T_3a du complément.

Cette remarque n'a de valeur qu'indicative : nous pensons qu'il est possible d'aboutir, en explorant systématiquement cette direction, à des enregistrements parallèles d'une même surface, multipliant ainsi les possibilités de rapports entre les surfaces discursives d'un même Δ_x (1).

4. PROBLÈMES PARTICULIERS D'ENREGISTREMENT : QUELQUES EXEMPLES

a) L'ambiguïté des lexèmes

On a déjà constaté (2) qu'un même terme pouvait, selon les conditions, recevoir des enregistrements différents. Par exemple, la préposition *de*, dans

|| Jamais de ma vie je ne lui parlerai

doit être enregistrée comme l'introducteur d'un complément circonstanciel de temps, alors que dans

|| Je ne lui parlerai jamais de ma vie

de introduit le complément d'objet indirect de *parler*.

(1) Cf. « Régularisation de l'enregistrement », p. 84.

(2) Cf. p. 72.

Une remarque similaire peut être faite à propos du complément de nom ; soit

E_1 = la prise ϵ du plâtre (la prise du plâtre)

E_2 = la venue ϵ de Jean (la venue de Jean)

E_3 = la prise ϵ de Constantinople (la prise de Constantinople)

E_4 = le train ϵ de Paris (le train de Paris).

On voit que T_3a appliquée à chacun de ces énoncés permet de séparer E_1 et E_2

la prise du plâtre $\rightarrow$ le plâtre prend

la venue de Jean $\rightarrow$ Jean vient

de E_3

la prise de Constantinople $\rightarrow$ X prend Constantinople

et de E_4

le train de Paris $\rightarrow$ le train $\left| \begin{array}{l} \text{va à} \\ \text{vient de} \end{array} \right|$ Paris

La relation d'adjonction *adjectivale* est, elle aussi, susceptible de variation, selon que la relation d'adjectivation est ou non présupposée (1) chez l'auditeur par l'orateur. Par exemple, la relation de l'adjectif *martial* au substantif qui lui correspond doit être enregistrée de façon différente dans les deux phrases

|| L'air martial du colonel avait séduit la marquise

|| La cour martiale condamna le colonel à la détention perpétuelle.

On posera donc

|| l'air + ϵ + * + martial

mais

|| la cour + ϵ' + * + martial (syntagme figé).

Il est à noter que le discours peut figer provisoirement ou définitivement certaines relations adjectivales antérieurement non-figées, comme il apparaît

(1) Cf. le problème de la présupposition et de l'implication, in DUCROT (O.), « Logique et linguistique », *Langages*, n° 2, 16.

dans l'exemple ci-dessous, imaginaire mais nullement impossible, au moins en tant qu'effet littéraire :

|| En raison de l'état d'urgence, le commandement décréta que tous les soldats devraient désormais arborer un *air martial*...

Ici on aurait

|| un air + ϵ + * + martial

mais dans

|| Tout soldat pris sans son *air martial* serait fusillé sur le champ.

on écrirait

|| L'air + ϵ' + * + martial.

b) *Le complément d'adjectif*

Soit la phrase

|| Napoléon était avide de gloire.

On enregistrera

E_1 = Napoléon était * avide,

E_2 = (avide $\rightarrow$ avidité) ϵ de gloire,

d'où

$E_1 \delta_2 E_2$.

On effectue donc la transformation intermédiaire

ADJ $\Rightarrow$ [N : Substantif (ADJ)]

pour pouvoir appliquer la règle d'adjonction.

c) *Les relations ternaires*

Le cas des propositions contenant plus de deux syntagmes nominaux a déjà été évoqué (1); nous avons montré que dans certains cas une *règle de dissociation* (T_1) pouvait s'appliquer : soit par exemple la phrase

|| J'ai vu l'express de Bordeaux et l'autorail du Mans.

(1) Cf. p. 44.

On l'enregistrera

E_1 = j'ai vu * l'express,

E_2 = express ϵ de Bordeaux,

E_3 = j'ai vu * l'autorail,

E_4 = autorail ϵ du Mans.

et $E_1 \delta_2 E_2$

$E_1 \varphi_1 E_3$

$E_3 \delta_2 E_4$

avec φ_1 = et

Il existe d'autre part des cas où la règle de dissociation ne peut pas s'appliquer : soit la phrase

|| Je voudrais du whisky et de l'eau

Nous l'enregistrerons

E_5 = Je voudrais * A

E_6 = whisky ϵ_3 à A

E_7 = eau ϵ_3 à A

(avec une forme spéciale ϵ_3 désignant l'appartenance).

D'où

$E_5 \delta_2 E_6$

$E_6 \varphi_1 E_7$

$E_5 \delta_2 E_7$ (saturation)

avec φ_1 = et

Il existe enfin des cas (assez rares) où la proposition est construite sur la structure d'une *relation ternaire*. Par exemple

|| X donne Y à Z (1)

ou || X est entre Y et Z (2)

En ce qui concerne le cas (1), nous avons déjà vu que les propositions du type

|| Ève donne une pomme à Adam

|| Il donne de l'argent aux pauvres

pouvaient être enregistrées

E_8 — Ève donne une pomme

E_9 — Ève donne à Adam ($E_8 \propto E_9$)

E_{10} — Il donne * de l'argent

E_{11} — Il donne à les pauvres ($E_{10} \propto E_{11}$)

Il est clair, d'autre part, qu'il faut distinguer par un enregistrement différent des précédents les phrases du type

|| Il offre une glace à la vanille

soit

E_{12} — il offre * une glace

E_{13} — glace ϵ à la vanille ($E_{12} \delta_2 E_{13}$)

Mais certaines phrases sont irrémédiablement ambiguës à cet égard, par exemple

|| Le livre conserve une importance dans la civilisation

On enregistrera alors les deux interprétations, en appliquant la règle de saturation, soit :

E_{14} = le livre conserve * une importance

E_{15} = le livre conserve dans la civilisation

E_{16} = une importance ϵ dans la civilisation

et

$E_{14} \delta_1 E_{15}$

$E_{14} \delta_2 E_{16}$

$E_{15} \varphi_2 E_{16}$ (saturation)

Le cas (2)

|| X est entre Y et Z

présente une difficulté différente des précédentes dans la mesure où nous voulons éviter d'enregistrer des prédicats ternaires; nous proposons la solution suivante :

$E_{16} = X \epsilon_4 p_x K$

$E_{17} = Y \text{ or } * K$

$E_{18} = Z \text{ ext } * K$

et

$E_{16} \delta_2 E_{17}$

$E_{17} \varphi_1 E_{18}$

$E_{16} \delta_2 E_{18}$ (saturation)

Dans cet enregistrement,

K représente le segment YZ

$\epsilon_4 p_x K$ signifie être à l'intérieur du segment YZ

or $* K$ signifie être à l'origine de K

et ext $* K$ signifie être l'extrémité de K .

d) *Le comparatif*

Soit la phrase

|| Racine était meilleur tragédien que Crébillon

Nous ferons intervenir une transformation de type T_1 donnant les deux énoncés :

E_{19} = Racine était * tragédien

E_{20} = Crébillon était * tragédien

ainsi qu'un opérateur $\overrightarrow{p}_2$ d'inégalité, signifiant « davantage que..., mieux que..., etc. ».

Soit

$E_{19} \varphi_n E_{20}$

e) *La proposition-sujet*

Soit la phrase

|| Que la terre tourne est (un fait) prouvé par la science.

Première solution :

L'énoncé « la terre tourne » contenu dans la phrase peut être transformé selon T_3a :

|| La terre tourne

$\rightarrow$ || La rotation ϵ de la terre

d'où l'état intermédiaire

[La rotation de la terre est prouvée par la science]

auquel on peut appliquer T_2 , soit

E_{21} = la rotation est prouvée par la science

E_{22} = la rotation ϵ de la terre

Remarquons que T_3b appliquée à E_{21} fournit

E_{23} = la science prouve * la rotation.

Deuxième solution

On peut également commencer par rétablir l'ordre de dépendance canonique au niveau de la phrase, soit

[(est prouvée par la science)
= la science prouve] (que) (la terre tourne)

5. RÉGULARISATION DE L'ENREGISTREMENT

Notre objectif est, on le sait, de multiplier les possibilités de co-occurrence d'une surface à l'autre. Pour cela, nous prendrons les décisions suivantes :

1. Toutes les transformations T_3b , purement intérieures à l'énoncé, seront effectuées *systématiquement dans un seul sens* de manière à réduire les écarts morphologiques entre les énoncés.
2. Dans le cas de la nominalisation (T_3a), on a vu ci-dessus que cette transformation mettait en cause le contenu des énoncés voisins, et la nature des opérateurs de dépendance. On générera donc systématiquement les différentes solutions possibles en fonction de T_3a , et on enregistrera les dépendances qui correspondent à chacune d'elles. Par exemple

|| Le professeur affirme que la science démontre
|| la rotation terrestre

E_1 = le professeur affirme $\phi \phi$

E_2 = la science démontre * la rotation

E_3 = la rotation ϵ * terrestre

T_3a appliquée à E_3 donne

E_4 = la rotation ϵ de la terre

T_3a appliquée à E_4 donne

E_5 = la terre tourne $\phi \phi$

Le résultat de T_3 sur E_2 est

E_6 = la science démontre $\phi \phi$

d'où

$E_1 \quad \varphi_2 \quad E_2$

$E_2 \quad \delta_2 \quad E_3$


$E_2 \quad \delta_2 \quad E_4$

$E_1 \quad \varphi_2 \quad E_6$

$E_6 \quad \varphi_2 \quad E_5$ avec φ_2 = que

Par ce moyen, le contenu du discours enregistré est régularisé de telle manière que les différences dues à la variation des constructions syntaxiques sans variation sémantique se trouvent autant que possible éliminées.

En résumé, le processus d'enregistrement a la forme générale indiquée ci-dessous. Répétons encore une fois que l'automatisation de ce processus exige un long travail linguistique au cours duquel bien des points avancés par nous seront vraisemblablement remis en question : l'essentiel était pour nous de spécifier ici les requisit linguistiques indispensables à l'analyse. En d'autres termes, nous avons ici proposé un *procédé* et non une *théorie de la langue*, étant entendu que ce procédé repose sur des pré-supposés théoriques qui exigent précisément d'être explicités et critiqués par le linguiste. Le point essentiel concerne, selon nous, la question de savoir s'il est licite de représenter une séquence par un graphe reliant des énoncés élémentaires de composition fixe, du type de la *lexis*.



II. L'ANALYSE AUTOMATIQUE DU MATÉRIEL ENREGISTRÉ

Soit un corpus C_x de discours $\mathcal{D}_{x1} \dots \mathcal{D}_{xn}$ correspondant à des conditions T_x stables, définies par des *critères externes*, de type sociologique (*situation* et *position* de l'émetteur, *rôles* mis en jeu, etc.) ⁽¹⁾.

Le corpus C_x a été transformé par l'enregistrement en un ensemble

$$\mathcal{B}_x = \{ b_1, b_2, \dots, b_n \}$$

avec

$$b_i = E_i \psi_n E_j$$

et

$$E_i, E_j \in \mathcal{E}_x$$

avec

$$\mathcal{E}_x = \{ E_0, E_1, E_2, \dots, E_n \}$$

Conformément à nos hypothèses précédentes ⁽²⁾, nous posons l'existence de deux mécanismes :

a) une sélection-combinaison (S-C) effectuée sur la langue et produisant l'ensemble des énoncés :

$$(S-C)_x(\mathcal{L}) = \mathcal{E}_x;$$

b) une application ψ de l'ensemble des énoncés sur lui-même :

$$\mathcal{E} \psi \mathcal{E}.$$

Remarquons à propos du mécanisme S-C que certaines contraintes sont imposées par la langue $\mathcal{L}$ elle-même — par exemple, la nécessité de sélectionner un complément d'objet pour le combiner avec un verbe transitif — : ces contraintes sont donc extérieures à S-C. S-C représente ici les contraintes qui ne sont pas imposées par $\mathcal{L}$. Par exemple, la sélection-combinaison effectuée sur les mots « propriété » et « vol » n'est pas la même dans les deux séquences

- || Le vol est une atteinte à la propriété individuelle;
- || La propriété, c'est le vol.

⁽¹⁾ Une fois le noyau initial défini par des *critères externes* il semble possible (voir note finale, p. 118 sqq) de concevoir un *filtre* qui sélectionnerait au moyen de critères internes les discours susceptibles « d'enrichir » le noyau initialement posé.

⁽²⁾ Cf. p. 35.

Nous considérerons que les contraintes syntaxiques sont *stables dans la langue* (les effets d'ordre, d'emphase, etc. n'étant pas considérés comme syntaxiques) et que, par conséquent, la spécificité des contraintes combinatoires sur les composantes des énoncés, ainsi que celle du mécanisme d'application $\psi(\mathcal{E} \times \mathcal{E})$ représentent la distance du discours par rapport à la langue c'est-à-dire l'efficacité des conditions de production sur le processus de production du discours, soit

$$I'_x \circ \mathcal{L} \Rightarrow \Delta_x$$

Pour mettre en évidence Δ_x , nous chercherons à définir les « points d'ancrage » dans le corpus — que nous appellerons les « domaines sémantiques » —, ainsi que les relations de dépendance entre ces domaines.

On dira ⁽¹⁾ que deux énoncés E_i et E_j ont même interprétation sémantique si

- E_i et E_j sont paradigmatiquement proches l'un de l'autre;
- E_i et E_j sont liés par des dépendances fonctionnelles identiques à deux autres énoncés E_k et E_m eux-mêmes paradigmatiquement proches l'un de l'autre.

Ceci suppose qu'on puisse définir

- un programme de comparaison paradigmatique des énoncés;
- un programme de formation des domaines sémantiques, par mise en relation des énoncés au moyen des opérateurs de dépendance ψ_n .

A) Analyse paradigmatique des énoncés

1. PARTITION DE $\mathcal{E}_x$ EN CATÉGORIES

Soient deux énoncés E_i et E_j appartenant à $\mathcal{E}_x$. On sait que E_i et E_j sont composés chacun d'une séquence de termes ordonnés selon les classes morpho-syntaxiques, soit par exemple

F_i	D_1	N_1	V	ADV	PP	D_2	$N_{2/3}$
$E_i = a$	b	c	d	e	f	g	h
$E_j = a$	b	c	d	j	f	k	m

⁽¹⁾ Cf. p. 35.

Associations un nombre binaire π au couple (E_i, E_j) en prenant pour convention que

Deux termes identiques dans la même classe morpho-syntaxique se traduisent par le chiffre 1 dans π , à la place correspondante, et deux termes différents par le chiffre 0.

Par exemple, on obtient ici

$$(E_i, E_j) = 11110100$$

On voit qu'il est possible de classer chacun des $n(n-1)/2$ couples formés à partir de n éléments de $\mathcal{E}_x$ selon leur « nom » binaire, représentant la catégorie — soit G_i — à laquelle chaque couple appartient.

Soit donc un ensemble $\mathcal{E}_x$ d'énoncés E_i tels que

$$E_i = x_i^1, x_i^2, \dots, x_i^k, \dots, x_i^8$$

Définissons l'application de $\mathcal{E} \times \mathcal{E}$ dans 2^8 , où « 2 » désigne l'ensemble $\{0, 1\}$:

$$\forall (E_i, E_j) \in \mathcal{E} \times \mathcal{E} \rightarrow \pi \langle \alpha_1, \alpha_2, \dots, \alpha_k, \dots, \alpha_8 \rangle \in 2^8$$

tel que $\forall k, 1 \leq k \leq 8$:

$$(x_i^k = x_j^k) \rightarrow \alpha_k = 1$$

$$(x_i^k \neq x_j^k) \rightarrow \alpha_k = 0$$

Remarquons que

$$\pi(E_i, E_j) = \pi(E_j, E_i).$$

Soit maintenant une relation R entre les éléments de $\mathcal{E} \times \mathcal{E}$ définie par

$$(E_i, E_j)R(E_p, E_q) \Leftrightarrow \pi(E_i, E_j) = \pi(E_p, E_q)$$

R est une relation d'équivalence, car

- $(E_i, E_j)R(E_i, E_j)$ (réflexivité)
- $(E_i, E_j)R(E_p, E_q) \Leftrightarrow (E_p, E_q)R(E_i, E_j)$ (commutativité)
- $[(E_i, E_j)R(E_p, E_q)] \wedge [(E_p, E_q)R(E_m, E_n)] \rightarrow (E_i, E_j)R(E_m, E_n)$ (transitivité).

Nous appellerons G_i l'ensemble des éléments de $\frac{\mathcal{E} \times \mathcal{E}}{R}$. Notons enfin que l'on peut effectuer une partition de G_i : soit en effet une catégorie G_i telle que :

$$G_i = \{ (E_i, E_j); (E_i, E_k); (E_m, E_n); (E_n, E_p); (E_k, E_g) \}$$

Il est clair que l'on peut écrire

$$G_i = \{ G_i^1 \mid G_i^2 \}$$

avec

$$G_i^1 = \{ E_i, E_j, E_k, E_g \}$$

$$G_i^2 = \{ E_m, E_n, E_p \}$$

Les énoncés contenus dans G_i^2 sont tels qu'ils conservent fixes au moins toutes les classes morphosyntaxiques correspondant à 1 dans le π associé à G_i . Bien entendu, il peut se trouver que le couple (E_j, E_k) par exemple ne soit pas contenu dans G_i , mais dans une catégorie G_j conservant les mêmes classes que G_i plus d'autres classes; par exemple

$$E_i = a \ b \ c \ d$$

$$E_j = a \ b \ m \ k$$

$$E_k = a \ b \ m \ h$$

On a


$$(E_i, E_j) = 1 \ 1 \ 0 \ 0$$

$$(E_i, E_k) = 1 \ 1 \ 0 \ 0;$$

mais

$$(E_j, E_k) = 1 \ 1 \ 1 \ 0.$$

D'où l'analyse des proximités paradigmiques (Alg. 1) donnée dans le tableau suivant.



Alg. 1. Analyse des proximités paradigmiques

2. VALEUR DE LA PROXIMITÉ PARADIGMATIQUE

En fonction de ce qui précède, on pourrait ordonner les catégories G_i en fonction du nombre de classes morpho-syntaxiques conservées dans le couple (E_i, E_j) , nombre qui serait une estimation de la proximité. Toutefois, il importe de ménager la possibilité d'attribuer des valeurs différentes aux différentes classes : par exemple, on peut raisonnablement faire l'hypothèse que la conservation de N_1 et de V entre E_i et E_j leur assure une proximité paradigmatisque supérieure à la conservation de D_1 et D_2 .

On posera donc des coefficients $p_1, p_2, \dots, p_8$ tels que

$$\pi < \alpha_1, \alpha_2, \dots, \alpha_k, \dots, \alpha_8 > \rightarrow p = < \alpha_1 p_1 + \dots + \alpha_k p_k + \alpha_8 p_8 >$$

avec $\alpha_k = 0$ ou 1.

La valeur de ces coefficients peut d'ailleurs être fixée soit une fois pour toutes par le linguiste, soit au contraire posée comme fonction d'une variable, par exemple la forme de l'énoncé, auquel cas on aurait

$$p_k = f(\alpha_k)$$

ou même

$$p_k = f(a_i/a_j)$$

On peut d'autre part envisager de modifier la valeur de p_k en fonction de la nature de a_i/a_j . Si, par exemple, $a_i^8 = a_j^8 - \phi$ ($N_{2,3}$ vide), on n'associerait pas à cette occurrence le même poids que si $a_i^8 = a_j^8$ avec a^8 non vide.

Quelles que soient les décisions ultérieures sur ce point, on voit qu'à chaque partition de G_i — soit G_i^n — peut être affecté un « poids » p traduisant la valeur du rapport paradigmatisque entre le couple d'énoncés considérés (¹).

(¹) A titre provisoire nous proposons les pondérations suivantes :

x_i/x_j	F	D ₁	N ₁	V	ADV	PP	D ₂	N ₂
x_1/x_1	3	2	5	5	3	3	2	5
ϕ/ϕ	—	1	—	—	1	1	1	1
e/e	—	—	—	2	—	—	—	—

3. CALCUL DE LA PROXIMITÉ DE DEUX ÉNONCÉS DANS L'ENSEMBLE $\mathcal{E}_x$

Considérons deux énoncés E_i et E_j appartenant à un ensemble $\mathcal{E}_x$. Nous venons de montrer comment on peut attribuer une valeur p à leur rapport paradigmatisque; cette valeur résulte de la comparaison de E_i et E_j , abstraction faite des autres énoncés de $\mathcal{E}_x$. Or le fait qu'il existe ou non un ou plusieurs énoncés de $\mathcal{E}_x$ qui soient intermédiaires entre E_i et E_j influe sur leur proximité dans $\mathcal{E}_x$.

Soit par exemple

E_i — le colonel séduisit la marquise


E_j — l'officier plut à la marquise

S'il existe un énoncé

E_k — le colonel plut à la marquise

la possibilité de substitution paradigmatisque entre les composants de E_i et E_j s'en trouve augmentée.

On définira donc un programme, soit Alg. 2, permettant de déterminer systématiquement les énoncés intermédiaires entre deux énoncés donnés, et d'en déduire la valeur résultante, soit P , de la proximité paradigmatisque caractérisant leur couple à l'intérieur de l'ensemble $\mathcal{E}_x$.



Alg. 2. Analyse de la proximité paradigmatic de (E_i, E_j) rapportée à l'ensemble S_x

B) Constitution des domaines sémantiques et analyse de leurs dépendances

1. ANALYSE DES SIMILITUDES

Soient deux énoncés E_i et E_j appartenant à S_x .

— S'il existe dans S_x deux relations binaires

$$\begin{array}{ccc} E_i & \psi_k & E_m \\ E_j & \psi_k & E_n \end{array}$$

— et si la valeur des proximités paradigmatic entre E_i et E_j d'une part, E_m et E_n d'autre part, est supérieure à une borne donnée p_α , on dira que

$$\begin{pmatrix} E_i \\ E_j \end{pmatrix} \psi_k \begin{pmatrix} E_m \\ E_n \end{pmatrix}$$

constitue une *zone de similitude*, éventuellement susceptible de se prolonger par concaténation:

soit

$$\begin{pmatrix} E_i \\ E_j \end{pmatrix} \psi_k \begin{pmatrix} E_m \\ E_n \end{pmatrix} \psi_p \begin{pmatrix} E_q \\ E_r \end{pmatrix}$$

si

$$\begin{pmatrix} E_m \\ E_n \end{pmatrix} \psi_p \begin{pmatrix} E_q \\ E_r \end{pmatrix}$$

répond aux mêmes exigences que précédemment. On appellera *chaîne de similitude* une concaténation de zones de similitude.

a) Formation des ψ -classes

Soit un ensemble S_x formé de n relations binaires du type $E_i \psi_k E_m$, avec

$$\psi = \begin{Bmatrix} \alpha \\ \delta_1, \delta_2 \\ \varphi_1, \dots, \varphi_n, \varphi_\alpha \end{Bmatrix}$$

Engendrons g classes différentes correspondant aux g opérateurs de dépendance ψ ayant une fonction différente dans S_x (on suppose que l'enregistrement a régularisé les cas d'équivalence entre deux opérateurs ψ de morphologie différentes ayant même fonction).

Soit $\mathcal{B}_x$:

E_1	δ_1	E_2
E_2	δ_2	E_3
E_4	φ_1	E_4
E_1	φ_5	E_5
E_5	δ_1	E_6
E_4	φ_α	E_5
E_5	φ_1	E_7
E_7	δ_2	E_8
.	.	.
.	.	.

$\mathcal{B}_x$ prend alors la forme suivante

δ_1	δ_2	φ_α	φ_1	φ_5	
E_1, E_2	E_2, E_3	E_4, E_5	E_1, E_4	E_1, E_5	
E_5, E_6	E_7, E_8	.	E_5, E_7	.	
.	.	.	.	.	
.	.	.	.	.	

On conviendra d'appeler $G(\psi_i)$ l'ensemble des énoncés placés à gauche dans la classe ψ_i , et $D(\psi_i)$ l'ensemble des énoncés placés à droite.

Par exemple

$$E_7 \in G(\delta_2)$$

$$E_4 \in D(\varphi_1)$$

b) Formation des chaînes de similitude

Soit la ψ -classe ψ_n . Supposons qu'elle contienne E_i et E_j , tels que

$$E_i \in G(\psi_n)$$

$$E_j \in G(\psi_n)$$

Il en résulte que cette même classe comprend E_k et E_m , tels que

$$E_i \psi_n E_k$$

$$E_j \psi_n E_m$$

Soit P_1 la valeur de la proximité paradigmatisée de E_i et E_j , rapportée à l'ensemble $\mathcal{E}_n$: $P_1 = p(E_i, E_j)$ selon Alg. 2. Soit de la même manière $P_2 = p(E_k, E_m)$ selon Alg. 2. On dira que

$$\begin{pmatrix} E_i \\ E_j \end{pmatrix} \psi_n \begin{pmatrix} E_k \\ E_m \end{pmatrix}$$

constitue une zone de similitude si

$$\frac{P_1 + P_2}{2} > p_\alpha \quad p_\alpha \text{ étant fixe.}$$

On choisira pour p_α une valeur intermédiaire, par exemple la demi-somme des valeurs maximum (cf. Annexe III, p. 122).

Remarque 1

Soit

$$E_i = ay * b$$

$$E_j = ay * c$$

$$E_k = bw * k$$

$$E_m = cw * q$$

(nous représentons ici les énoncés par quatre éléments, pour simplifier l'écriture).

On voit que l'opposition b/c , présente dans le couple (E_i, E_j) est répétée dans le couple (E_k, E_m) : pour éviter de tenir compte deux fois de la même opposition, on conviendra d'écrire $b/c = x_1$ et de transcrire respectivement E_k et E_m par les expressions

$$x_1 w * k$$

$$x_1 w * q$$

d'où

$$P_2 = p(x_1 w * k, x_1 w * q).$$

Nous appellerons cette opération « annulation de la différence répétée ».

Remarque 2


On peut réitérer l'opération qui vient d'être effectuée, à la condition qu'il existe une ψ -classe ψ_p telle que

$$E_k \in G(\psi_p)$$

$$E_m \in G(\psi_p)$$

On appellera chaîne de similitude le résultat de n réitérations de l'opération décrite ci-dessus.

D'où l'algorithme 3.



Alg. 3. Formation des chaînes de similitude.

2. FORMATION DES DOMAINES

a) Groupe opérateur

Soit une chaîne

$$C_n = \left(\begin{matrix} E_i \\ E_j \end{matrix} \right) \psi_i \left(\begin{matrix} E_m \\ E_n \end{matrix} \right) \psi_j \left(\begin{matrix} E_x \\ E_y \end{matrix} \right) \dots \psi_z \left(\begin{matrix} E_x \\ E_y \end{matrix} \right)$$

On convient de placer en tête de l'expression C_n la série des opérateurs, ordonnés en fonction de leur apparition dans la chaîne, soit ici

$$C_n = (\psi_i, \psi_j, \dots, \psi_z) \left[\left(\begin{matrix} E_i \\ E_j \end{matrix} \right), \left(\begin{matrix} E_m \\ E_n \end{matrix} \right), \dots, \left(\begin{matrix} E_x \\ E_y \end{matrix} \right) \right]$$

On appellera groupe opérateur l'ensemble ordonné des opérateurs, placé en tête dans l'expression C_n .

b) Catégorie de chaîne

Soit C^* l'ensemble des chaînes produites par Alg. 3. Il est possible d'effectuer une partition de C^* en fonction du groupe opérateur des chaînes de C^* ; d'où les n catégories $K_1, K_2, \dots, K_i, \dots, K_n$ correspondant aux n groupes opérateurs différents contenus dans C^* .

c) Homogénéité de deux chaînes dans une même catégorie : définition du domaine sémantique

On appellera domaine un ensemble de chaînes d'une même catégorie, tel que les chaînes soient homogènes entre elles; on dira que deux chaînes d'une même catégorie sont homogènes entre elles si on peut définir une homogénéité entre leurs zones de similitude respectives, prises successivement.

Définition de l'homogénéité entre deux zones de similitude

Pour simplifier l'écriture, nous poserons :

$$C_p = (\text{groupe opérateur } K_i) [(S_1) \dots (S_i), (S_{i+1}) \dots (S_n)]$$

$$C_q = (\text{groupe opérateur } K_j) [(S'_1) \dots (S'_j), (S'_{j+1}) \dots (S'_n)]$$

avec

$$(S_i) = \begin{pmatrix} E^1 \\ E^2 \end{pmatrix}; \quad (S'_j) = \begin{pmatrix} E^3 \\ E^4 \end{pmatrix}; \quad (S_{i+1}) = \begin{pmatrix} E^5 \\ E^6 \end{pmatrix}; \quad (S'_{j+1}) = \begin{pmatrix} E^7 \\ E^8 \end{pmatrix}$$

où le nombre provisoirement attribué en *exposant* à chaque énoncé indique sa place dans le présent calcul, et ne doit pas être confondu avec l'indication des énoncés dans ξ_x .

Formons et calculons

$$\begin{array}{ll} P(E^1, E^3) & P(E^5, E^7) \\ P(E^1, E^4) & P(E^5, E^8) \\ P(E^2, E^3) & P(E^6, E^7) \\ P(E^2, E^4) & P(E^6, E^8) \end{array}$$

On dira que les deux zone « $(S_i)(S_{i+1})$ » et « $(S'_i)(S'_{i+1})$ » sont homogènes, ce qu'on notera

$$[(S_i)(S_{i+1})] \mathcal{H}[(S'_i)(S'_{i+1})]$$

si l'une au moins des expressions suivantes est supérieure à la borne fixée p_α .


$$P(I) = \frac{P(E^1, E^3) + P(E^5, E^7)}{2}$$

$$P(II) = \frac{P(E^1, E^4) + P(E^5, E^8)}{2}$$

$$P(III) = \frac{P(E^2, E^3) + P(E^6, E^7)}{2}$$

$$P(IV) = \frac{P(E^2, E^4) + P(E^6, E^8)}{2}$$

D'où le test d'homogénéité Alg. 4.



Alg. 4. Test d'homogénéité entre deux zones de similitude

Homogénéité entre deux chaînes de similitude

Une application récursive de Alg. 4 à deux chaînes C_n et $C_{n'}$ appartenant à une même catégorie K_i permet de tester l'homogénéité de ces deux chaînes : elles seront déclarées homogènes — soit $C_n \mathcal{H} C_{n'}$ — si le test Alg. 4 est positif pour toutes les valeurs de i prises deux à deux (i et $i+1$), i étant compris entre 1 et n . L'éventualité d'une homogénéité partielle entre C_n et $C_{n'}$ n'a pas été envisagée ici, ce qui ne signifie pas qu'on ne sera pas amené, ultérieurement, à la prendre en considération.

Ajoutons enfin que deux chaînes dont le groupe opérateur ne diffère que par un opérateur final d'adjonction — (ψ_i, ψ_j) et $(\psi_i, \psi_j, \delta_1)$ par exemple — peuvent être homogènes bien qu'elles ne fassent pas partie, *stricto sensu*, de la même catégorie; cette disposition particulière se justifie par le fait que l'adjonction peut développer un énoncé sous forme métonymique. Soit par exemple

$$\begin{aligned} (\psi_1 \dots \psi_n, \delta_1) & \quad (S_1) \dots (S_n)(S_{n+1})(S_{n+2}) \\ (\psi_1 \dots \psi_n) & \quad (S'_1) \dots (S'_n)(S'_{n+1}). \end{aligned}$$

Supposons


$E_x \in (S_{n+1})$, E_x = le président a exposé la situation

$E_y \in (S_{n+2})$, E_y = le président e' de la République

$E_z \in (S'_{n+1})$, E_z = le président a commenté la situation

On a ici un effet métonymique entre E_z et $E_x \delta_1 E_y$, plus précisément entre « le président » et « le président de la République ».

L'ensemble des règles qui précèdent est représenté dans Alg. 5.



Alg. 5. Homogénéité entre deux chaînes de similitude

On appellera *domaine sémantique* l'ensemble des chaînes d'une même catégorie (compte tenu de la précédente remarque sur les adjonctions) homogènes entre elles.

On a donc, pour une catégorie donnée :

$$K_i = \{ K_i^1, K_i^2 \dots K_i^p \},$$

avec $K_i^n = D_s$ (domaine sémantique de nom S).

On dira que deux domaines d'une même catégorie (soient K_i^m et K_i^n) sont disjoints si

- 1) $\forall C_i \in K_i^m, \sim \exists C_x, C_x \in K_i^n$ tel que $C_i \mathcal{R} C_x$;
- 2) $\forall C_j \in K_i^n, \sim \exists C_k, C_k \in K_i^m$ tel que $C_j \mathcal{R} C_k$.

On voit qu'un *domaine* correspond à un ensemble de séquences superposables.

La dimension d'un domaine correspond au nombre de *places* qu'il possède, soit le produit du nombre de *lignes* (les différentes surfaces) par celui des *colonnes* (le nombre d'énoncés appartenant à la chaîne, soit $n + 1$ si le groupe opérateur comporte n opérateurs). Par définition, deux séquences appartenant à un même domaine reçoivent la même interprétation sémantique.


3. ANALYSE DE LA DÉPENDANCE ENTRE LES DOMAINES SÉMANTIQUES

a) Dépendance entre deux énoncés

On dira qu'un énoncé E_n dépend d'un énoncé E_k — ce qu'on notera ($E_k \Rightarrow E_n$) — s'il existe une concaténation de dépendances directes entre E_k et E_n .

Soit $E_k \varphi_\alpha E_1 \varphi_\beta \dots \varphi_\nu E_n$

D'où Alg. 6.



Alg. 6. Analyse de la dépendance entre énoncés

b) *Dépendance entre deux séquences*

On appellera origine d'une séquence — soit $\mathcal{O}(S_n)$ — l'énoncé placé à gauche de cette séquence.

— si deux séquences S_n et $S_{n'}$ ont même origine, on notera

$$\mathcal{O}(S_n) = \mathcal{O}(S_{n'}) \text{ et } S_n \diamond S_{n'}.$$

— si deux séquences ont des origines différentes, on dira que $S_{n'}$ dépend de S_n (ou que S_n commande $S_{n'}$) si l'origine de $S_{n'}$ dépend de l'origine de S_n , et on notera $S_n \rightarrow S_{n'}$.

c) *Relations entre deux domaines*

— On dira que deux domaines D_x et D_y ont des origines totalement communes si, pour toute séquence du domaine D_x , il existe une séquence du domaine D_y ayant même origine, et réciproquement.

On notera $D_x \odot D_y$.

— On dira que le domaine D_x inclut le domaine D_y si l'ensemble des origines des séquences de D_y est une partie de l'ensemble des origines de D_x .

On notera $D_x \supset D_y$.

— On dira qu'il existe une intersection entre les domaines D_x et D_y si l'intersection des ensembles des origines de leurs séquences respectives n'est pas vide, bien que D_x n'inclue pas D_y et que D_y n'inclue pas D_x .

On notera $D_x \cap D_y$.

— On dira qu'un domaine D_y dépend d'un domaine D_x si, l'intersection des ensembles des origines de leurs séquences étant vides, certaines séquences de D_y dépendent de certaines séquences de D_x , sans que l'inverse soit vérifié.

Cette dépendance comporte plusieurs degrés que l'on distinguera ainsi :

- si toute séquence de D_x commande une séquence de D_y , et si toute séquence de D_y dépend d'une séquence de D_x

on notera $D_x \Rightarrow D_y$;

- si toute séquence de D_x commande une séquence de D_y , sans que toute séquence de D_y dépende d'une séquence de D_x ,

on notera $D_x \Rightarrow\Rightarrow D_y$

- s'il existe certaines séquences (mais pas toutes) de D_x qui commandent des séquences de D_y , et si toute séquence de D_y dépend d'une séquence de D_x , on notera

$$D_x \rightarrow D_y$$

- s'il existe certaines séquences (mais pas toutes) de D_x qui commandent des séquences de D_y , sans que toute séquence de D_y dépende d'une séquence de D_x , on notera

$$D_x \rightarrow\rightarrow D_y$$

- Si, pour deux domaines D_x et D_y , il existe à la fois des séquences de D_x qui commandent des séquences de D_y et des séquences de D_y qui commandent des séquences de D_x , on notera


$$D_x \rightarrow D_y$$

- Si enfin deux domaines D_x et D_y , tels que l'intersection des ensembles des origines de leurs séquences soit vide et que aucune séquence de D_x ne commande une séquence de D_y et réciproquement, on dira que D_x et D_y sont disjoints, et on notera

$$D_x \parallel D_y$$

d'où l'Alg. 7.

En fonction de ce qui précède, on dira que le processus de production $\mathcal{A}_x$ d'un discours est représenté par le réseau de relations affectant les domaines sémantiques préalablement mis en évidence.



CONCLUSION PROVISOIRE

PERSPECTIVES D'APPLICATION DE L'ANALYSE AUTOMATIQUE DU DISCOURS

Le projet que nous venons de présenter est incomplet à bien des égards. D'une part, en effet, nous laissons au sociologue la responsabilité de définir dans le détail les traits qui caractérisent spécifiquement une condition de production discursive à travers la *situation* et la *position* des protagonistes du discours dans une structure sociale donnée; nous avons par ailleurs laissé provisoirement de côté la question des *discours qui ne sont pas des monologues*, dans la mesure où la solution de ce problème s'est montrée dépendre de la résolution du cas particulier auquel nous nous sommes borné ici; nous avons également maintes fois signalé que l'élaboration des *règles d'enregistrement* de la surface discursive exigeait un *travail linguistique* dont nous n'avons fourni ici que l'esquisse; enfin, il est bien clair que le *programme d'analyse*, tel que nous l'avons présenté pour des raisons de clarté d'exposition, comporte nombre de répétitions qui doivent être éliminées dans la rédaction du programme définitif: ici, c'est au mathématicien que nous faisons appel, pour définir la séquence minimale d'algorithmes susceptible d'exécuter l'analyse.

D'autre part, et ceci engage directement notre propre activité ultérieure, nous sommes conscient de l'existence d'un certain nombre de difficultés qui restent à surmonter: par exemple, le dispositif actuel d'analyse rend compte des *équivalences terme à terme* entre deux surfaces discursives, dans la mesure où il compare l'une à l'autre deux concaténations parallèles d'énoncés; mais si l'on admet l'éventualité d'*équivalences sémantiques globales*, correspondant à des structures de dépendance différentes après transformation des surfaces, on voit que ce problème reste actuellement en suspens. Disons seulement qu'il semble possible d'envisager une «ré-injection» des résultats de l'analyse actuelle dans les surfaces discursives initiales, et une nouvelle confrontation des concaténations générables à partir de ce

nouvel état de la surface : on aboutirait ainsi à l'idée d'un processus récurrent, constitué de *cycles d'analyse*, tels que les résultats obtenus à la « sortie » du cycle n constitueraient « l'entrée » du cycle $n + 1$.

Si l'on considère le résultat actuel du programme d'analyse, on voit que le processus de production dominant Δ_x est représenté par un ensemble de « domaines » comportant entre eux divers types de liaison⁽¹⁾ : nous pensons qu'il est alors possible de représenter chaque domaine par une ou plusieurs *propositions*, au sens *logique* du terme, du type $g(x)$ ou $m(x, y)$ selon les cas, et de définir inductivement les transformations dont sont affectés les prédicats des variables propositionnelles mises en jeu dans le processus de production : on obtiendrait ainsi des règles logiques définissant les *cohérences sémantiques et la transformation de ces cohérences*, c'est-à-dire l'effet sémantique produit par Δ_x . On disposerait ainsi d'un instrument permettant de distinguer les types de processus mis en jeu (la structure du récit se distinguant par exemple de celle de la *démonstration*), et de fournir par là des *faits théoriques* susceptibles de s'intégrer à une théorie du discours comme théorie générale de la production des effets de sens⁽²⁾.

L'enjeu de cette entreprise est donc finalement de réaliser les conditions d'une pratique de la *lecture*, en tant que détection systématique des symptômes représentatifs des effets de sens, à l'intérieur de la surface discursive. Avant d'évoquer rapidement les usages que l'on peut attendre d'une telle pratique, il importe de préciser un dernier point, d'importance capitale pour nous ; il s'agit du *principe* de cette lecture, que l'on pourrait appeler « principe de la double différence » : nous avons montré dans ce travail comment la confrontation réglée de surfaces discursives relevant d'un même Γ_x des conditions de production permettait de mettre à jour les *différences internes* à travers lesquelles se manifeste l'*invariant du discours x*, que nous avons appelé le processus de production Δ_x . Nous obtenons par ce moyen une représentation des effets sémantiques *présents* dans Δ_x . Mais ce que nous avons dit précédemment à propos des « discours implicites » auxquels se réfèrent une surface discursive donnée nous invite à penser que les *différences externes* entre Δ_x et un ou plusieurs autres processus Δ_y , Δ_z , ... qui constituent l'*extérieur spécifique* de Δ_x doivent également être prises en considération : en d'autres termes, nous pensons qu'un processus Δ_x se caractérise non seulement par les effets sémantiques qui s'y trouvent réalisés, *ce qui est dit* dans le discours x , mais aussi l'*absence d'un certain*

(1) Cf. p. 106-107.

(2) Nous soulignons encore une fois que la théorie du discours ne peut en aucune façon se substituer à une théorie de l'idéologie, pas plus qu'à une théorie de l'inconscient, mais qu'elle peut intervenir dans le champ de ces théories.

nombre d'effets qui sont présents « ailleurs », précisément dans ce que nous appelons l'*extérieur spécifique* de Δ_x . Cela suppose que l'on ne peut définir l'absence d'un effet de sens que comme l'*absence spécifique de ce qui est présent autre part* : le « non dit », l'implicite caractéristique d'un Δ_x est donc représenté par la distorsion qu'induit sur Δ_x sa confrontation à Δ_y , Δ_z , ... qui deviennent ainsi la *cause réelle des absences propres* à Δ_x . Par exemple, les « erreurs », les « oublis » propres au discours d'une science à un état donné ne sont visibles que par rapport au discours qui vient le corriger.

De la même façon, une figure de style n'existe que par rapport à un processus implicitement supposé chez le destinataire, et sur lequel le destinataire prend appui.

Les modes d'insertion de la pratique d'analyse du discours dans divers secteurs de la recherche posent un grand nombre de problèmes spécifiques que nous n'aborderons pas ici. Nous nous contenterons, là aussi, d'indiquer quelques directions, à titre d'exemple.

1. Le champ de l'investigation sociologique

Dans la mesure où la sociologie se donne pour tâche d'interroger la *relation entre les rapports de force et les rapports de sens propres à une structure sociale donnée*, elle traite le discours du sujet sociologique comme représentatif de cette relation entre sa *situation* (socio-économique) et sa *position* (idéologique) dans la structure. Ce que dit le sujet doit donc toujours être référé aux conditions dans lesquelles il le dit : ce qui est pertinent, ce n'est donc pas tant le « contenu » de l'interview qu'un dirigeant d'entreprise accorde au sociologue, que la confrontation du discours qu'il lui tient *par rapport à ce qu'il dit et fait par ailleurs*, c'est-à-dire : par rapport à d'autres rôles discursifs dont les effets peuvent être saisis *ailleurs*, PLUS la description de la pratique effectuée par le sujet, comme représentant d'une place dans le champ des pratiques, par le discours scientifique de la sociologie.

En d'autres termes, la mise en jeu du « principe de double différence » doit permettre à la fois de définir le processus discursif dominant Δ_x , et les absences spécifiques qu'il recèle, par rapport à d'autres processus, répondant à d'autres conditions de production discursives.

Des problèmes tels que celui de « l'implicite culturel », celui des formes implicites et explicites du consensus et de la différenciation, celui de l'implication de la réponse fournie dans la question posée, pourraient peut-être s'éclairer par ce moyen.

2. Le champ de l'histoire des sciences

L'identification de la « rupture épistémologique » entre une science et le terrain dont elle se retire pour se constituer est apparue comme un des problèmes cruciaux que l'histoire des sciences doit résoudre : l'analyse des conditions dans lesquelles un nouveau discours scientifique s'instaure, avec des moyens qu'il emprunte à des sciences déjà existantes ou à des représentations « non-scientifiques », peut être décrite comme la mise en rapport de plusieurs processus de production dont l'interaction engendre, dans certaines conditions, un nouveau processus bouleversant les règles de cohérence régissant le discours antérieur. S'il est vrai que lire un texte scientifique, c'est le rapporter à ce dont il se sépare, on voit que la pratique d'analyse nécessite la mise en évidence de ce qui, dans un texte $\mathcal{D}_x$, produit un *décalage* — une différence assignable dans la nature des prédicats et de leurs transformations — par rapport à un processus de production dominant Δ_x dont la répétition indéfinie est précisément rendue impossible par $\mathcal{D}_x$.

L'étude des processus auxquels une science fait des emprunts, dont elle use comme de *métaphores* pour se comprendre et pour se faire comprendre ⁽¹⁾, celle du « contexte » d'une œuvre scientifique — la constellation des processus discursifs avec lesquels elle débat et se débat —, celle enfin de la « diffusion » des connaissances dans un système de représentations pré-scientifiques, posent une série de problèmes que le type d'analyse proposé contribuerait peut-être à résoudre.

Rappelons qu'un immense travail reste à effectuer avant que ces diverses possibilités soient concrètement réalisables. En effet, la mise en œuvre de ces analyses est subordonnée en fait à l'*automatisation de l'enregistrement de la surface discursive*, étant donné le volume du matériel à traiter : nous pensons qu'il n'y a pas ici d'autre issue possible, et qu'en particulier toute réduction arbitraire préalable de la surface $\mathcal{D}_{xm}$ par des techniques du type « résumé codé » doit être évitée, puisqu'elle suppose en fait la connaissance du résultat qu'il s'agit précisément d'obtenir, à savoir la représentation du Δ_x correspondant à la classe de discours dont $\mathcal{D}_{xm}$ est extrait.

⁽¹⁾ Entre Aristote et Harvey, dit G. Canguilhem, les métaphores diffèrent. Aristote pensait que le sang irriguait le corps comme l'eau irrigue la terre. Harvey, au contraire, conçoit la circulation sanguine comme un système hydraulique, avec des pompes et des écluses.

ANNEXE I


EXEMPLE D'ENREGISTREMENT D'UNE SURFACE DISCURSIVE

Soit la séquence suivante, extraite de *Alice au Pays des Merveilles*, début du chapitre XI, « Qui a volé les tartes ? ».

Quand ils ⁽¹⁾ arrivèrent, le Roi et la Reine étaient assis sur des trônes. Une grande foule les entourait, composée de toutes sortes de quadrupèdes et d'oiseaux, et de tout le paquet de cartes. Le Valet de Cœur, debout devant eux, était enchaîné et encadré de deux soldats. Près du Roi se tenait le Lapin Blanc : il avait une trompette dans une main et dans l'autre un rouleau de parchemin. Sur une table au milieu de la salle était posé un grand plateau de tartes. Elles étaient si appétissantes qu'Alice eut une envie folle de les manger.

Nous ne disposons pas du tableau exhaustif des formes F , D et ψ_n : les décisions que nous avons prises ici ne sont évidemment valables qu'à titre d'exemple pour cette analyse et n'ont aucune portée définitive.

⁽¹⁾ En fonction de la fin du chapitre X, on sait que « ils » = Alice et le Griffon.

Formes de P Formes de D

Le fait que, dans cette séquence, aucun déterminant ne fonctionne selon la modalité de la *classe* ou du *concept* a permis certaines simplifications d'écriture, valables pour la séquence.

Fléchage : le déterminant renvoie à une ou plusieurs existences individuelles.

singulier = L — le Roi, la Reine

pluriel = LS — les tartes

Balayage : le déterminant renvoie à une ou plusieurs séries d'existants.

singulier = TL — tout le paquet

pluriel = TS — toutes sortes d'oiseaux

Extraction : le déterminant désigne un ou plusieurs éléments extraits d'un ensemble.

singulier = U — une trompette

pluriel = DS — des tartes

Remarque : U_i désigne l'extraction de l'élément i appartenant à un ensemble ordonné $\langle a_1, a_i, \dots, a_n \rangle$.

Par exemple :

U_1 (une main)

U_2 (l'autre main)

Formes de ψ_n

δ_1 — adjonction à N_1

δ_2 — adjonction à $N_{2/3}$

φ_1 — relation de simultanéité temporelle (lorsque)

φ_2 — marque d'arrêt, non qualifiée (.)

φ_3 — relation de coordination associative (et)

φ_4 — marque d'arrêt qualifiée (explication, développement) (:) :


φ_5 — relation de conséquence (si... que, au point... que)

φ_α — relation de position dans la séquence

D'où l'ensemble $\mathcal{E}_n$, l'ensemble $\mathcal{B}_n$ et sa représentation graphique, donnés ci-dessous.

1	δ_1	2	9	δ_1	12	23	δ_2	24
2	φ_α	3	12	δ_1	13	23	δ_1	25
1	δ_1	3	7	φ_α	17	24	φ_α	25
1	φ_1	4	1	φ_α	14	23	δ_2	26
3	φ_α	4	14	δ_1	17	25	δ_2	26
4	δ_1	5	14	φ_3	16	22	φ_α	26
5	φ_α	6	14	δ_1	15	18	φ_α	27
4	δ_1	6	16	δ_1	15	27	δ_2	28
1	φ_2	7	16	δ_1	17	28	φ_α	29
4	φ_α	7	17	φ_α	18	27	δ_1	29
7	δ_1	8	18	δ_1	19	29	φ_α	30
7	δ_1	9	19	φ_α	20	27	δ_1	30
8	φ_α	9	18	φ_4	20	30	φ_2	31
9	δ_1	10	20	δ_1	21	31	φ_5	32
10	φ_α	11	20	δ_2	22	32	δ_1	33
9	δ_1	11	18	φ_3	23	32	φ_6	34
11	φ_α	12	21	δ_2	22	1	φ_2	27
1	φ_2	17						
1	φ_2	18						

Ensemble $\mathcal{B}_n$


 Représentation graphique de B_x

Indice de l'énoncé	F	D_1	N_1	V	ADV	PP	D_2	$N_{2/3}$
1	F_5	ϕ	R	asseoir	ϕ	sur	DS	trône
2	F_4	L	roi	ϵ_3	ϕ	à	ϕ	R
3	F_4	L	reine	ϵ_3	ϕ	à	ϕ	R
4	F_1	ϕ	X	arriver	ϕ	ϕ	ϕ	ϕ
5	F_4	ϕ	Alice	ϵ_3	ϕ	à	ϕ	X
6	F_4	L	griffon	ϵ_3	ϕ	à	ϕ	X
7	F_2	U	foule	entourer	ϕ	*	ϕ	R
8	F_4	ϕ	foule	ϵ_1	ϕ	*	ϕ	grand
9	F_5	ϕ	foule	composer	ϕ	de = par	ϕ	K
10	F_4	TS	quadrupède	ϵ_3	ϕ	à	ϕ	K
11	F_4	TS	oiseau	ϵ_3	ϕ	à	ϕ	K
12	F_4	TL	paquet	ϵ_3	ϕ	à	ϕ	K
13	F_4	ϕ	paquet	ϵ	ϕ	de	LS	carte
14	F_5	L	valet	enchaîner	ϕ	ϕ	ϕ	ϕ
15	F_4	ϕ	valet	ϵ	ϕ	de	ϕ	cœur
16	F_5	ϕ	valet	encadrer	ϕ	de = par	DEUX	soldat
17	F_2	ϕ	valet	être debout	ϕ	devant	ϕ	R
18	F_2	L	lapin	se tenir	ϕ	près de	L	roi
19	F_4	ϕ	lapin	ϵ	ϕ	*	ϕ	blanc
20	F_2	L	lapin	avoir	ϕ	*	U	trompette
21	F_2	ϕ	lapin	avoir	ϕ	dans	U_1	main
22	F_4	ϕ	trompette	ϵ	ϕ	dans	U_1	main
23	F_2	L	lapin	avoir	ϕ	*	U	rouleau
24	F_4	ϕ	rouleau	ϵ	ϕ	de	ϕ	parchemin
25	F_2	ϕ	lapin	avoir	ϕ	dans	U	main
26	F_4	ϕ	rouleau	ϵ	ϕ	dans	U_2	main
27	F_5	U	plateau	poser	ϕ	sur	U_2	table
28	F_4	ϕ	table	ϵ	ϕ	au milieu de	L	salle
29	F_4	ϕ	plateau	ϵ	ϕ	*	ϕ	grand
30	F_4	ϕ	plateau	ϵ	ϕ	de	DS	tarte
31	F_2	LS	tarte	être	ϕ	*	ϕ	appétissant
32	F_1	ϕ	Alice	avoir	ϕ	*	U	envie
33	F_4	ϕ	envie	ϵ	ϕ	*	ϕ	fou
34	F_3	ϕ	Alice	manger	ϕ	*	LS	tarte

 Ensemble $\mathcal{E}_x$

ANNEXE II

TEST DE LA CONGRUENCE ENTRE DEUX ENSEMBLES D'ÉNONCÉS $\mathcal{E}_x$ et $\mathcal{E}_y$

Soit un ensemble $\mathcal{E}_x$.

Engendrons l'ensemble $H_x = \mathcal{E}_x \times \mathcal{E}_x$ dont les éléments sont les couples (E_i, E_j) qu'on peut constituer à partir des éléments E_n de $\mathcal{E}_x$, ces couples n'étant pas ordonnés, et les couples (E_i, E_i) étant exclus.

Si l'ensemble $\mathcal{E}_x$ contient n éléments différents, H_x contiendra h_x éléments, avec

$$h_x = \frac{n_x(n_x - 1)}{2}$$

Considérons maintenant le sous-ensemble $H'_x \subset H_x$, tel que

$$\forall (E_i, E_j) \quad , \quad (E_i, E_j) \in H'_x \Leftrightarrow p(E_i, E_j) \geq p_x$$

Soit h'_x le cardinal de ce sous-ensemble H'_x .

On appellera *densité sémantique* de $\mathcal{E}_x$ le rapport

$$\gamma_x = \frac{h'_x}{h_x} = \frac{h'_x}{\frac{n_x(n_x - 1)}{2}} = \frac{2h'_x}{n_x(n_x - 1)}$$


Remarquons que γ_x varie entre 0 et 1.

On posera que si l'union de deux ensembles $\mathcal{E}_x$ et $\mathcal{E}_y$, soit $\mathcal{E}_u$, $\mathcal{E}_x$ et $\mathcal{E}_y$ ayant respectivement une densité sémantique γ_x et γ_y , est telle que $\gamma_u \geq \gamma_x$ et $\gamma_u \geq \gamma_y$, $\mathcal{E}_x$ et $\mathcal{E}_y$ sont congruents (cf. p. 119 et 120).


On posera que, un noyau initial $\mathcal{E}_x$, auquel correspond un corpus $C_x = \mathcal{D}_{x1} \dots \mathcal{D}_{xm}$, ayant été défini, tous les corpus C_i , tels que $\mathcal{E}_i$ soient congruent avec $\mathcal{E}_x$, enrichissent le corpus C_x .

D'où Alg. 8 testant la congruence entre deux ensembles d'énoncés $\mathcal{E}_x$ et $\mathcal{E}_y$.

$\mathcal{E}_x$	n_x	H_x	$h_x = \frac{n_x(n_x - 1)}{2}$	$H'_x \subset H_x$	$h'_x \leq h_x$	$\gamma_x = \frac{2h'_x}{n_x(n_x - 1)}$
$\mathcal{E}_y$	n_y	H_y	$h_y = \frac{n_y(n_y - 1)}{2}$	$H'_y \subset H_y$	$h'_y \leq h_y$	$\gamma_y = \frac{2h'_y}{n_y(n_y - 1)}$
$\mathcal{E}_x \cap \mathcal{E}_y = \mathcal{E}_i$	n_i	H_i	$h_i = \frac{n_i(n_i - 1)}{2}$	$H'_i \subset H_i$	$h'_i \leq h_i$	$\gamma_i = \frac{2h'_i}{n_i(n_i - 1)}$
$\mathcal{E}_x - \mathcal{E}_i$ $\mathcal{E}_y - \mathcal{E}_i$	$n_x - n_i$ $n_y - n_i$	H_r	$h_r = (n_x - n_i)(n_y - n_i)$	$H'_r \subset H_r$	$h'_r \leq h_r$	$\gamma_r = \frac{h'_r}{(n_x - n_i)(n_y - n_i)}$
$\mathcal{E}_x \cup \mathcal{E}_y = \mathcal{E}_u$	$n_u = n_x + n_y - n_i$	H_u	$h_u = \frac{(n_x - n_y - n_i)(n_x + n_y - n_i - 1)}{2}$	$H'_u \subset H_u$	$h'_u \leq h_u$	$\gamma_u = \frac{2h'_u}{(n_x + n_y - n_i)(n_x - n_y - n_i - 1)}$
or	$h'_u = (h'_x + h'_y - h'_i) \cdot \frac{2(h'_x + h'_y - h'_i - h'_i)}{(n_x + n_y - n_i)(n_x - n_y - n_i - 1)}$					
d'où						



$$h_u = h'_x + h'_y + h'_i - h'_i$$



Alg. 8. Congruence entre deux ensembles d'énoncés

ANNEXE III

EXEMPLE D'ANALYSE D'UN CORPUS C_x

1. Description du corpus

Le corpus est constitué de 8 occurrences ($D_{x1} \dots D_{x8}$) du récit de la vie de Jeanne d'Arc tel qu'il est présent dans la mémoire d'adultes de culture universitaire.

L'enregistrement de ce corpus aboutit à un ensemble de 126 énoncés — soit E_x cet ensemble — et à un ensemble de 140 relations binaires — soit β_x cet ensemble.

2. Formation des chaînes de similitude

Cf. Alg. 3, p. 98.

Après avoir réparti les éléments de β_x entre les différentes ϕ -classes, on a formé les différentes chaînes de similitude, en appliquant les pondérations provisoires proposées p. 92, et en choisissant pour borne p_x la demi-somme des poids maximum de deux couples d'énoncés, soit $p_x = 28$;

(31)	F_1	ϕ	J	Chercher	ϕ	ϕ	ϕ	ϕ
(57)	F_1	ϕ	J	Aller	ϕ	ϕ	ϕ	ϕ
(85)	F_1	ϕ	J	Essayer	ϕ	ϕ	ϕ	ϕ

φ_2

(32)	F_3	ϕ	J	Voir	ϕ	*	L	Roi
(58)	F_3	ϕ	J	Trouver	ϕ	*	L	Roi
(86)	F_3	ϕ	J	Rétablir	ϕ	*	L	Roi

δ_2

(33)	F_4	ϕ	Roi	ϵ	ϕ	de	ϕ	France
(59)	F_4	ϕ	Roi	ϵ	ϕ	*	ϕ	Charles VII
(88)	F_4	ϕ	Roi	ϵ	ϕ	*	ϕ	Charles VII

Remarque : φ_2 — relation de conséquence finale.

On obtient

$$p(31,57) = 3 + 1 + 5 + 0 - 1 + 1 + 1 + 1 = 13$$

$$p(32,58) = 20$$

$$p(33,59) = 12$$

$$\text{et } p(31,57) + p(32,58) = 33 > p_x$$

$$p(32,58) + p(33,59) = 32 > p_x$$

$$\text{soit } (\varphi_2 \delta_2) \begin{pmatrix} 31 \\ 57 \end{pmatrix} \begin{pmatrix} 32 \\ 58 \end{pmatrix} \begin{pmatrix} 33 \\ 59 \end{pmatrix}$$

De même

$$p(57,85) = 13$$

$$p(58,86) = 20 \quad 13 + 20 = 33 > p_x$$

$$p(59,88) = 21 \quad 20 + 21 = 41 > p_x$$

$$\text{soit } (\varphi_2 \delta_2) \begin{pmatrix} 57 \\ 85 \end{pmatrix} \begin{pmatrix} 58 \\ 86 \end{pmatrix} \begin{pmatrix} 59 \\ 88 \end{pmatrix}$$

et

$$p(31,85) = 13$$

$$p(32,86) = 20 \quad 13 + 20 = 33 > p_x$$

$$p(33,88) = 12 \quad 20 + 12 = 32 > p_x$$

Remarque : les opérations ayant été effectuées à la main, on a négligé d'appliquer les algorithmes Alg. 1 et Alg. 2 qui, en toute rigueur, interviennent dans Alg. 3.

3. Formation des domaines

Toutes les chaînes de similitude comportant le même groupe-opérateur et homogènes entre elles appartiennent à un même domaine : on s'est contenté ici (analyse manuelle) de considérer que deux chaînes sont homogènes si elles comportent une séquence commune.

D'où par exemple :

$\begin{pmatrix} 5 \\ 31 \end{pmatrix}$	$\begin{pmatrix} 6 \\ 32 \end{pmatrix}$	$\begin{pmatrix} 7 \\ 33 \end{pmatrix}$
$\begin{pmatrix} 5 \\ 57 \end{pmatrix}$	$\begin{pmatrix} 6 \\ 58 \end{pmatrix}$	$\begin{pmatrix} 7 \\ 59 \end{pmatrix}$
$\begin{pmatrix} 5 \\ 85 \end{pmatrix}$	$\begin{pmatrix} 6 \\ 86 \end{pmatrix}$	$\begin{pmatrix} 7 \\ 88 \end{pmatrix}$
$\begin{pmatrix} 31 \\ 42 \end{pmatrix}$	$\begin{pmatrix} 32 \\ 43 \end{pmatrix}$	$\begin{pmatrix} 33 \\ 44 \end{pmatrix}$
$\begin{pmatrix} 31 \\ 98 \end{pmatrix}$	$\begin{pmatrix} 32 \\ 99 \end{pmatrix}$	$\begin{pmatrix} 33 \\ 100 \end{pmatrix}$
$\begin{pmatrix} 42 \\ 57 \end{pmatrix}$	$\begin{pmatrix} 43 \\ 58 \end{pmatrix}$	$\begin{pmatrix} 44 \\ 59 \end{pmatrix}$
$\begin{pmatrix} 42 \\ 85 \end{pmatrix}$	$\begin{pmatrix} 43 \\ 86 \end{pmatrix}$	$\begin{pmatrix} 44 \\ 88 \end{pmatrix}$
$\begin{pmatrix} 42 \\ 98 \end{pmatrix}$	$\begin{pmatrix} 43 \\ 99 \end{pmatrix}$	$\begin{pmatrix} 44 \\ 100 \end{pmatrix}$
$\begin{pmatrix} 57 \\ 98 \end{pmatrix}$	$\begin{pmatrix} 58 \\ 99 \end{pmatrix}$	$\begin{pmatrix} 59 \\ 100 \end{pmatrix}$
$\begin{pmatrix} 85 \\ 98 \end{pmatrix}$	$\begin{pmatrix} 86 \\ 99 \end{pmatrix}$	$\begin{pmatrix} 88 \\ 100 \end{pmatrix}$

Et par conséquent

(φ_2, δ_2)

$\begin{pmatrix} (5) & F_3 & \phi & J & \text{Aller} & \phi & \phi & \phi & \phi \end{pmatrix}$	
$\begin{pmatrix} (31) & F_1 & \phi & J & \text{Chercher} & \phi & \phi & \phi & \phi \end{pmatrix}$	
$\begin{pmatrix} (42) & F_3 & \phi & J & \text{Aller} & \phi & \phi & \phi & \phi \end{pmatrix}$	
$\begin{pmatrix} (57) & F_1 & \phi & J & \text{Aller} & \phi & \phi & \phi & \phi \end{pmatrix}$	
$\begin{pmatrix} (85) & F_1 & \phi & J & \text{Essayer} & \phi & \phi & \phi & \phi \end{pmatrix}$	
$\begin{pmatrix} (98) & F_3 & \phi & J & \text{Aller} & \phi & \phi & \phi & \phi \end{pmatrix}$	
$\begin{pmatrix} (6) & F_3 & \phi & J & \text{Trouver} & \phi & * & L & \text{Roi} \end{pmatrix}$	
$\begin{pmatrix} (32) & F_3 & \phi & J & \text{Voir} & \phi & * & L & \text{Roi} \end{pmatrix}$	
$\begin{pmatrix} (43) & F_3 & \phi & J & \text{F. Couron.} & \phi & * & L & \text{Roi} \end{pmatrix}$	
$\begin{pmatrix} (58) & F_3 & \phi & J & \text{Trouver} & \phi & * & L & \text{Roi} \end{pmatrix}$	
$\begin{pmatrix} (86) & F_3 & \phi & J & \text{Rétablir} & \phi & * & L & \text{Roi} \end{pmatrix}$	
$\begin{pmatrix} (99) & F_3 & \phi & J & \text{Trouver} & \phi & * & L & \text{Roi} \end{pmatrix}$	
$\begin{pmatrix} (7) & F_4 & \phi & \text{Roi} & \epsilon & \phi & \text{de} & \phi & \text{France} \end{pmatrix}$	
$\begin{pmatrix} (33) & F_4 & \phi & \text{Roi} & \epsilon & \phi & \text{de} & \phi & \text{France} \end{pmatrix}$	
$\begin{pmatrix} (44) & F_4 & \phi & \text{Roi} & \epsilon & \phi & \text{de} & \phi & \text{France} \end{pmatrix}$	
$\begin{pmatrix} (59) & F_4 & \phi & \text{Roi} & \epsilon & \phi & * & \phi & \text{Charles VII} \end{pmatrix}$	
$\begin{pmatrix} (88) & F_4 & \phi & \text{Roi} & \epsilon & \phi & * & \phi & \text{Charles VII} \end{pmatrix}$	
$\begin{pmatrix} (100) & F_4 & \phi & \text{Roi} & \epsilon & \phi & \text{de} & \phi & \text{France} \end{pmatrix}$	

Résultat que l'on peut synthétiser ainsi

(φ_2, δ_2)	J	$\begin{pmatrix} \text{Aller} \\ \text{Chercher} \\ \text{Essayer} \end{pmatrix}$	ϕ	J	$\begin{pmatrix} \text{Trouver} \\ \text{Voir} \\ \text{F. Couron.} \\ \text{Rétablir} \end{pmatrix}$	$*$	Roi	$\begin{pmatrix} \text{Roi} \epsilon \\ \text{de France} \\ \text{Charles VII} \end{pmatrix}$
-------------------------	-----	---	--------	-----	---	-----	--------------	---

L'analyse aboutit à définir 29 domaines répondant aux mêmes conditions de formation.

4. Rapports entre les domaines

L'application des algorithmes Alg. 6 et Alg. 7 aux domaines précédemment définis aboutit au tableau ci-après. Les domaines ont été ordonnés de

manière à ce que les inclusions et intersections ($\supset$, $\subset$, $\cap$) soient regroupées : on aboutit ainsi à des regroupements de domaines (ou *hyperdomaines*) caractérisés par le fait que tous les domaines d'un hyperdomaine ont au moins une origine commune.

On aboutit ainsi à un ensemble de 10 hyperdomaines auquel on peut attribuer une dénomination indiquant leur fonction dans le discours, soit :

- 11, 12, 13 = naissance
- 21, 22, 23, 24, 25, 26, 27, 28 = réception de l'ordre
- 31 = contenu de l'ordre
- 41, 42, 43, 44 = départ au combat
- 51 = obtention d'une aide
- 61, 62 = sacre du roi
- 71 = combat
- 81, 82, 83 = salut du pays
- 91 = expulsion de l'ennemi
- 101, 102, 103, 104, 105 = capture et mort

	11	12	13	21	22	23	24	25	26	27	28	31	41	42	43	44	51	61	62	71	81	82	83	91	101	102	103	104	105
11																													
12																													
13																													
21																													
22																													
23																													
24																													
25																													
26																													
27																													
28																													
31																													
41																													
42																													
43																													
44																													
51																													
61																													
62																													
71																													
81																													
82																													
83																													
91																													
101																													
102																													
103																													
104																													
105																													

Rapports entre
les domaines

ANNEXE IV

ÉTUDE DES MARQUES DE DÉTERMINATION DANS F

par Catherine FUCHS

Cette classification des marques de déterminations du lexème verbal, dont chaque combinaison assigne une forme *F* à tout énoncé *E*, s'inspire de Jakobson. Elle appelle quelques remarques. Nous nous proposons d'examiner ici plus en détail ces différentes marques, le nombre de valeurs que chacune d'entre elles peut prendre, sous quelles formes morphologiques et/ou classes de mots elles se trouvent attestées sur la chaîne, et quels types de repérages syntaxiques permettront, à un premier niveau d'analyse, de les isoler en vue de l'enregistrement des formes de l'énoncé associées aux énoncés minimaux; puis nous donnerons quelques brèves indications sur une recherche ultérieure visant à intégrer ces déterminations dans des systèmes (= réseaux de valeurs) syntaxico-sémantiques, ce qui constituerait un essai de mise sur pied d'une sémantique formelle⁽¹⁾.

Nous suggérons de distinguer d'une part les déterminations dont les valeurs sont portées directement par le verbe principal (ce que traditionnellement on appelle « sémantisme du lexème verbal » et « conjugaison du verbe ») et d'autre part celles qui sont marquées sur la chaîne par un ou plusieurs morphèmes distincts du verbe principal. Reprenons cette distinction :

1. Marques portées par le verbe principal

a) Le « sémantisme du lexème verbal ».

Nous entendons par là des valeurs aspectuelles attachées à la notion du verbe (sous sa forme nue, c'est-à-dire pas encore asserté, ni pris dans un réseau de valeurs modo-temporelles).

(1) Tout cet exposé prend directement appui sur les développements actuels des recherches de A. CULIOLI. Il est indispensable, sur ce point, de se référer à l'article « La formalisation en linguistique » paru dans le n° 9 des *Cahiers pour l'Analyse* (été 1968).

Les deux valeurs fondamentales seront : le *processus* (exemple : « faire », « apprendre ») et l'*état* (exemple : « savoir »); indiquons très rapidement qu'un des critères de distinction entre processus et état est le fonctionnement de la négation : alors que le verbe d'état nous place dans le cadre d'une logique bivalente (ne pas savoir = ignorer; ne pas ignorer = savoir), le processus connaît, à côté de la négation forte, un inverseur (faire, défaire) dont la négation (ne pas défaire) ne ramène pas au processus initial (faire). Au terme d'une analyse plus fine, on distinguerait des sous-classes, comme : processus suspendu (exemple : « attendre »), propriété, produit... On peut ainsi espérer construire une sorte de dictionnaire où tout lexème verbal serait indexé en fonction de ces classes aspectuelles de procès (*procès* étant ici employé comme terme générique, recouvrant à la fois processus et état). Notons au passage qu'à ce premier type de valeurs aspectuelles viendra s'en ajouter un second que l'on dégage dans l'analyse des temps du verbe asserté, dans un énoncé donné. Une étude ultérieure devrait permettre d'établir les lois de la combinatoire aspectuelle qui joue entre ces deux types; on pourrait ainsi calculer (au sens de calcul formel) les valeurs finales résultant de la mise en relation, au moment de l'énonciation, des valeurs aspectuelles provenant d'opérations de niveaux très différents.

b) La « conjugaison ».

À un premier stade d'analyse on dégagera les valeurs traditionnelles de temps, de mode et d'aspect, soit par une étude morphologique des désinences associées à la base du lexème verbal, dans le cas des temps simples, par exemple, soit par des règles syntaxiques de regroupements binaires (de type : auxiliaire + verbe principal) pour les temps composés ou la voix passive, par exemple. Cette étape se trouve déjà entièrement expérimentée et automatisée au CETA de Grenoble, où l'on distingue sous le terme de « variables » le temps, la voix, le mode, et sous le terme de « valeurs de ces variables » le présent, l'imparfait, l'indicatif, le subjonctif, l'actif, le passif, etc. Dans un second moment de l'analyse, on s'attachera à raffiner ces notions : on distinguera à l'intérieur de chacune de ces valeurs traditionnelles un certain nombre de nouvelles valeurs à la fois plus fines et plus puissantes, appartenant à la théorie formelle de l'analyse, et se regroupant dans un système unique modalo-aspecto-temporel.

b 1) *Le temps*. Pour dégager les nouvelles valeurs spécifiques de chaque temps, il conviendrait d'effectuer une analyse linguistique poussée de l'organisation du système verbal de la langue sur laquelle on travaille (ici le Français), et aussi de posséder un schéma général d'organisation assez puissant pour pouvoir s'appliquer à d'autres langues. La plupart des notions que nous présentons ici sont empruntées aux études de A. CULIOLI. Disons, de façon très succincte, que nous prévoyons de dégager pour chaque temps (au sens de « tense ») des valeurs de repère sur l'axe des temps (« time »), des valeurs aspectuelles (perfectif, imperfectif, ponctuel...) des valeurs modales (actualisation, position du sujet par rapport à l'énonciation...) et des emplois spécifiques par lesquels un opérateur donné, auquel on attribue

certaines valeurs (par exemple l'imparfait en Français : « hier il pleuvait ») se trouve parfois utilisé pour renvoyer à une toute autre valeur (exemple : l'hypothétique « s'il pleuvait, je ne sortirais pas »).

b 2) *Le mode*. On construira de même des réseaux de valeurs pour les modes, qui permettront d'indexer de façon rigoureuse et opératoire l'indicatif par rapport au subjonctif à l'impératif, au conditionnel et à l'infinitif. Là encore des valeurs aspectuelles et modales permettront de rendre compte des différents emplois de l'infinitif ou du participe, par exemple.

b 3) *La voix*. Il en va de même pour la voix. Soit par exemple la forme verbale « il est fatigué ». Il est clair que, suivant le contexte, elle peut prendre des valeurs différentes : « il est fatigué par ce long voyage » s'interprétera comme le produit (ou résultat) du processus : « ce long voyage le fatigue »; mais on peut aussi considérer ce produit en soi, comme un état : « il est dans un état de fatigue... »; enfin on peut prendre cette forme comme l'attribution d'une propriété « il est vite fatigué = il a la propriété de se fatiguer vite, pour un rien ». Si donc l'on arrive à donner des valeurs du système verbal une représentation topologique, on se donnera par là même la possibilité de dégager par une analyse unique les valeurs de modalités de temps, de mode et d'aspect.

2. Les marques portées par des morphèmes distincts du verbe principal

Ces marques sont essentiellement des marques de modalités et aussi d'aspect. Pour la classification des modalités, nous reprendrons la distinction posée par Culioli (1968, p. 112) : « modalité sera entendu au quadruple sens de : 1) affirmation ou négation, injonctif... 2) certain, probable, nécessaire... 3) appréciatif : il est triste que... 4) pragmatique, en particulier mode allocutoire, causatif, bref, ce qui implique une relation entre sujets ». Ces quatre types de modalités, que nous noterons *M1*, *M2*, *M3* et *M4*, comporteront chacun un certain nombre de valeurs qui peuvent se trouver attestées sur la chaîne sous des formes extrêmement variables; la première tâche dans l'élaboration d'une grammaire de reconnaissance en vue de l'enregistrement automatique des énoncés consiste donc à les repérer. Donnons un bref relevé (non exhaustif, d'ailleurs) des classes de mots sous lesquels on peut les rencontrer.

a) *Des verbes*

Par exemple : « il peut venir » s'enregistrera comme : *E* = il venir ϕ et dans *F* un opérateur renvoyant soit à *M2*, avec la valeur « possible » (peut-être viendra-t-il, peut-être ne viendra-t-il pas), soit à *M4*, avec la valeur « portant sur le sujet », que nous représentons par $\rightarrow S$ (il a la permission de venir), par opposition à la valeur « portant sur le sujet » $S \rightarrow$ (il veut venir).

Indiquons comme ligne de recherche future qu'il doit être possible d'analyser ainsi de nombreux verbes, comme par exemple les causatifs (« Pierre fait courir Jean = Pierre fait que Jean se trouve dans la situation où il court »); à la limite il

conviendrait de décomposer également ainsi les prédicats à trois arguments, dans la mesure où ils comportent un premier sujet accomplissant une action qui porte sur un second sujet (« Pierre donne un livre à Paul = Pierre fait que (*M4*) Paul a un livre ou : un livre est à Paul »).

b) *Des locutions verbales*

Qu'il doit être facile d'indexer dans la mesure où elles sont en nombre relativement peu élevé; par exemple : il est triste que, il est heureux que = *M3*; il est possible que, il est probable que = *M2*.

c) *Des particules*

Marquant ce que nous avons appelé « le statut » c'est-à-dire l'assertion ou *M1*. L'affirmation se caractérise par une marque zéro, la négation par la particule *ne*, suivie de : *pas*, *jamais*... (qui par eux-mêmes ne sont ni positifs ni négatifs); des règles syntaxiques permettent de regrouper ces deux éléments d'un même signifiant discontinu.

d) *Des adverbes*

L'analyse morphologique donne pour seule indication l'appartenance d'une unité à la classe adverbe; il convient donc d'établir des sous-classes et notamment de distinguer

— Les adverbes qui fonctionnent comme opérateurs de modalités :

Exemple : *M1* : oui, non; *M2* : probablement, certainement; *M3* : malheureusement; *M4* : obstinément, volontairement.

— Les adverbes qui fonctionnent comme marques d'aspects :

Exemple : duratif : « tu es encore là depuis tout à l'heure », « quand je l'ai revu il avait toujours l'air aussi triste »; itératif : « il m'a encore menti ».

Ces adverbes seront enregistrés dans *F* comme opérateurs portant sur la totalité de l'énoncé *E*, contrairement aux adverbes de localisation spatio-temporelle qui, en tant que circonstanciés, seront enregistrés comme *N2* dans *E* [note : pour une étude plus approfondie sur les différents types d'adverbes, voir la thèse de C. Fuchs (en préparation) : « De quelques adverbes en Français, en vue d'un traitement automatique de reconnaissance »].

Parmi les marques de détermination portées par des morphèmes extérieurs au verbe principal, il faut enfin noter l'émphase et l'exclamation, manifestées sur la chaîne par les formes : « c'est que... » « c'est... qui... »; on les considérera comme des opérations doubles résultant d'une modalité mixte : assertion adversative et explicative; on les distinguera soigneusement du présentatif « c'est... qui (que)... » qui sert à insister sur l'un des arguments du prédicat (il est intéressant de noter que cette opération est impossible à effectuer sur le prédicat lui-même).

Il nous reste une remarque à faire sur ce bref exposé des marques de détermination à enregistrer dans *F* : nous nous sommes basés sur la distinction entre

verbe principal (enregistré dans *E*) et verbe opérateur (enregistré dans *F*). Il convient de se demander à quel moment de l'analyse et par quels moyens on opère cette distinction. Nous proposons ici deux solutions d'enregistrement, qui ne sont d'ailleurs pas mutuellement exclusives : *a*) les verbes et adverbess qui fonctionnent comme opérateurs de modalités étant en nombre fini (et relativement restreint surtout pour *M* 1, *M* 2 et *M* 3), on peut envisager un indexage forme par forme dans un dictionnaire, avec la référence : opérateur de *M* 1, *M* 2... et en spécifiant éventuellement la ou les valeurs de *M* 1, *M* 2... Un tel repérage aura l'avantage de permettre de placer l'opérateur immédiatement à l'extérieur de *E* et de l'enregistrer dans *F*; *b*) ces opérateurs (à l'exclusion peut-être de *M* 1) constituant des jugements qui modifient l'énoncé c'est-à-dire la fonction de prédication qui unit *V* à *N*₁ et *N*₂, ils sont susceptibles d'une paraphrase (d'ailleurs très souvent attestée sur la chaîne) du type : nominalisation du verbe + être + adjectivation de l'opérateur, ce qui constitue un énoncé canonique construit à l'aide de la copule : *N*₁ *ε* *N*₂ (adj); exemple : «il viendra certainement», «il est certain qu'il viendra» peut s'enregistrer comme : *E*₁ = il venir ϕ *E*₂ = sa venue ϵ certaine. On peut donc envisager dans un premier stade d'enregistrer ces opérateurs à l'intérieur de *E*.

Pour nous résumer, nous dresserons deux tableaux récapitulatifs :

Ce deuxième tableau donne quelques indications supplémentaires (qui, faute de place, resteront allusives) sur la façon dont nous pensons pouvoir pousser l'analyse linguistique des réseaux de valeurs en vue de l'élaboration d'une sémantique formelle. Comme on le voit, ceci permettrait de traiter aussi bien les opérations faites sur *V* (valeurs que nous enregistrons dans *F*) que les opérations effectuées sur *N*₁ et *N*₂ (dans *E*). Toutes s'inscriraient dans un même cadre théorique général. Indiquons que déjà un travail de formalisation logique de ce cadre théorique est en cours d'élaboration : les modalités *M* 1 et *M* 2, les concepts linguistiques de « notion » et de « lexis », ainsi que les opérations de « fléchage » (ces chevaux courent dans le pré), « extraction » (il y a une pomme sur la table) et « parcours » (le cheval est un animal à quatre pattes) ont fait l'objet d'une étude de Dupraz et Rouault ⁽¹⁾ basé sur le langage des classes (classes distributives et classes collectives selon Lesniewski).

Nous regrettons de n'avoir pu donner ici, faute de place, que des indications extrêmement brèves sur les directions de recherche dans lesquelles nous pensons qu'il serait fructueux de se diriger.

(1) Document CETA, n° G 2400 A, juillet 1968.

Valeurs dégagées par l'analyse morphologico-syntaxique	TEMPS	MODE	VOIX	ASPECTS	MODALITÉS	EMPHASE
Classes de mots et/ou marques morphologiques relevées sur la chaîne						
BASE du lexème verbal				Processus État		
DÉSINENCES du lexème verbal	Simple et Composés	Indicatif Subjonctif Conditionnel Impératif	Actif Passif			
Verbes secondaires					<i>M</i> 2- <i>M</i> 3 <i>M</i> 4	
Particules et adverbess					<i>M</i> 1- <i>M</i> 2 <i>M</i> 3- <i>M</i> 4	
Tournures						Emphase Exclamation

Valeurs (sémantique formelle)	Opérations sur V Système verbal (= «time» + aspects + modalités)	Opérations sur N_1, N_2
Valeurs dégagées par l'analyse morphologico-syntaxique		
TEMPS	×	
MODE	×	
VOIX	×	
ASPECTS	×	
MODALITÉS	×	
EMPHASE	×	
N_1 et * N_2		Fléchage. Extraction. Parcours
ϵ * N_2		Propriété + Classe
p N_2		Localisation
Présentatif		Extraction

ANNEXE V

DÉFINITION DES PRINCIPAUX SYMBOLES UTILISÉS

L'ordre dans lequel les symboles sont commentés est celui de leur apparition dans l'ensemble de ce travail.

1. Éléments constitutifs du procès de langage

Le symbolisme

$$A \xrightarrow[\text{R}]{\substack{\{\mathcal{L}\} \\ \text{D}}} B$$

s'interprète : A produit en direction de B le discours D dans la langue $\mathcal{L}$, à propos du « référent » R .

A et B représentent les *places* du procès, et non des unités biologiques ou psychologiques.

R représente l'*objet du discours*, c'est-à-dire ce à propos de quoi des propriétés sont construites dans le discours, et non un ensemble de stimuli situationnels.

2. Formations imaginaires intervenant dans le procès

Le symbolisme

$$I_X(Y)$$

s'interprète : l'image de Y à la place de X
avec

$$X = A \text{ ou } B$$

$$Y = A, B, R \text{ ou une formation imaginaire } [I_X(Y)] \text{ déjà constituée.}$$

On peut ainsi engendrer par exemple :

$$I_A(A), I_A(I_B(A)), I_A(I_B(R))$$

Nous laissons en suspens la question de savoir si

- toutes les expressions qu'on peut ainsi engendrer sont douées de sens,
- s'il existe une règle d'arrêt à l'égard de la ré-introduction d'une formation imaginaire déjà constituée dans une nouvelle formation.

3. Conditions de production,

Le symbolisme

$$I_x^n(A, B)$$

s'interprète : l'état n des conditions de production du discours $\mathcal{D}_x$ que A produit en direction de B .

Cet état I_x^n est, dans l'état actuel de cette recherche, défini comme un vecteur constitué par les états correspondants des formations imaginaires suivantes :

$$I_x^n(A, B) = \begin{pmatrix} I_A^n(A) \\ I_A^n(B) \\ I_A^n(R) \\ I_A^n(I_B^n(A)) \\ I_A^n(I_B^n(B)) \\ I_A^n(I_B^n(R)) \end{pmatrix}$$

On supposera le plus souvent A et B assignés, et on notera simplement I_x^n .

4. Processus de production

Le symbolisme $\Delta_x^n(A, B)$

s'interprète : l'état du processus de production du discours $\mathcal{D}_x$ correspondant à I_x^n .

Le processus Δ_x^n est défini comme l'effet, dans un système linguistique naturel donné, soit $\mathcal{L}$, de I_x^n : autrement dit, Δ_x^n désigne les opérations de *combinaison-substitution* à travers lesquelles $\mathcal{D}_x$ se trouve réalisé.

5. Transformation des conditions de production

Le symbolisme

$$I_x^n * \Delta_j^i \rightarrow I_x^{n+1}$$

s'interprète : l'effet d'un processus de production Δ_j^i sur un état donné des conditions I_x^n , cet effet consistant en une transformation de cet état.

Remarque sur les points 3, 4 et 5

Ces points ne constituent que l'esquisse d'une théorie du discours en tant que procès de langage. Plusieurs questions, en particulier celle de la combinaison à dominante des conditions des production d'un discours, restent à traiter.

6. Corpus de surfaces discursives

Le symbolisme

$$C_x = \mathcal{D}_{x1}, \mathcal{D}_{x2}, \dots, \mathcal{D}_{xn}$$

s'interprète :

on appelle C_x (corpus lié au discours $\mathcal{D}_x$) un ensemble de réalisations empiriquement attestées du discours $\mathcal{D}_x(A, B)$ considéré comme représentatif de $I_x^n(A, B)$.

L'analyse automatique proposée a pour but, étant donné C_x , de déterminer Δ_x .

7. Opérateurs de dépendance

On appelle opérateur de dépendance (soit la désignation générale ψ) le terme qui connecte deux énoncés élémentaires (voir définition ci-dessous), de telle sorte que l'un de ces énoncés dépende de l'autre ($E_i \psi E_j$)

$$\psi = \{ \delta_1, \delta_2, \varphi_1, \dots, \varphi_n, \varphi_\alpha, \alpha \}$$

- | | |
|-----------------------------|--|
| δ_1 | se lit : E_j détermine le terme N_1 de E_i |
| δ_2 | se lit : E_j détermine le terme $N_{2/3}$ de E_i |
| $\varphi_1 \dots \varphi_n$ | se lit : E_j est lié à E_i par une connexion (coordination ou subordination) non-déterminative. |
| φ_α | se lit : E_j est postérieur à E_i dans la séquence (relation d'ordre pouvant intervenir lorsqu'il n'existe aucune relation à partir de laquelle cette relation d'ordre peut être déduite). |
| α | se lit : E_i et E_j pris ensemble permettent de reconstituer une relation sémantique à trois places. |

8. Ensemble des énoncés élémentaires

On note cet ensemble $\mathcal{E}_x = \{E_i, E_1, \dots, E_j, \dots, E_n\}$

Tout énoncé E_j appartenant à $\mathcal{E}_x$ s'écrit sous la forme

$$E_j = \langle F_i, D_1, N_1, V, ADV, PP, D_2, N_{2/3} \rangle$$

avec les huit classes morpho-syntaxiques suivantes :

F_i = forme de l'énoncé E_j , intégrant la voix, le temps, le mode, la modalité et l'emphase.

D_1 = déterminant du sujet N_1 de l'énoncé E_j

N_1 = sujet de l'énoncé E_j

V = verbe

ADV = adverbe

PP = préposition

D_2 = déterminant du complément $N_{2/3}$ de l'énoncé E_j

$N_{2/3}$ = complément direct, indirect ou circonstanciel.

9. Ensemble de relations binaires entre énoncés

On note cet ensemble

$$\mathcal{B}_x = \{b_1 \dots b_k \dots b_q\},$$

tel que

$$b_k = E_i \psi_n E_j \quad (\text{voir } \S 7)$$

10. Vecteur booléen associé à un couple d'énoncés

Soit deux énoncés formant le couple (E_i, E_j) .

On peut associer au couple (E_i, E_j) un vecteur booléen, noté π , tel que deux termes identiques dans la même classe morpho-syntaxique se traduisent par le chiffre 1 dans π , à la place correspondante, et deux termes différents par le chiffre 0.

11. Pondération du vecteur booléen π associé à (E_i, E_j)

Soit $\pi(E_i, E_j) = \alpha_1 \dots \alpha_k \dots \alpha_8$, avec $\alpha_k = 0$ ou 1.

On pose des coefficients liés à chaque classe morpho-syntaxique, soit

$$p_1 \dots p_k \dots p_8$$

et on calcule

$$p(E_i, E_j) = \alpha_1 p_1 \dots \alpha_k p_k \dots \alpha_8 p_8$$

Remarque : L'algorithme Alg. 2 permet de tenir compte du cas où le corpus contient un énoncé E_x tel que

$$\frac{p(E_i, E_x) + p(E_x, E_j)}{2} > p(E_i, E_j)$$

On aboutit ainsi à une proximité de (E_i, E_j) rapportée à $\mathcal{E}_x$, soit $P(E_i, E_j)$ la valeur qui lui correspond.

12. Zone de similitude

Soit deux relations binaires b_x et b_y , comportant le même opérateur de dépendance ψ_n :

soit

$$b_x = E_i \psi_n E_k$$

$$b_y = E_j \psi_n E_m$$

On dira que E_i, E_j, E_k, E_m constituent une zone de similitude si, étant donné $P_1(E_i, E_j)$ et $P_2(E_k, E_m)$ (cf. § 11), on a

$$\frac{P_1 + P_2}{2} > p_x, \quad p_x \text{ étant une borne antérieurement fixée.}$$

13. Chaîne de similitude et domaine sémantique

On appelle *chaîne de similitude* une suite de n zones de similitude imbriquées l'une dans l'autre, n étant supérieur ou égal à 1.

On note C^* l'ensemble des chaînes de similitude correspondant à un corpus $\mathcal{C}_x$.

Deux chaînes sont d'une même catégorie si elles sont de même longueur et si elles comportent les mêmes opérateurs de dépendance aux mêmes places.

Un domaine sémantique (D_i) regroupe l'ensemble des chaînes d'une même catégorie, homogènes entre elles (cf. p. 99, déf. de l'homogénéité). Un domaine sémantique apparaît ainsi constitué par un ensemble de séquences sémantiquement superposables.

14. Origine d'une séquence, relation entre deux séquences, relations entre deux domaines

Voir p. 104, 106 et 107 la définition des différents symboles utilisés.

BIBLIOGRAPHIE

(Ouvrages cités)

- ACKERMANN (W.), *Représentation et assimilation de connaissances*. Paris, C.E.R.P., 1956, Ronéotypé.
- BENVENISTE (E.), *Problèmes de linguistique générale*. Paris, Gallimard, 1966.
- BOURDIEU (P.), *Un art moyen*. Paris, Éditions de Minuit, 1965.
- CARTWRIGHT (D. P.), L'analyse du matériel qualitatif, in FESTINGER (L.), KATZ (D.), Eds : *Les méthodes de recherche dans les sciences sociales*. New York, Dryden Press, 1953. Trad. française, Paris, P.U.F., 1963, 2^e éd.
- CHOMSKY (N.), Syntaxe logique et sémantique : leur pertinence linguistique. *Langages*, 1966, n° 2, 42-57.
- CULIOLI (A.), La formalisation en linguistique. *Cahiers pour l'analyse*, 1968, n° 9, 106-117.
- GROS (R. C.), GARDIN (J. C.), LÉVY (F.), *L'automatisation des recherches documentaires*. Paris, Gauthier-Villars, 1964.
- DOLEŽEL (L.), Un modèle statistique de codage linguistique. *Études de linguistique appliquée*, 1964, n° 3, 51-63.
- DUCHOT (O.), Logique et linguistique. *Langages*, 1966, n° 2, 3-30.
- GURVITCH (G.), *Traité de sociologie*. Paris, P.U.F., 1958.
- HARRIS (Z.), *Discourse analysis*. La Haye, Mouton and Co, 1963.
- IRIGARAY (L.), Négation et transformation négative dans le langage des schizophrènes. *Langages*, 1967, n° 5, 84-98.
- JAKOBSON (R.), *Essais de linguistique générale*. Paris, Éditions de Minuit, 1963.
- LEVI-STRAUSS (C.), *Le cru et le cuit*. Paris, Plon, 1964.
- MERTON (R. K.), *Social theory and social structure*. Glencoe, The Free Press, 1957. Trad. française : *Éléments de théorie et de méthodologie sociologique*. Paris, Plon, 1965.
- MOSCOVICI (S.), PLON (M.), Les situations-colloques : observations théoriques et expérimentales. *Bull. Ps.*, 1966, XIX, n° 8-12, 702-722.
- MOUNIN (G.), *Les problèmes théoriques de la traduction*. Paris, Gallimard, 1963.
- PAGÈS (R.), Image de l'émetteur et du récepteur dans la communication. *Bull. Ps.*, 1955 VIII, n° 7-8, 452-460.
- SAUSSURE (F. de), *Cours de linguistique générale*. Paris, Payot, 1915, 3^e éd., 1962.
- SOLA-POOL (I. de), *Trends in content analysis*. Urbana, Univ. Illinois Press, 1959.
- STONE (Ph. J.), DUNPHY (D. C.), SMITH (M. S.), OGILVIE (D. M.). — *The General Inquirer. A computer approach to content analysis*. Cambridge Mass., M.I.T. Press., 1966.
- ULLMANN (S.), *Précis de sémantique française*, Berne, Francke, 1959, 2^e éd.

IMPRIMERIE NOUVELLE, ORLÉANS (O.P.L.A.C.L. 31.6427). — 5980 - 10/1969.

Dépôt légal : n° 6302 (4^e trimestre 1969).

Imprimé en France.

