

*Université Paris Nanterre
Année Universitaire 2024 – 2025*

ÉTUDE HISTORIQUE ET COMPARATIVE DE MÉTHODES DE SÉMANTIQUE DISTRIBUTIONNELLE

Lydia Belhoul, Lucile Bessac, Solomiia Korol

Sous la direction de M. Hugo Dumoulin

AU COMMENCEMENT, IL Y AVAIT PÊCHEUX

Enquête sur un moment clé de l'histoire du TAL en France

DOMAINES SÉMANTIQUES

SYNONYMIE CONTEXTUELLE

FORMULATION
LINGUISTIQUE RIGOUREUSE




Analyse Automatique
du Discours
Michel Pêcheux
1969

ALGORITHME PIONNIER DE CLUSTERISATION SÉMANTIQUE


LA THÉORIE ...

“Le roi qui est anglais arrive sur le trône avec sa femme”



ÉNONCÉS ÉLÉMENTAIRES

Arguments
essentiels du verbe



RELATIONS PHI & DELTA

Coordination,
subordination ...



GRAPHES

Représentation

“Le roi est anglais”

“Le roi arrive sur le trône”

“La femme du roi arrive sur le trône”

...

... ET LA PRATIQUE !

1

Spacy : Fonctionnalités manquantes

... ET LA PRATIQUE !

1

Spacy : Fonctionnalités manquantes

2

Stanza : Résolution de la coréférence

... ET LA PRATIQUE !

1

Spacy : Fonctionnalités manquantes

2

Stanza : Résolution de la coréférence

3

GrewPy : Temps de calcul et nombre de cas particuliers

... ET LA PRATIQUE !

1

Spacy : Fonctionnalités manquantes

2

Stanza : Résolution de la coréférence

3

GrewPy : Temps de calcul et nombre de cas particuliers

**Algorithme
complexe**

... ET LA PRATIQUE !

1

Spacy : Fonctionnalités manquantes

2

Stanza : Résolution de la coréférence

3

GrewPy : Temps de calcul et nombre de cas particuliers

**Algorithme
complexe**

**Pas de machine
adaptée**

... ET LA PRATIQUE !

1

Spacy : Fonctionnalités manquantes

2

Stanza : Résolution de la coréférence

3

GrewPy : Temps de calcul et nombre de cas particuliers

**Algorithme
complexe**

**Pas de machine
adaptée**

**Pas d'outils
adaptés**

... ET LA PRATIQUE !

1

Spacy : Fonctionnalités manquantes

2

Stanza : Résolution de la coréférence

3

GrewPy : Temps de calcul et nombre de cas particuliers

Algorithme
complexe

Pas de machine
adaptée

Pas d'outils
adaptés

La motivation
qui baisse

... ET LA PRATIQUE !

1

Spacy : Fonctionnalités manquantes

2

Stanza : Résolution de la coréférence

3

GrewPy : Temps de calcul et nombre de cas particuliers

Algorithme
complexe

Pas de machine
adaptée

Pas d'outils
adaptés

La motivation
qui baisse

De - en - de temps
pour le projet

AU COMMENCEMENT, IL Y AVAIT PÊCHEUX

Enquête sur un moment clé de l'histoire du TAL en France

DOMAINES SÉMANTIQUES

SYNONYMIE CONTEXTUELLE

FORMULATION
LINGUISTIQUE RIGOUREUSE



Analyse Automatique
du Discours
Michel Pêcheux
1969

ALGORITHME PIONNIER DE CLUSTERISATION SÉMANTIQUE

PROBLÉMATIQUE



LE CONTEXTE DE COOCCURRENCE

DIFFÉRENTS CONTEXTES

PROBLÉMATIQUE



LE CONTEXTE DE COOCCURRENCE

DIFFÉRENTS CONTEXTES



DIFFÉRENTS CLUSTERS

PROBLÉMATIQUE



LE CONTEXTE DE COOCCURRENCE

DIFFÉRENTS CONTEXTES



DIFFÉRENTS CLUSTERS



QUELLES REPRÉSENTATION SÉMANTIQUES ?

PROBLÉMATIQUE



LE CONTEXTE DE COOCCURRENCE

DIFFÉRENTS CONTEXTES



DIFFÉRENTS CLUSTERS



QUELLES REPRÉSENTATION SÉMANTIQUES ?

Quel est l'impact du choix du contexte de cooccurrence sur le type de regroupement lexical généré, de quel type sont ces clusters et qu'apportent ces différentes méthodes ?

CONTEXTE

Structuration automatique du
lexique dans l'analyse de
corpus.



1970s

Analyse
Automatique du
Discours
Pêcheux



2000s

Cooccurrence
"simple"
Evert



2010s

Word2Vec
Gensim
Mikolov

CONCRÈTEMENT ?

**Comparaison
de 3
méthodes**

**Évaluation de la
cohérence de
chaque cluster**



CORPUS PARLAMINT 2018

01

Corpus
multilingue
structuré TEI/XML

02

362 documents,
>18M tokens

03

Annotations
morpho-
syntaxiques
enrichies



MÉTHODOLOGIE



Etape 1

Pre-traiter le corpus, extraire des entités élémentaires

Etape 2

Trouver les relations syntaxiques

Etape 3

Faire la réduction de dimension et la clusterisation

Etape 4

Evaluer et comparer

Etape 5

Décrire tout dans le rapport

RESSOURCES ET OUTILS

OUTILS

- GOOGLE DRIVE
- GITHUB
- OVERLEAF
- DISCORD

LANGAGES

- PYTHON
- R

LIBRAIRIES

- GENSIM
- GREWPY
- WORDSPACE
- FACTOEXTRA
- SPACY
- TORCH
- NUMPY
- SEABORN
- PANDAS
- SCIKIT-LEARN

COOCCURRENCE SYNTAXIQUE



Comment ça marche ?

GÉNÉRATION
DU CONLL-U



COOCCURRENCE SYNTAXIQUE



Comment ça marche ?

GÉNÉRATION
DU CONLL-U



ÉNONCÉ ÉLÉMENTAIRE

D₁ N₁ V ADV F_i p D₂ N_{2/3}

EXTRACTION AVEC GREWPTY

```
pattern = """pattern {
    X-[nsubj|obj|iobj|nsubj:pass|cop]->Y;
    Y-[det]->Z;
    X-[aux:pass|aux:tense]->W;
}"""
```

COOCCURRENCE SYNTAXIQUE

Comment ça marche ?

GÉNÉRATION
DU CONLL-U



ÉNONCÉ ÉLÉMENTAIRE

D_1 N_1 V ADV F_i p D_2 $N_{2/3}$

EXTRACTION AVEC GREWPY

```
pattern = """pattern {
    X-[nsubj|obj|iobj|nsubj:pass|cop]->Y;
    Y-[det]->Z;
    X-[aux:pass|aux:tense]->W;
}"""
```

MATRICE DE
COOCCURRENCE

président	prdopte	la	loi
president	1	1	1
adopte	1	0	0
la	0	0	1
loi	0	1	1

COOCCURRENCE SYNTAXIQUE

Comment ça marche ?

GÉNÉRATION
DU CONLL-U



ÉNONCÉ ÉLÉMENTAIRE

D_1 N_1 V ADV F_i p D_2 $N_{2/3}$

EXTRACTION AVEC GREWPY

```
pattern = """pattern {  
    X-[nsubj|obj|iobj|nsubj:pass|cop]->Y;  
    Y-[det]->Z;  
    X-[aux:pass|aux:tense]->W;  
}"""
```

PONDÉRATION
PPMI

RÉDUCTION DE
DIMENSIONNALITÉ

MATRICE DE
COOCCURRENCE

président	prdopte	la	loi
president	1	1	1
adopte	1	0	0
la	0	0	1
loi	0	1	1

COOCCURRENCE SYNTAXIQUE

Comment ça marche ?

GÉNÉRATION
DU CONLL-U




ÉNONCÉ ÉLÉMENTAIRE

D_1 N_1 V ADV F_i p D_2 $N_{2/3}$

EXTRACTION AVEC GREWPY

```
pattern = """pattern {  
    X-[nsubj|obj|iobj|nsubj:pass|cop]->Y;  
    Y-[det]->Z;  
    X-[aux:pass|aux:tense]->W;  
}"""
```

CLUSTERISATION K-MEANS



PONDÉRATION
PPMI

RÉDUCTION DE
DIMENSIONNALITÉ

MATRICE DE
COOCCURRENCE

président	prdopte	la	loi
president	1	1	1
adopte	1	0	0
la	0	0	1
loi	0	1	1

COOCCURRENCE SYNTAXIQUE



Choix des paramètres

Taille de la fenêtre de cooccurrence

- Petite fenêtre (2 mots) : Relations syntaxiques locales (sujet - auxiliaire - verbe).

Méthode de pondération

- PPMI = Positive Pointwise Mutual Information
- Atténue l'impact des mots fréquents, renforce les cooccurrences significatives.

Réduction de dimension



- PCA = Analyse en Composantes Principales (Principal Component Analysis)
- MDS = Réduction Multidimensionnelle par Mise en Évidence (Multidimensional Scaling)

Nombre de clusters

- k=4 est optimal, parce que les clusters sont bien séparés et l'inertie est basse


VISUALISATIONS

Clustering des mots (PCA + K-means)



VISUALISATIONS

Clustering des mots (MDS + K-means)



QUELQUES CONCLUSIONS

OBSERVATIONS

- **Les clusters** se font selon les fonctions syntaxiques
- Le choix de **la méthode de réduction de dimensionnalité (MDS, PCA)** impacte fortement la clusterisation

LIMITES


- Dans notre cas, **fenêtre limitée** (2 seulement) pour des questions techniques
- Choix de travailler sur les **lemmes uniquement** pour être comparable à la méthode W2V, peut fausser les résultats
- Résultats éloignés de l'objectif initial
- Difficulté d'interprétation

COOCCURRENCE LINÉAIRE



Comment ça marche ?

FENÊTRE GLISSANTE




EXTRACTION DE N-GRAMS

MATRICE DE COOCCURRENCE

	président	prdopte	la	loi
président				
president		1	1	1
adopte		1	0	0
la		0	0	1
loi		0	1	1

PONDÉRATION PPMI

CLUSTERISATION AVEC K-MEANS



INTERPRÉTATION
ET VISUALISATION

COOCCURRENCE LINÉAIRE

Choix des paramètres recommandés

Taille de la fenêtre de cooccurrence

- Petite fenêtre (2-3 mots) : Relations syntaxiques locales (ex. : sujet-verbe).
- Grande fenêtre (5-10 mots) : Relations plus abstraites, mais risque de bruit.

Méthode de pondération

- PPMI = Positive Pointwise Mutual Information
- Atténue l'impact des mots fréquents, renforce les cooccurrences significatives.

Réduction de dimension


- PCA = Analyse en Composantes Principales (Principal Component Analysis)
- MDS = Réduction Multidimensionnelle par Mise en Évidence (Multidimensional Scaling)

Quantité de clusters

- $k=4$ est optimal, parce que les clusters sont bien séparés et l'inertie est basse

VISUALISATIONS

Clustering des mots (PCA + K-means)



The figure displays three word embeddings visualized as convex hulls on a 2D plane defined by dimension 1 (x-axis) and dimension 2 (y-axis). The left plot shows three distinct clusters: a green cluster for 'dispositif' (including words like 'disposition', 'texte', 'projet', 'mesure', 'sénat', 'objet'), a purple cluster for 'séance' (including words like 'proposition', 'rapport', 'crédit', 'droit', 'avis', 'sujet', 'amendement', 'assemblée', 'commission', 'loi', 'scrutin', 'budget', 'choix', 'décision', 'conseil', 'question', 'occasion', 'engagement', 'majorité', 'nombre', 'france', 'discussión', 'plusieurs'), and a red cluster for 'ministère' (including words like 'collègue', 'groupe', 'mission', 'temps', 'débat', 'rapporteur', 'travail', 'argument', 'gouvernement', 'président', 'ministre'). The right plot shows a large teal cluster for 'action' (including words like 'être', 'aucun', 'réaliser', 'suspendre', 'lever', 'repandre', 'passer', 'pouvoir', 'avoir', 'émettre', 'soumettre', 'ouvrir', 'voir', 'reprendre', 'reconnaitre', 'trouver', 'commencer', 'comprendre', 'mener', 'avoir', 'introduire', 'supprimer', 'maintenir', 'fixer', 'inscrire', 'porter', 'examiner', 'rejeter', 'voter', 'adopter', 'tenir', 'annoncer', 'choisir', 'créer', 'augmenter', 'rendre', 'décider', 'déposer', 'présenter', 'proposer', 'demander', 'engager', 'recevoir', 'donner', 'prendre', 'dire', 'mettre', 'évoquer', 'permettre', 'entendre', 'faire', 'connaître', 'lancer', 'poser', 'comprendre', 'mener').

QUELQUES CONCLUSIONS

AVANTAGES

- **Simplicité et efficacité :**
méthode facile à implémenter
- **Visualisation claire**
- **Réduction dimensionnelle (MDS, PCA)**
- **PPMI** capture les relations significatives

LIMITES

- **Paramétrage difficile**
- **Relations simples uniquement**
- **La perte d'information**
- **Une fenêtre trop large = bruit**
- **Que les relations de surface. Pas les dépendances plus profondes :(**

WORD2VEC

Comment ca marche ?

CORPUS TOKENISÉ



EXTRACTION BIGRAMS



RÉDUCTION DE DIMENSION PCA



APPRENTISSAGE DES
REPRÉSENTATIONS




CLUSTERISATION WARD



VISUALISATION

- Cluster 0 (2870 mots): européen, projet, économique, qualité, développement, Europe, économie, agriculteur, investissement, produit, secteur, développer, Union_européen, prix, ligne, marché, acteur, outil, agriculture, international
- Cluster 1 (4246 mots): entreprise, année, moyen, euro, budget, emploi, amendement_viser, logement, million_euro, risque, salarié, million, financement, activité, fiscal, augmenter, coût, milliard_euro, supplémentaire, financier
- Cluster 2 (6981 mots): pouvoir, faire, état, falloir, proposer, loi, texte, français, droit, devoir, politique, cas, public, aujourd, grand, prendre, important, prévoir, dispositif, social
- Cluster 3 (2629 mots): amendement, article, groupe, applaudissement_banc, parole_mme, ministre, soutenir_amendement, groupe_laREM, avis_commission, collègue, parole, disposition, monsieur_ministre, avis_gouvernement, défendre, avis, banc
- Cluster 4 (6384 mots): bien, avoir, agir, vouloir, non, savoir, raison, venir, souhaiter, rappeler, temps, Monsieur_ministre, donner, voir, heure, fois, cher_collègue, passer, ici, dire
- Cluster 5 (2113 mots): procédure, étranger, protection, protéger, délai, femme, juge, victime, règlement, égard, recours, administratif, interdire, durée, relation, mineur, violence, accueillir, accueil, demandeur_asile
- Cluster 6 (4928 mots): France, pays, personne, national, jour, exemple, contre, parlementaire, information, bénéficiaire, parlement, président, assemblée, petit, aide, vivre, conséquence, famille, sein, difficulté
- Cluster 7 (2884 mots): permettre, nouveau, cadre, service, action, formation, enfant, santé, vie, plan, renforcer, jeune, accompagner, grâce, accès, adapter, lutte_contre, établissement, mettre_place, école
- Cluster 8 (2385 mots): être, gouvernement, question, mesure, travail, commission, projet_loi, sujet, débat, ailleurs, rapport, répondre, accord, viser, député, dernier, proposition, adopter, proposition_loi, présent
- Cluster 9 (1244 mots): territoire, mer, population, ville, construire, construction, circonscription, Paris, zone, habitant, environnement, environnemental, vente, quartier, situer, métropole, aménagement, territoire_rural, patrimoine, t



EXTRACTION REPRÉSENTANT ET
PARANGONS



DÉDUIRE LE K OPTIMAL



WORD2VEC

Choix des paramètres recommandés

Paramètres

- Taille des vecteurs : 100
Dimension
- fenêtre de contexte : 5
mots symétriques).
- Min count= 5 : ignore les
mots rares.
- Epoch= 10(entraînement
itératifs sur le corpus)

Quantité de clusters


- k=3 est optimal, en
appliquant la
méthode du coude

Réduction de dimension

- PCA = Analyse en
Composantes
Principales (Principal
Component Analysis)
- WARD = Methode
hierarchique
aglomérative

VISUALISATIONS

clustering ward_pca k=10



clustering ward-pca k=10


- Cluster 0 (2870 mots):
européen, projet, économique, qualité, développement, Europe, économie, agriculteur, investissement, produit, secteur, développer, Union_européen, prix, ligne, marché, acteur, outil, agriculture, international
- Cluster 1 (4246 mots):
entreprise, année, moyen, euro, budget, emploi, amendement_viser, logement, million_euro, risque, salarié, million, financement, activité, fiscal, augmenter, coût, milliard_euro, supplémentaire, financier
- Cluster 2 (6981 mots):
pouvoir, faire, état, falloir, proposer, loi, texte, français, droit, devoir, politique, cas, public, aujourd, grand, prendre, important, prévoir, dispositif, social
- Cluster 3 (2629 mots):
amendement, article, groupe, applaudissement_banc, parole_mme, ministre, soutenir_amendement, groupe_LaREM, avis_commission, collègue, parole, disposition, monsieur_ministre, avis_gouvernement, défendre, avis, banc
- Cluster 4 (6384 mots):
bien, avoir, agir, vouloir, non, savoir, raison, venir, souhaiter, rappeler, temps, Monsieur_ministre, donner, voir, heure, fois, cher_collègue, passer, ici, dire
- Cluster 5 (2113 mots):
procédure, étranger, protection, protéger, délai, femme, juge, victime, règlement, égard, recours, administratif, interdire, durée, relation, mineur, violence, accueillir, accueil, demandeur_asile
- Cluster 6 (4928 mots):
France, pays, personne, national, jour, exemple, contre, parlementaire, information, bénéficiaire, parlement, président, assemblée, petit, aide, vivre, conséquence, famille, sein, difficulté
- Cluster 7 (2004 mots):
permettre, nouveau, cadre, service, action, formation, enfant, santé, vie, plan, renforcer, jeune, accompagner, grâce, accès, adapter, lutte_contre, établissement, mettre_place, école
- Cluster 8 (2305 mots):
être, gouvernement, question, mesure, travail, commission, projet_loi, sujet, débat, ailleurs, rapport, répondre, accord, viser, député, dernier, proposition, adopter, proposition_loi, présent
- Cluster 9 (1244 mots):
territoire, mer, population, ville, construire, construction, circonscription, Paris, zone, habitant, environnement, environnemental, vente, quartier, situer, métropole, aménagement, territoire_rural, patrimoine, t

Dendrogramme hiérarchique ~~Ward~~ linkage




CHOIX K OPTIMAL

Inertie en escalier (méthode du coude)



CLUSTERING K=3

Visualisation des clusters de mots (Ward + PCA)



- **Cluster 1**
(Noms Propres)
- **Cluster 2**
(Économie/Fiscalité)
- **Cluster 3**
(Société/Droits/Educations)

- Cluster 0 (17038 mots):

être, bien, pouvoir, faire, avoir, état, falloir, gouvernement, agir, vouloir, proposer, article, loi, question, applaudissement_banc, texte, français, non, droit, savoir

- Cluster 1 (2349 mots):

amendement, groupe, parole_mme, ministre, soutenir_amendement, avis_commission, collègue, monsieur_ministre, avis_gouvernement, défendre, avis, Monsieur_président, avis_défavorable, amendement_viser, rapporteur,

- Cluster 2 (16317 mots):

permettre, France, mesure, territoire, public, pays, année, dispositif, cadre, moyen, situation, personne, service, national, jour, euro, projet, connaître, exister, travailler

REPRÉSENTANTS & PARANGONS

REPRÉSENTANTS:

le mot le plus proche du centroïde du cluster dans l'espace vectoriel. Il incarne le vocabulaire typique du cluster

Cluster	Mot	Similarité au centroïde
1	Elimas_rapporteure	0.9322275
1	Christophe_Jerretie	0.9291595
1	Monica_Michel	0.9234616
1	Deprez_Audebert	0.9187125
1	mme_Sandra	0.9176735
2	réindexation	0.9058040
2	plafond_exonération	0.8808417
2	plafond_affectation	0.8777672
2	abaisser_plafond	0.87746674
2	cotisation_chômag	0.8653048
3	éligible_CPF	0.8253838
3	discriminatoire	0.8152453
3	coparentalité	0.81228185
3	second_degrer	0.8119795
3	obligatoire_avocat	0.80881953

• **Cluster 1**
(Noms Propres)

• **Cluster 2**
Économie/Fiscalité)

• **Cluster 3**
(Société/Droits/Eductions)

PARANGONS

le mot le plus éloigné des centroïdes des autres clusters, c'est-à-dire le plus spécifique au cluster

Cluster	Mot	Similarité autres centro
1	Collard	0.25309473
1	parole_Hervé	0.25804436
1	Marie	0.26063538
1	entendre_orateur	0.26145414
1	Éric_Ciotti	0.26971555
2	flamber	0.24831331
2	Faut_rappeler	0.2512516
2	anner_année	0.26467758
2	ratio	0.20537564
2	fortune	0.27524847
3	forum	0.2020441
3	science	0.21310833
3	hautement	0.22801948
3	contournement	0.23274797
3	radicalisation	0.23331073

FIGURE 23 – La liste des 5 parangons de chaque cluster

FIGURE 22 – La liste des 5 représentants spécifiques de chaque cluster

QUELQUES CONCLUSIONS

AVANTAGES

- **Modèle distribué puissant :**
capte des régularité
sémantiques très fines.
- **Représentations continues:**
Comparaisons sémantiques
précises
- **Efficace sur de grands
corpus.**
- **Utilisable sur d'autres tâches
NLP:** classification, détection.
- **Compatible avec d'autres
méthodes de réduction**

LIMITES

- **Insensible à la polysémie:**
un mot= un vecteur
- **Dépendant du contexte
d'apprentissage.**
- **Pas de relations syntaxiques
explicites**
- **Interprétation des résultats
reste subjective (pas de
sens humain)**

COMPARAISON DES MÉTHODES

COOCCURRENCE SYNTAXIQUE

- Clusters fondés sur les fonctions syntaxiques et donc ici catégories grammaticales
- Analyse limitée par la taille réduite des énoncés élémentaires

COMPARAISON DES MÉTHODES

COOCCURRENCE SYNTAXIQUE

- Clusters fondés sur les fonctions syntaxiques et donc ici catégories grammaticales
- Analyse limitée par la taille réduite des énoncés élémentaires

COOCCURRENCE LINÉAIRE

- Regroupements liés à la proximité de surface dans le texte
- Visualisation simple mais clusters sensibles au bruit et aux paramètres (fenêtre)

COMPARAISON DES MÉTHODES

COOCCURRENCE SYNTAXIQUE

- Clusters fondés sur les fonctions syntaxiques et donc ici catégories grammaticales
- Analyse limitée par la taille réduite des énoncés élémentaires

COOCCURRENCE LINÉAIRE

- Regroupements liés à la proximité de surface dans le texte
- Visualisation simple mais clusters sensibles au bruit et aux paramètres (fenêtre)

WORD2VEC

- Représentations sémantiques denses et robustes
- Clusters thématiquement cohérents (budget, droit, institutions...)

DIFFICULTÉS RENCONTRÉES

**Gestion des
données
massives**

**Limites des
ressources
informatiques**

**Instabilité
des outils**

**Paramétrage
délicat des
algorithmes**

**Problèmes
organisationnels
et humains**

**Incompatibilité
logicielle**

MERCI

C'EST LA FIN...

...mais vous pouvez
poser des questions !



Github