



Projet tutoré

Étude historique et comparative de différentes
méthodes de sémantique distributionnelle sur la
base d'un corpus ParlaMint

Belhoul Lydia, Bessac Lucile, Korol Solomiia

Sous la direction de :
M. Hugo DUMOULIN

Université Paris Nanterre
Année Universitaire 2024 – 2025

Remerciements

Notre équipe souhaite adresser nos sincères remerciements à M. Hugo Dumoulin, notre encadrant de projet, pour son accompagnement attentif et ses conseils toujours pertinents. Sa disponibilité, sa patience et sa rigueur ont été essentielles à chaque étape de ce travail. Grâce à son engagement constant, nous avons pu surmonter les difficultés rencontrées et approfondir notre réflexion.

Nous remercions aussi chaleureusement l'ensemble de nos enseignant(e)s du master TAL et nos ami(e)s de groupe qui nous ont soutenus et partagé leurs idées.

Table des matières

1	Introduction	5
1.1	Contexte	5
1.2	Problématique et questions de recherche	5
1.3	Objectifs du projet	5
1.4	Méthodologie générale	6
1.5	Ancrage théorique	6
2	État de l’art : l’apprentissage distributionnel et les approches de clusterisation lexicale	7
2.1	Apprentissage distributionnel et modélisation du sens lexical . .	7
2.2	Trois approches pour la clusterisation lexicale	8
2.3	Méthodes de clusterisation	10
3	Présentation du corpus ParlaMint	12
4	Organisation du travail	13
4.1	Dépôts de travail	13
4.2	Difficultés rencontrées	14
5	Méthodologie	17
5.1	Corpus et préparation des données	17
5.2	Les paramètres ajustables et leur impact sur le clustering final .	17
5.2.1	Taille de la fenêtre de cooccurrence	17
5.2.2	Méthode d’association (fréquence brute, PMI, PPMI) . .	18
5.2.3	Nombre de dimensions retenues (PCA, MDS)	18
5.2.4	Nombre de clusters k	18
5.2.5	Sélection des mots (top n)	19
5.3	Méthode inspirée par M.Pêcheux	19
5.3.1	Corpus et préparation des données	19
5.3.2	Structure des énoncés élémentaires et relations	19
5.3.3	Taille de la fenêtre de cooccurrence	20
5.3.4	Méthode d’association	20
5.3.5	Nombre de dimensions	20
5.3.6	Nombre de clusters k	21
5.4	Cooccurrence linéaire	21
5.4.1	Génération des triplets de cooccurrence	21
5.4.2	Construction de la matrice de cooccurrence	22
5.4.3	Pondération avec le score PPMI	22
5.4.4	Réduction de dimension et clusterisation	22
5.4.5	Évaluation des résultats	23
5.5	Word2Vec	24
5.5.1	Construction des représentations vectorielles	24
5.5.2	Réduction de dimension	24
5.5.3	Détermination du nombre de clusters	25

5.5.4	Algorithme de clustering	25
6	Résultats	26
6.1	Approche inspirée par M.Pêcheux	26
6.1.1	Analyse des clusters	26
6.2	Cooccurrence linéaire	29
6.2.1	Visualisations de clusters	29
6.2.2	Analyse des clusters	30
6.2.3	Avantages et limites de cooccurrence linéaire	31
6.3	Word2Vec	32
6.3.1	Visualisation des regroupements lexicaux	32
6.3.2	Détermination du nombre de clusters	33
6.3.3	Analyse des clusters	35
6.3.4	Apports et limites du modèle Word2Vec	38
6.4	Comparaison des résultats	38
6.4.1	Organisation syntaxique vs. sémantique	38
6.4.2	Qualité des regroupements	38
7	Conclusions	39

1 Introduction

1.1 Contexte

Dans le contexte de l’analyse de corpus textuels, la **structuration automatique du lexique** constitue un enjeu fondamental pour la compréhension des régularités discursives et thématiques d’un ensemble de documents. L’évolution des méthodes de traitement automatique des langues (TAL) a permis le développement de techniques avancées de représentation des mots, facilitant leur regroupement selon des critères contextuels ou sémantiques.

Ce projet s’inscrit dans cette dynamique, en proposant une **étude historique et comparative** de différentes méthodes de **sémantique distributionnelle**, appliquées à un même corpus parlementaire (ParlaMint). L’originalité de notre approche réside dans le fait de confronter des modèles issus de **différentes époques et paradigmes théoriques**, allant de l’**analyse du discours de Michel Pêcheux** (années 1970), aux **modèles statistiques de cooccurrence** (années 2000), jusqu’aux **plongements lexicaux neuronaux comme Word2Vec** (2010). Cette perspective diachronique permet d’interroger les continuités et ruptures dans la manière dont le sens lexical a été construit à partir du contexte au fil du temps.

1.2 Problématique et questions de recherche

La problématique centrale du projet porte sur l’impact de la **définition du contexte** sur la structuration distributionnelle du lexique. Comment ces différentes conceptions du contexte influencent-elles les représentations sémantiques, et en quoi affectent-elles la qualité des regroupements lexicaux obtenus par clusterisation ?

L’étude menée vise donc à répondre aux questions suivantes :

- Quels types de regroupements lexicaux sont produits par chaque méthode dans un corpus parlementaire ?
- Ces regroupements sont-ils thématiquement ou discursivement cohérents ?
- En quoi se distinguent-ils des clusters générés par les autres méthodes ?
- Quelle valeur ajoutée les représentations vectorielles récentes apportent-elles, en regard des méthodes antérieures de cooccurrence linéaire ou syntaxique et vice-versa ?

1.3 Objectifs du projet

Ce projet vise à tester et **comparer trois méthodes de représentation distributionnelle du sens lexical**, toutes appliquées à un même corpus :

- (1) Une cooccurrence syntaxique inspirée de l’**analyse du discours de Michel Pêcheux** ;
- (2) Une méthode de **cooccurrence linéaire**, fondée sur les matrices de voisinage syntaxique ou linéaire (DSM) ;

- (3) L’approche par **plongements lexicaux neuronaux** via l’algorithme Word2Vec.

L’objectif est de mettre en évidence les différences entre ces approches en termes de structure des regroupements lexicaux obtenus, de pertinence sémantique et de cohérence thématique.

1.4 Méthodologie générale

Pour chaque méthode étudiée, un modèle sémantique distributionnel (DSM) est construit à partir du corpus ParlaMint. Le processus d’analyse suit les étapes suivantes :

- **Constitution de vecteurs** : matrice de cooccurrences ou vecteurs pré-entraînés ;
- **Réduction de dimensionnalité** via PCA ou MDS pour faciliter la visualisation et la clusterisation ;
- **Application d’un algorithme de clustering** (principalement KMeans) pour identifier des groupes lexicaux ;
- **Comparaison des résultats** à l’aide de visualisations et d’analyses qualitatives.

1.5 Ancrage théorique

Ce travail s’appuie sur plusieurs cadres conceptuels et méthodologiques :

- **La théorie distributionnelle** formulée par Zellig Harris HARRIS [3], qui pose le principe fondamental selon lequel le sens d’un mot peut être inféré à partir de ses contextes ;
- Les travaux de l’Analyse Automatique du Discours de **Michel Pêcheux** sur la **synonymie contextuelle** et la construction idéologique du sens [6] ;
- Les contributions d’**Evert** sur les DSM classiques et les matrices de co-occurrence [1] ;
- Les représentations vectorielles prédictives développées par **Mikolov et al. dans Word2Vec** [5].

Ce socle théorique permet de situer notre démarche dans un champ interdisciplinaire, croisant **linguistique computationnelle, analyse du discours et apprentissage automatique**.

2 État de l’art : l’apprentissage distributionnel et les approches de clusterisation lexicale

2.1 Apprentissage distributionnel et modélisation du sens lexical

L’apprentissage distributionnel repose sur l’idée fondatrice que le sens d’un mot peut être appréhendé à partir de ses contextes d’usage. Cette hypothèse, connue sous le nom de « *distributional hypothesis* », fut formulée dès les années 1950 par des linguistes tels que Zellig Harris [3], selon laquelle « *words that occur in the same contexts tend to have similar meanings* ». Sur cette base, de nombreuses méthodes ont été développées pour représenter les mots sous forme de vecteurs, dans des espaces où la distance traduit une certaine proximité sémantique ou fonctionnelle.

Historiquement, les premières représentations distributionnelles ont été construites à partir de matrices de cooccurrence [4, 7], souvent pondérées par des mesures d’association telles que la fréquence brute, le *mutual information* (MI), ou encore le *pointwise mutual information* (PMI). Ces approches dites « comptables », comme celles décrites par Evert [1], s’appuient typiquement sur une fenêtre glissante (linéaire) pour définir les contextes, ce qui favorise une représentation locale du sens.

Avec l’essor de l’apprentissage automatique, une nouvelle génération de modèles distributionnels dits « prédictifs » a émergé. Ces modèles, parmi lesquels Word2Vec [5], reposent sur l’idée de prédire le contexte d’un mot (ou inversement) à l’aide de réseaux neuronaux peu profonds. Ils ont démontré une capacité remarquable à capturer des régularités linguistiques fines, y compris des analogies sémantiques ou syntaxiques.

Par ailleurs, des approches syntaxiques ont également été proposées, en particulier dans le sillage des travaux de Michel Pêcheux [6], pour qui le sens est indissociable des structures discursives. Ces modèles s’éloignent de la simple cooccurrence linéaire en intégrant des relations grammaticales et énonciatives dans la définition du contexte.

Enfin, pour visualiser et analyser les représentations sémantiques obtenues, des techniques de réduction de dimension telles que PCA (Principal Component Analysis), t-SNE (t-Distributed Stochastic Neighbor Embedding) ou UMAP (Uniform Manifold Approximation and Projection) sont couramment utilisées. Ces techniques permettent de projeter des vecteurs de haute dimension dans un espace lisible en 2D ou 3D, tout en préservant la structure des données.

2.2 Trois approches pour la clusterisation lexicale

a. Approche inspirée de l’analyse du discours de Pêcheux : vers une cooccurrence syntaxique (relations profondes)

La notion de **cooccurrence syntaxique** désigne un élargissement du concept traditionnel de cooccurrence lexicale, en intégrant des dimensions structurelles plus profondes, telles que les **relations syntaxiques, discursives ou fonctionnelles**. Plutôt que de se limiter à la proximité linéaire des mots, ces approches redéfinissent le contexte lexical à partir d’unités grammaticales ou argumentatives plus complexes.

Dans cette perspective, certains travaux inspirés de l’analyse du discours, notamment ceux de **Michel Pêcheux** [6], ont mis en lumière l’importance des structures énonciatives et des formations discursives dans la construction du sens. Ces approches postulent que le sens des mots émerge de leur fonction dans des configurations syntaxiques et discursives spécifiques, souvent centrées sur l’action verbale, et liées à des positions idéologiques.

Appliquées au traitement automatique, ces méthodes s’appuient sur des outils d’analyse syntaxique ou de segmentation discursive pour identifier des contextes profonds, allant au-delà de la simple cooccurrence de surface. Elles permettent de regrouper des lexèmes non pas seulement parce qu’ils apparaissent ensemble, mais parce qu’ils **occupent des rôles similaires dans des structures argumentatives comparables**, ou qu’ils s’inscrivent dans des enchaînements discursifs cohérents.

Bien que plus complexe à opérationnaliser, cette approche ouvre des perspectives originales pour la classification lexicale, en capturant des régularités discursives qui échappent aux méthodes purement distributionnelles ou vectorielles.

b. Cooccurrence linéaire (relations de surface)

Les modèles classiques de sémantique distributionnelle s’appuient sur une définition plus stricte de la cooccurrence, généralement fondée sur la proximité linéaire des mots dans le texte. Dans cette approche, deux mots sont considérés comme liés s’ils apparaissent dans une fenêtre fixe autour d’un mot cible, souvent définie en nombre de mots (par exemple ± 5). Il s’agit d’une méthode simple, robuste et historiquement centrale dans la modélisation distributionnelle, notamment au début des années 2000.

Cette forme de cooccurrence, que l’on pourrait qualifier de surface, est aveugle à la structure grammaticale et ne prend pas en compte les rôles syntaxiques des termes. Elle repose sur l’idée que la fréquence de coapparition dans un voisinage textuel immédiat suffit à révéler des proximités sémantiques ou thématiques. Les contextes extraits sont ensuite utilisés pour construire des matrices de cooccurrence, souvent pondérées par des mesures comme le MI (mutual information) ou le PPMI (positive pointwise mutual information), avant d’être réduites dimensionnellement et utilisées pour des tâches comme la clusterisation.

Un élément central de cette approche est le paramétrage de la **fenêtre de cooccurrence**, c'est-à-dire la portée dans laquelle deux mots sont considérés comme étant en relation. Dans les modèles traditionnels, cette fenêtre est définie en nombre de mots (par exemple, deux mots à gauche et deux à droite du mot cible). Une fenêtre trop courte capture des relations très locales mais risque de manquer des associations pertinentes à plus grande distance ; à l'inverse, une fenêtre trop large peut introduire du bruit sémantique.

Concrètement, cette approche repose sur les étapes suivantes :

- **Extraction des n-grams de cooccurrence** : les contextes ne sont limités à des fenêtres fixes.
- **Construction de la matrice** : une matrice est construite à partir des relations extraites.
- **Pondération** : les scores de cooccurrence sont pondérés par des mesures d'association telles que la fréquence, le MI ou le PPMI, pour renforcer les associations significatives.
- **Réduction de dimension** : des techniques comme DSM ou PCA permettent de projeter l'espace de cooccurrence dans un espace vectoriel interprétable.

c. Word2Vec

Développé par une équipe de chercheurs chez Google [5], Word2Vec propose deux architectures principales : *Continuous Bag of Words* (CBOW) et *Skip-gram*. Dans le premier, le modèle prédit un mot à partir de son contexte, tandis que dans le second, il prédit le contexte à partir d'un mot donné. Les représentations obtenues sont denses, continues, et permettent des opérations vectorielles qui traduisent des relations sémantiques complexes (ex. roi - homme + femme $\approx$ reine).

Word2Vec s'est imposé comme une méthode de référence dans les tâches de TAL grâce à sa performance et à sa simplicité d'entraînement. Il permet une projection efficace du lexique dans un espace vectoriel structuré, ouvrant la voie à des analyses exploratoires comme la clusterisation.

Sur le plan technique, Word2Vec s'appuie sur un apprentissage non supervisé à partir d'un grand corpus textuel, sans requérir d'analyse syntaxique préalable. Il encode les régularités distributionnelles dans un espace vectoriel de dimension réduite (souvent 100 à 300 dimensions), ce qui le rend particulièrement adapté aux tâches d'exploration lexicale à grande échelle.

Le modèle utilise des stratégies d'optimisation telles que le *negative sampling* ou la *hierarchical softmax*, qui accélèrent considérablement l'entraînement par rapport aux méthodes comptables basées sur des matrices de cooccurrence explicites.

Contrairement aux approches traditionnelles, Word2Vec ne construit pas une matrice de cooccurrence ; il apprend directement des représentations en fonction de la capacité prédictive du contexte. Cela le rend plus robuste au bruit, plus souple face à la variabilité du corpus, mais aussi moins transparent sur le plan linguistique (les dimensions du vecteur n'ont pas d'interprétation directe).

Enfin, ces vecteurs peuvent être analysés par des techniques de clustering comme K-means, ou projetés dans un espace 2D/3D via des algorithmes comme PCA, t-SNE ou UMAP, afin de visualiser des regroupements lexicaux. Cette capacité à rendre visible la structure sémantique implicite d’un corpus est l’un des atouts majeurs du modèle.

2.3 Méthodes de clusterisation

Une fois les représentations lexicales obtenues — qu’elles soient issues d’un modèle vectoriel dense (Word2Vec), d’une matrice de cooccurrence pondérée (PPMI), ou d’un modèle syntaxico-discursif — il devient possible d’explorer les relations entre les mots via des méthodes de clusterisation. L’objectif est de regrouper les unités lexicales en fonction de leur proximité dans l’espace vectoriel, c’est-à-dire selon leur similarité distributionnelle.

Deux grandes familles d’algorithmes de clusterisation peuvent être mobilisées dans ce cadre :

- **K-means**, qui partitionne les données en k groupes en minimisant la variance intra-cluster. Cet algorithme repose sur une hypothèse forte de forme sphérique des clusters et nécessite de spécifier à l’avance le nombre de groupes. Il est rapide, efficace, bien adapté à des données continues et de grande dimension comme les vecteurs Word2Vec. Toutefois, il est sensible à la sélection initiale des centroïdes, et peut produire des résultats instables sans initialisation contrôlée. Des stratégies comme l’initialisation **k-means++** ont été utilisées pour atténuer ce biais.
- **Clustering hiérarchique** (souvent agglomératif), qui procède de manière ascendante : chaque point commence comme un cluster isolé, et des fusions successives sont effectuées en fonction d’une métrique de distance (ex. : euclidienne, cosinus) et d’une méthode de linkage (ex. : Ward, average). Ce type d’algorithme produit une structure arborescente — le dendrogramme — qui permet d’observer plusieurs niveaux de regroupement. Il est particulièrement utile pour explorer la granularité des thématiques dans le lexique, mais son coût computationnel le rend moins adapté à des volumes massifs de données.

Dans notre étude, nous avons principalement opté pour le **K-means**, en raison de sa compatibilité naturelle avec les vecteurs denses, de sa rapidité et de sa capacité à produire des partitions nettes pour un nombre de clusters déterminé. Le choix du nombre k a été guidé par des méthodes heuristiques comme la *méthode du coude* et la *silhouette score*, complétées par une validation qualitative sur la cohérence sémantique des regroupements.

Le **clustering hiérarchique** a été utilisé à des fins complémentaires, notamment pour :

- analyser la structure multi-niveaux des regroupements lexicaux ;
- valider des hypothèses sur les proximités thématiques ;
- ajuster le paramétrage de k dans K-means par comparaison visuelle avec les coupures naturelles du dendrogramme.

Ainsi, la combinaison de ces deux approches permet d'exploiter à la fois l'efficacité opérationnelle de K-means et la richesse interprétative des arbres hiérarchiques.




FIGURE 1 – Visualisation de K-means et clustering hiérarchique

3 Présentation du corpus ParlaMint

Le corpus ParlaMint (Parliaments in Time) est issu d’une initiative européenne visant à constituer un ensemble de **corpus parlementaires multilingues et annotés de manière standardisée**. Il s’agit d’un projet issu de la collaboration entre différents pays européens dans le cadre de l’infrastructure de recherche CLARIN ERIC, dont l’objectif est de fournir aux chercheurs des ressources linguistiques structurées, ouvertes et comparables à travers les pays.

ParlaMint couvre plusieurs années d’activité parlementaire dans divers pays et propose des données sous des **formats conformes aux standards TEI/XML**. Les discours parlementaires sont enrichis par des **annotations morpho-syntaxiques**, des **métadonnées sur les locuteurs** (nom, sexe, rôle parlementaire, parti politique, etc.), et des **indications temporelles précises sur les séances**.

L’annotation linguistique est produite par des outils nationaux adaptés aux langues concernées, puis harmonisée pour assurer l’interopérabilité. Le corpus peut ainsi être exploité de manière transversale : il permet d’appliquer des méthodes d’analyse linguistique, sociolinguistique ou politique sur une base de données structurée et homogène. Grâce à son format ouvert et ses métadonnées riches, ParlaMint facilite les études comparatives à l’échelle européenne.

Nous avons utilisé pour notre étude un extrait du corpus ParlaMint France, spécifiquement pour l’année 2018, composé de 362 documents rapportant les séances de l’Assemblée nationale. Cette sous-partie du corpus présente un volume conséquent de données textuelles puisque chacun des 362 documents **compte plus de 1 000 lignes et 50 000 tokens**, soit **plus de 18 000 000 tokens** au total, permettant d’appliquer des méthodes d’analyse sémantique et de clustering sur des représentations vectorielles issues de l’apprentissage distributionnel.

Le corpus ParlaMint est particulièrement riche en **diversité lexicale**, en raison des différents discours prononcés dans un cadre parlementaire. Les textes couvrent une large gamme de sujets, allant de la politique intérieure et économique aux débats internationaux, offrant ainsi un terrain de recherche idéal pour des applications d’analyse sémantique. En outre, les **métadonnées détaillées** sur les locuteurs permettent de relier les discours aux acteurs politiques spécifiques, facilitant ainsi l’étude de l’influence des partis et des personnalités sur le discours parlementaire.

L’exploitation de cette version du corpus nous a permis de construire un pipeline d’analyse adapté à une tâche de clustering lexical, tout en assurant la représentativité des genres discursifs parlementaires pour l’année 2018. Ce corpus a également servi de base pour tester différentes techniques de vectorisation et de réduction dimensionnelle, en vue de mieux comprendre les dynamiques discursives et les relations sémantiques entre les termes utilisés dans le contexte parlementaire.

Grâce à l’annotation fine du corpus et sa structure homogène, ParlaMint permet de **comparer les discours parlementaires** sur une échelle temporelle et géographique, et constitue une ressource essentielle pour l’étude de l’évolution des idées politiques, des stratégies rhétoriques, et des changements de langage dans le cadre législatif.

4 Organisation du travail

4.1 Dépôts de travail

Le projet est organisé de manière à favoriser une collaboration fluide et efficace entre les membres de l'équipe et les parties prenantes. Nous avons utilisé plusieurs outils pour faciliter le partage de fichiers et la gestion du projet.

Le projet utilise **Google Drive** pour le stockage et le partage de documents textuels. Toutes les notes de réunions et sources de bibliographie sont organisées dans un dossier commun, permettant à chaque membre de l'équipe d'accéder à la dernière version des fichiers à tout moment.



FIGURE 2 – Dossiers du Google Drive

Le code du projet est également versionné et géré grâce à Git via **GitHub**. Chaque collaboratrice avait sa branche nommée selon son prénom. Nous pouvions proposer des améliorations, tester des algorithmes et enfin choisir les scripts à garder.




FIGURE 3 – Dossiers du dépôt sur GitHub

Pour la rédaction du présent rapport, **Overleaf** a été utilisé afin de collaborer en temps réel et à distance.

Pour faciliter la communication quotidienne entre les membres de l'équipe, nous avons mis en place un serveur **Discord**. Ce serveur permet de discuter des problèmes techniques en temps réel, de partager des idées et de coordonner les prochaines étapes du projet. Il existe plusieurs canaux, notamment :

- **général** : Pour les échanges informels et les questions générales.
- **documents** : Un espace pour ajouter les sources et la bibliographie.
- **dates-importantes** : Où sont partagées les dates de réunions et les deadlines.
- **ressources** : Pour partager des sites web et autres ressources pouvant être utiles.

- **decryptage-algo** : Pour discuter de la meilleure approche et diviser nos objectifs globaux en sous-tâches plus simples.




FIGURE 4 – Channels du serveur Discord

Chaque 1 à 2 semaines, nous avons organisé des réunions pour discuter des progrès, résoudre les problèmes techniques et planifier les étapes suivantes. Ces réunions étaient généralement réalisées en ligne et parfois en présentiel. Aussi, une journée par mois était consacrée à des sessions de travail intensives à l’université.

4.2 Difficultés rencontrées

Les difficultés rencontrées dans ce projet ont été à la fois d’ordre **technique**, **méthodologique** et **organisationnel**.




FIGURE 5 – Poids du corpus à différents étapes de traitement

L’un des principaux défis concernait la **gestion des données massives**, en particulier lors des étapes de génération de fichiers conll, de matrices de co-occurrence, de réduction dimensionnelle et de clustering. Le corpus ParlaMint, même dans sa version restreinte à une seule année parlementaire, représente un volume de texte considérable d’un **poids de 78.6 MiB**. Le traitement de plusieurs dizaines de milliers de lignes et de millions de tokens a nécessité des optimisations importantes, notamment des filtres lexicaux, des échantillonnages, et des sauvegardes intermédiaires pour éviter les recalculs. Malgré ces mesures, les temps de calcul restaient parfois très importants, nous ralentissant considérablement dans notre processus.



FIGURE 6 – Exemple d’approximation du temps nécessaire à la génération de tous les conll

Un autre obstacle majeur a été **la mémoire vive et la puissance de calcul limitées** de nos ordinateurs personnels. Certaines opérations, comme l’entraînement de Word2Vec ou la réduction dimensionnelle par t-SNE, sont particulièrement gourmandes et demandent une grande quantité de mémoire vive et une importante puissance de calcul. Ces contraintes ont restreint la taille des jeux de données exploitables et ont imposé des arbitrages constants entre qualité du modèle et faisabilité technique.

Par ailleurs, nous avons rencontré des **problèmes d’instabilité avec RStudio**, notamment lors de l’exécution de scripts lourds impliquant la bibliothèque **factoextra** ou des objets **DSMatrix**. Dans plusieurs cas, les sessions plantaient sans préavis, provoquant la perte de calculs intermédiaires non sauvegardés. De plus, nous avons constaté des incompatibilités entre certaines versions de RStudio et les distributions récentes d’Ubuntu, affectant notamment l’interface graphique et l’affichage des graphiques. Ces difficultés nous ont contraints à tester plusieurs configurations système et à recourir à des solutions alternatives, comme l’exécution en ligne de commande, l’utilisation de notebooks Jupyter pour les parties critiques ou l’utilisation de solution en ligne comme Posit Cloud.

L’**interprétation** fine des clusters a exigé un travail itératif et collaboratif important, nécessitant des visualisations manuelles et des échanges fréquents au sein du groupe pour valider ou remettre en question certaines hypothèses.

À cela s’ajoutent des **contraintes humaines et organisationnelles** qui ont également pesé sur le bon déroulement du projet. Le sujet nous a été imposé, sans possibilité de choisir ni la thématique, ni les membres du groupe. Ce manque de liberté a eu un impact négatif sur notre motivation initiale, d’autant plus que, dans les autres projets, les groupes sont souvent formés selon des affinités, mais aussi en fonction des compatibilités d’emplois du temps et des lieux de résidence. Dans notre cas, certaines personnes vivaient très éloignées géographiquement, rendant les réunions en présentiel quasi impossibles. Nous avons donc dû nous adapter en organisant des visios, qui sont souvent moins efficaces, notamment pour les phases de réflexion collective ou les tests rapides.

Le **timing du projet** a également été difficile à gérer, car il coïncidait avec plusieurs échéances majeures : les partiels de fin de semestre 1, la recherche active de stages pour certains membres, et le rythme particulièrement soutenu de l’alternance pour d’autres. À cela s’ajoutaient d’autres rendus de projets

dans différentes matières, contribuant à une surcharge de travail globale et à des difficultés de coordination dans notre groupe.

Enfin, le **lancement du cours a été particulièrement flou**. Les consignes étaient peu claires, l'intérêt pédagogique du projet ne nous a pas semblé suffisamment explicité et le barème d'évaluation n'a été communiqué que très tardivement. Ce manque de cadrage a contribué à une forme de désengagement initial, à une difficulté à se projeter dans les objectifs attendus et a éveillé un questionnement quant à la pertinence de ce cours ou du moins du format choisi. Une explication plus précise du but pédagogique de ce cours et du choix de ce format "projet", avec des attendus précis, une feuille de route claire et un cadrage pédagogique plus explicite, aurait sans doute permis une implication plus forte et un travail plus serein de la part de tous les membres du groupe. Ce cours aurait par exemple pu fonctionner de pair avec celui de gestion de projet et aurait pu être l'occasion de prendre le temps de mettre en pratique les notions de gestion de projet étudiées dans ledit cours.

5 Méthodologie

5.1 Corpus et préparation des données

Le corpus utilisé provient du projet **ParlaMint** (version 2018). Les 362 fichiers texte ont été parcourus récursivement, et les lignes vides ont été supprimées. Une fonction de prétraitement a été appliquée à chaque ligne, comprenant :

- la mise en minuscules ;
- la suppression des caractères non alphabétiques ;
- la suppression des mots vides (stopwords) ;
- la conservation uniquement des mots de plus de deux lettres.

Un sous-ensemble de 20 000 lignes a été traité, puis 100 000 tokens ont été retenus pour accélérer les étapes suivantes.

5.2 Les paramètres ajustables et leur impact sur le clustering final

Le **clustering**, ou la **classification non supervisée**, est un processus essentiel dans l’analyse de données textuelles, notamment pour regrouper des termes similaires en fonction de leurs caractéristiques communes. Dans ce projet, nous avons utilisé différentes méthodes de clustering, y compris le *K-means*, et avons ajusté plusieurs paramètres afin de mieux comprendre l’impact de ces ajustements sur la qualité des regroupements lexicaux obtenus. Cette section présente les différentes manières dont les paramètres du clustering peuvent être modifiés et l’effet que cela a sur les résultats.

L’ensemble du pipeline d’analyse inclut plusieurs paramètres critiques, dont la variation modifie sensiblement la structure des regroupements lexicaux :

5.2.1 Taille de la fenêtre de cooccurrence

La taille de la fenêtre de cooccurrence joue un rôle crucial dans la capture des relations sémantiques entre les mots. Une fenêtre courte (par exemple, de taille 2) favorise la captation de **relations syntaxiques locales**, telles que les relations sujet-verbe ou verbe-objet. Ce type de fenêtre permet de capturer des connexions immédiates entre des mots qui apparaissent dans des contextes très proches les uns des autres, et qui sont souvent fortement liés dans la structure syntaxique de la phrase. Cela permet de mieux saisir les relations grammaticales précises et les associations locales de termes.

Cependant, une fenêtre large (par exemple, de taille 5 ou 10) élargit le **contexte sémantique** des mots, ce qui permet de capturer des associations plus **conceptuelles** ou **thématiques**. Une telle fenêtre prend en compte un plus grand nombre de mots voisins, augmentant ainsi la possibilité d’identifier des liens sémantiques plus éloignés ou plus abstraits, qui peuvent ne pas être évidents dans des contextes plus restreints. Toutefois, cet élargissement du contexte peut aussi introduire du **bruit** dans les cooccurrences, car il peut inclure des mots moins pertinents ou des relations moins directes.

Le choix de la taille de la fenêtre dépend donc de l'objectif de l'analyse : si l'on cherche à explorer les relations syntaxiques et les constructions grammaticales, une petite fenêtre est préférable. En revanche, pour explorer des relations plus abstraites ou thématiques entre les termes, une fenêtre plus grande est nécessaire, tout en acceptant le compromis potentiel lié à l'inclusion de bruit contextuel.

5.2.2 Méthode d'association (fréquence brute, PMI, PPMI)

Le choix du score influence directement la pondération des relations entre mots. Le PMI est une méthode couramment utilisée dans le traitement du langage naturel pour atténuer les effets du bruit fréquentiel et renforcer les cooccurrences informatives entre les mots.

Le score PPMI est basé sur l'idée que la probabilité conditionnelle d'apparition simultanée de deux mots doit être comparée à la probabilité attendue si les deux mots étaient indépendants. Le PPMI permet d'atténuer le poids des mots très fréquents et de renforcer les cooccurrences spécifiques, ce qui améliore la qualité sémantique des regroupements.

5.2.3 Nombre de dimensions retenues (PCA, MDS)

Le nombre de dimensions retenues lors de la réduction dimensionnelle, qu'il s'agisse de PCA (Principal Component Analysis) ou de MDS (Multi-Dimensional Scaling), a un impact majeur sur la qualité de la représentation des données. Conserver plus de dimensions permet de préserver un plus grand nombre d'informations sémantiques et de détails spécifiques liés à la structure des données. Cela permet de conserver la diversité des relations entre les mots et de maintenir une certaine fidélité à la complexité du modèle original. Cependant, cela entraîne également une visualisation moins claire, car l'augmentation du nombre de dimensions complique l'interprétation directe et rend les relations entre les points moins facilement discernables dans un espace 2D ou 3D.

En bref, le choix du nombre de dimensions à conserver doit être un compromis entre la complexité des données et la lisibilité de la visualisation. L'objectif est de trouver un équilibre qui permet de capturer suffisamment d'informations sémantiques tout en rendant l'interprétation des résultats accessible et pertinente pour l'analyse.

5.2.4 Nombre de clusters k

Ce paramètre de K-means doit être ajusté selon la granularité souhaitée dans les regroupements. Un petit k produit des clusters larges mais hétérogènes ; un grand k fragmente le lexique en groupes plus précis mais parfois redondants. Des méthodes comme le *coude* ou l'indice de silhouette ont été utilisées pour guider ce choix.

5.2.5 Sélection des mots (top n)

Le fait de ne retenir que les n mots les plus fréquents ou informatifs permet de stabiliser le clustering, mais peut masquer certaines subtilités sémantiques présentes dans les mots moins fréquents. Ce paramètre impacte grandement les temps de calcul.

5.3 Méthode inspirée par M.Pêcheux

L'objectif initial était d'enregistrer le corpus sous forme de **structures appelées énoncés élémentaires**, constituées des participants de l'action verbale étiquetés en UD "Core Nominal Arguments" : *nsubj*, *obj*, *iobj* ainsi que le verbe. L'idée était ensuite d'enregistrer le lien entre ces énoncés élémentaires, c'est à dire les relations de dépendances discursives de type *phi* (coordination) et *delta* (subordination), sous forme de graphe avant de clusteriser les énoncés pour donner des "familles paraphrastiques" ou domaines sémantiques et ainsi calculer la synonymie contextuelle.




FIGURE 7 – Structure de l'énoncé élémentaire telle que décrite dans l'Analyse Automatique du Discours de 1969

5.3.1 Corpus et préparation des données

Le corpus utilisé est le sous-ensemble français de ParlaMint 2018, composé de 362 discours parlementaires transcrits au format texte brut, sans annotations. Afin d'analyser la structure syntaxique du corpus à l'aide de **Grew**, il a été nécessaire de **générer le conll** de chaque document, tâche qui prenait environ 15 minutes par document et aurait par conséquent pris 90 heures en tout. Nous nous sommes donc limitées à la génération du conll des **110 premiers textes** qui ont ainsi constitué notre corpus pour cette partie du travail.

5.3.2 Structure des énoncés élémentaires et relations

Une fois les conll générés, nous avons, dans un premier temps et à l'aide de l'outil **GrewPy**, capturé les principaux arguments des verbes soient *nsubj* et son *det*, le verbe et l'auxiliaire. Nous avons ainsi créé un dictionnaire d'énoncés élémentaires. La deuxième plus longue phase après celle de génération des conll était le chargement du corpus pour la récupération des énoncés élémentaires.

```
pattern = """pattern {
    X-[nsubj|obj|iobj|nsubj:pass|cop]->Y;
    Y-[det]->Z;
    X-[aux:pass|aux:tense]->W;
}"""
```

FIGURE 8 – Requête GREW avec GrewPy pour la récupération d'énoncés élémentaires

5.3.3 Taille de la fenêtre de cooccurrence

La méthode de vectorisation par cooccurrence syntaxique offrant des contextes limités, nous avons trouvé qu'**une taille de fenêtre de contexte de 2 mots (window size = 2) produisait les meilleurs résultats** avec cette méthode et nous avons donc conservé cette fenêtre dans les autres cas afin d'avoir des résultats comparables. Une matrice de cooccurrence a ainsi été créée, donnant une représentation vectorielle de chaque mot.

5.3.4 Méthode d'association

La matrice brute est ensuite transformée à l'aide du score d'association **PPMI** (Positive Pointwise Mutual Information).

Dans le cadre de notre projet, la méthode PPMI a été utilisée pour pondérer les triplets générés à partir des paires mot, contexte. Après la génération des triplets (mot cible, mot contexte), une matrice de cooccurrence brute a été construite. Chaque entrée de cette matrice représente le nombre de fois qu'un mot cible apparaît dans un contexte donné.

La matrice de cooccurrence brute a ensuite été transformée en utilisant la fonction `dsm.score()` de la bibliothèque `wordspace` en R, spécifiquement avec le paramètre `score = "MI"`, ce qui permet de calculer le score Pointwise Mutual Information pour chaque paire de mots. Ce score est ensuite normalisé de manière à ce que les valeurs négatives (représentant des cooccurrences faibles ou inattendues) soient attribuées à zéro, et que seules les cooccurrences « significatives » aient une valeur positive.

5.3.5 Nombre de dimensions

Deux techniques de réduction de dimension ont été testées pour rendre les représentations vectorielles issues du PPMI exploitables et c'est finalement **MDS (Multi-Dimensional Scaling)** qui a été appliqué sur la matrice de distances cosinus entre les vecteurs. Une **réduction à 20 dimensions** a été retenue pour l'algorithme de clustering, et à 2 dimensions pour la visualisation des regroupements. Ce choix offre un compromis entre fidélité de la structure sémantique initiale et lisibilité.




FIGURE 9 – Visualisation de la réduction de dimensions

5.3.6 Nombre de clusters k

L'analyse visuelle des clusters a permis de déterminer que 6 était le nombre optimal de clusters. La comparaison des résultats pour différents nombres de clusters a montré que les configurations avec $k=2$ et $k=5$ ne parvenaient pas à capturer la diversité sémantique du corpus de manière optimale. Avec $k=2$, les clusters étaient trop larges, fusionnant des groupes de mots appartenant à des thématiques très différentes. À l'inverse, avec $k=5$, certains clusters restaient trop hétérogènes, mélangés avec des termes de contextes variés.

5.4 Cooccurrence linéaire

5.4.1 Génération des triplets de cooccurrence

À partir des tokens nettoyés issus du corpus ParlaMint, une segmentation en phrases est effectuée ligne par ligne. Un prétraitement comprend la mise en minuscules, la suppression des caractères non alphabétiques, l'élimination des mots vides (*stopwords*) ainsi que la conservation des mots de plus de deux lettres.

Ensuite, un glissement de fenêtre symétrique de taille 2 est appliqué pour générer des paires de type (*mot cible*, *mot contexte*). Chaque cooccurrence est initialement assignée un poids de 1. Ces paires sont ensuite agrégées pour obtenir une table de fréquence pondérant les occurrences récurrentes.

5.4.2 Construction de la matrice de cooccurrence

Les paires (**mot**, **contexte**) sont transformées en une matrice creuse (sparse matrix), où les lignes et colonnes correspondent aux formes lexicales uniques présentes dans le corpus. La matrice est encodée dans un objet **dsm** à l'aide de la bibliothèque **wordspace** en R, permettant une manipulation optimisée des représentations distributionnelles.

Afin de limiter la complexité computationnelle, seuls les 100 000 premiers tokens sont conservés, et les 100 mots les plus fréquents sont retenus pour certaines visualisations.

5.4.3 Pondération avec le score PPMI

La matrice brute est ensuite transformée à l'aide du score d'association **PPMI** (Positive Pointwise Mutual Information), qui permet d'atténuer les effets du bruit fréquentiel et de renforcer les cooccurrences informatives. Cette étape est essentielle pour mettre en évidence les relations sémantiques pertinentes entre les mots, au-delà de leur simple fréquence.

5.4.4 Réduction de dimension et clusterisation

L'approche revisitée dans notre projet consiste à **extraire des structures appelées énoncés élémentaires**, correspondant à des configurations syntaxiques simples (généralement sujet-verbe-objet), identifiées à l'aide d'un analyseur de dépendances. Ces énoncés sont ensuite reliés entre eux par des relations discursives de type *phi* (coordination) et *delta* (subordination), permettant de modéliser une articulation plus large des discours dans lesquels les mots apparaissent.

Contrairement aux approches fondées sur la simple proximité contextuelle (cooccurrence), cette méthode suppose que le sens lexical est en partie construit par les chaînes discursives dans lesquelles les mots s'insèrent. Ainsi, **deux mots peuvent être rapprochés non pas parce qu'ils apparaissent ensemble, mais parce qu'ils occupent une même fonction dans des structures argumentatives similaires**, ou qu'ils appartiennent à des énoncés parallèles dans deux prises de parole opposées.

Ce modèle repose donc sur une définition du contexte fortement verbocentrée et énonciative, où le verbe joue un rôle central dans l'organisation des relations sémantiques. Il s'agit d'une tentative de concilier la rigueur syntaxique avec les dimensions idéologiques et énonciatives du discours, héritées de l'analyse du discours française.

Deux techniques principales de réduction de dimension ont été mises en œuvre afin de rendre les représentations vectorielles issues du modèle PPMI exploitables pour la clusterisation et la visualisation :

- **MDS (Multi-Dimensional Scaling)** a été appliqué sur une matrice de distances cosinus entre les vecteurs lexicaux. Cette technique vise à préserver les distances relatives entre les mots dans un espace de plus faible dimension. Une réduction à 20 dimensions a été retenue pour l'algorithme

de clustering, et à 2 dimensions pour la visualisation des regroupements. Ce choix offre un compromis entre fidélité de la structure sémantique initiale et lisibilité.

- **PCA (Principal Component Analysis)** a également été utilisée, cette fois sur une version filtrée de la matrice PPMI, en conservant uniquement les mots et les contextes ayant une variance significative. Les deux premières composantes principales ont été extraites, permettant une représentation simplifiée du lexique dans un espace bidimensionnel.

Le calcul des distances cosinus a été préféré aux distances euclidiennes pour évaluer la similarité entre vecteurs, car il permet de neutraliser les effets liés à l'amplitude absolue des vecteurs (souvent corrélée à la fréquence des mots) et de se concentrer sur leur orientation relative dans l'espace.

	accès	afin	ailleurs	ainsi	alors	années	ans	ap
accès	0.00000	87.32954	88.04992	87.77941	88.01635	88.63186	88.46288	
afin	87.32954	0.00000	86.07153	85.48684	88.21578	87.91150	87.64689	
ailleurs	88.04992	86.07153	0.00000	86.68663	87.42771	87.62633	87.90173	
ainsi	87.77941	85.48684	86.68663	0.00000	87.52936	87.41476	87.97400	
alors	88.01635	88.21578	87.42771	87.52936	0.00000	85.98512	87.28215	
années	88.63186	87.91150	87.62633	87.41476	85.98512	0.00000	85.80857	
ans	88.46288	87.64689	87.90173	87.97400	87.28215	85.80857	0.00000	
applaudissements	88.04418	88.01912	88.50335	87.72428	88.99672	88.84879	88.30069	
aujourd	87.92682	88.07267	87.57656	87.77500	87.32846	86.72148	87.99976	
aussi	87.31854	86.06160	85.87853	85.93609	87.70654	87.43462	87.51159	
autres	87.84182	86.93733	86.28184	87.76594	87.26725	87.36736	87.97997	

FIGURE 10 – Matrice de distances cosine

5.4.5 Évaluation des résultats

Les résultats des différentes configurations ont été comparés à partir de critères de cohérence interne (mots sémantiquement proches dans un même cluster) et de pertinence thématique par rapport au corpus parlementaire. Des visualisations en deux dimensions ont facilité l'interprétation humaine, tandis que les distances cosinus et les scores de silhouette ont permis une évaluation plus quantitative.

Concrètement, la matrice de cooccurrence initiale a été construite à partir d'un sous-ensemble de 100 000 tokens extraits du corpus ParlaMint, à l'aide d'une fenêtre symétrique de taille 2. La pondération par PPMI a permis de faire émerger des relations sémantiques fines, en neutralisant l'effet de fréquence brute. Une réduction de dimension a ensuite été effectuée par deux techniques complémentaires : le MDS (avec $k=2$ pour la visualisation et $k=20$ pour le

clustering), ainsi que la PCA sur une version nettoyée de la matrice PPMI (suppression des lignes/colonnes à variance nulle).

L'algorithme K-means a été appliqué sur les coordonnées réduites, avec $k=4$, valeur choisie empiriquement après test de différentes configurations. Le score de silhouette moyen obtenu pour cette valeur était d'environ **0.42**, indiquant un bon compromis entre cohésion intra-cluster et séparation inter-cluster. Ce résultat est cohérent avec les visualisations obtenues via la fonction `fviz_cluster`, qui montrent des regroupements relativement nets dans l'espace projeté.

L'analyse des mots représentatifs dans chaque cluster (issus des centroïdes K-means) a permis de confirmer la validité thématique des regroupements. Ainsi, un cluster était dominé par des termes comme *emploi*, *revenu*, *million*, révélant un champ économique, tandis qu'un autre associait des mots tels que *président*, *texte*, *proposition*, correspondant à une dimension législative ou institutionnelle du discours.

Enfin, l'effet du choix de la méthode de réduction a été examiné. Le MDS a offert une meilleure préservation des distances cosinus originales, utile pour la structure sémantique globale, tandis que la PCA a produit des visualisations plus lisibles, en particulier sur les deux premières composantes principales. Les deux méthodes ont convergé vers des regroupements similaires, renforçant la robustesse des résultats.

5.5 Word2Vec

5.5.1 Construction des représentations vectorielles

Afin de représenter les mots de manière distribuée, le modèle Word2Vec a été entraîné sur l'ensemble des tokens nettoyés. Le modèle utilise l'architecture *Skip-gram* avec les paramètres suivants :

- taille des vecteurs : 100 ;
- fenêtre de contexte : 5 ;
- fréquence minimale : 5 ;
- nombre d'époques : 10 ;
- entraînement multithreadé.

Chaque mot est ainsi projeté dans un espace sémantique dense, où la proximité vectorielle reflète une proximité distributionnelle.

5.5.2 Réduction de dimension

Les vecteurs Word2Vec initiaux étant en 100 dimensions, une réduction a été appliquée pour faciliter les traitements et la visualisation :

- D'abord par ACP (Analyse en composantes principales) jusqu'à 20 dimensions, ce qui permet de conserver l'essentiel de la variance ;
- Puis via t-SNE (t-distributed Stochastic Neighbor Embedding), méthode non linéaire permettant une projection en 2D interprétable tout en préservant la structure locale des distances entre vecteurs.

Les projections obtenues ont permis de visualiser la répartition des mots dans l'espace sémantique

5.5.3 Détermination du nombre de clusters

Le nombre de clusters n'a pas été fixé arbitrairement. Il a été déterminé par une double approches :

- la méthode du coude appliquée à l'inertie intra-classe ;
- l'analyse visuelle d'un dendrogramme hiérarchique (linkage de Ward).

5.5.4 Algorithme de clustering

Les vecteurs réduits ont été regroupés à l'aide d'un clustering hiérarchique agglomératif (linkage de Ward). Cette méthode fusionne successivement les groupes de mots en minimisant l'augmentation de la variance intra-groupe. Elle est particulièrement bien adaptée aux représentations vectorielles comme Word2Vec (Ward, 1963).

L'interprétation qualitative des clusters repose sur deux indicateurs lexicaux :

- le mot représentant, proche du centroïde du cluster, reflète le lexique typique ;
- le mot parangon, distant des autres clusters, souligne ce qui rend le groupe spécifique.

6 Résultats

6.1 Approche inspirée par M.Pêcheux

6.1.1 Analyse des clusters

La figure ci-dessous présente une projection bidimensionnelle obtenue après réduction de dimensionnalité avec la méthode MDS. Chaque point représente un mot. Il convient toutefois d'interpréter ce type de projection avec prudence puisque les axes (Dim 1, Dim 2) n'ont pas de signification propre. Il convient d'effectuer un clustering pour pouvoir interpréter les résultats.




FIGURE 11 – Projection sur 2 dimensions après réduction de dimensionnalité MDS et cooccurrence syntaxique

Cette 2e visualisation utilise le même espace 2D, mais les mots sont ici regroupés en 4 clusters à l'aide de l'algorithme K-means, appliqué pour faire émerger des groupes de mots proches.




FIGURE 12 – Projection sur 2 dimensions après choix d'une fenêtre de cooccurrence syntaxique, réduction de dimensionnalité MDS et clustering k-means

Cette projection ci-dessus, graphique issu de la combinaison MDS (Multi-dimensional Scaling) et K-means met en évidence des regroupements lexicaux structurés selon les régularités syntaxiques extraites du corpus. La cooccurrence a été calculée sur la base de dépendances syntaxiques spécifiques (det, nsubj, aux, V) — ce qui oriente fortement les regroupements vers une organisation syntaxique et grammaticale.

- **Le cluster rouge**, placé tout comme le cluster vert sur la gauche du plot, regroupe des mots qui sont tous des substantifs. Ces noms sont fortement marqués politiquement et institutionnellement (président, ministre, gouvernement, majorité, débat) et caractéristiques de l'espace parlementaire et de ses acteurs.
- **Le cluster vert**, placé tout comme le cluster rouge sur la gauche du plot, regroupe des mots qui sont eux aussi tous des substantifs contient des mots techniques liés à la production législative (loi, texte, amendement, projet, rapport), évoquant le lexique de la fabrique des lois.
- **Le cluster bleu** rassemble des auxiliaires et modaux fréquents (être, avoir, pouvoir) ainsi que deux déterminants quantifieurs, aucun et certain. Nous pouvons émettre l'hypothèse que ce cluster a rassemblé ces mots en fonctions de leur rôle dans la structuration discursive.
- **Le cluster violet** regroupe majoritairement des verbes d'action parlementaire (proposer, voter, supprimer, adopter, présenter, demander), soit des formes caractéristiques de l'énonciation institutionnelle ou du faire législatif.

Le graphique ci-dessous présente une réduction dimensionnelle par Analyse en Composantes Principales (PCA) appliquée à une matrice de cooccurrences syntaxiques pondérée par PPMI. Cette projection est suivie d'un clustering non supervisé via K-means, afin de faire émerger des groupes de mots partageant des propriétés communes.




FIGURE 13 – Projection sur 2 dimensions après choix d’une fenêtre de cooccurrence syntaxique, réduction de dimensionnalité PCA et clustering k-means

Ici aussi, le nuage de points montre un regroupement des mots en fonction de leur fonction syntaxique ce qui est peu surprenant étant donnée la méthode de cooccurrence syntaxique qui a été appliquée pour définir la fenêtre de cooccurrence. On remarque par exemple :

- **Le mot “être” (en rouge, 1)** est projeté très à gauche, illustrant son rôle syntaxique omniprésent mais peu discriminant : il est utilisé comme auxiliaire dans une variété de contextes sans associations lexicales privilégiées.
- **Le mot “avoir” (en vert, 2)** apparaît également en marge, pour les mêmes raisons. Il est intéressant de voir qu’ici, contrairement à la méthode précédente, les auxiliaires ne sont pas regroupés dans le même cluster.
- **Les mots du cluster bleu (3)** forment le groupe principal : il s’agit de verbes d’action ou d’expression institutionnelle (adopter, proposer, protéger, décider, exprimer, subir...).
- **Le cluster violet (4)** contient des substantifs (gouvernement, commission, proposition, président, majorité), correspondant à des réalités institutionnelles puisqu’il s’agit du thème du corpus.

6.2 Cooccurrence linéaire

6.2.1 Visualisations de clusters

Le premier graphique obtenu (MDS des mots) s'agit d'une représentation en 2D des mots, obtenue par réduction dimensionnelle MDS. Les mots sont projetés sur deux dimensions, et sont visualisés sans regroupement explicite (clustering). Il est difficile de discerner les relations entre les mots juste à partir de cette projection (même après la limitation aux mots les plus fréquents), mais cette approche permet de visualiser les positions relatives des mots dans un espace sémantique de faible dimension.




FIGURE 14 – Positionnement multidimensionnel projeté sur 2 dimensions

La 2e visualisation utilise le même espace 2D, mais les mots sont regroupés en 4 clusters à l'aide de l'algorithme K-means. Ce graphique montre clairement des regroupements de mots similaires, en fonction de leur proximité dans l'espace sémantique. Les clusters sont représentés par des formes polygonales autour des mots, facilitant ainsi la compréhension des relations sémantiques entre eux.




FIGURE 15 – Visualisation de MDS avec k-means

Clustering des mots (PCA + K-means)

cluster

- 1
- 2
- 3
- 4

6.2.2 Analyse des clusters

Dans la première visualisation, on peut observer que des termes comme "président", "république" et "gouvernement" se retrouvent proches les uns des autres. Cela reflète leur utilisation commune dans des contextes similaires, comme les discussions politiques ou gouvernementales. À l'inverse, des termes comme "bancs" ou "applaudissements" apparaissent plus éloignés des autres mots, ce qui peut suggérer qu'ils sont utilisés dans des contextes différents et moins fréquents.

La deuxième visualisation présente une version plus affinée de cette projection en utilisant un clustering K-means après réduction dimensionnelle MDS. Ici, les mots sont regroupés en clusters distincts, chacun représentant des groupes de termes sémantiquement similaires. Par exemple, le cluster rouge regroupe

des mots comme "rapporteur", "président" et "ministre", qui sont tous associés à des rôles ou des fonctions politiques. L'application de l'algorithme K-means permet de visualiser clairement ces relations sémantiques, en montrant que certains mots partagent des contextes d'utilisation très proches, ce qui aurait été moins évident dans une simple projection en 2D.

Nous avons choisi de diviser l'espace sémantique en 4 clusters. Si ce nombre était plus élevé, on pourrait observer une division plus fine des termes, capturant ainsi des distinctions plus subtiles entre des groupes de mots. Par exemple, un nombre plus élevé de clusters pourrait séparer davantage des termes comme "sénat" et "dispositif", qui bien qu'étant liés à des politiques, peuvent être utilisés dans des contextes légèrement différents.

Dans la troisième visualisation, l'utilisation de PCA pour la réduction dimensionnelle avant d'appliquer K-means montre une approche différente. PCA maximise la variance expliquée dans les deux premières dimensions, ce qui peut modifier l'organisation des mots. Par exemple, des mots comme "président" et "secrétaire", qui apparaissaient ensemble dans l'espace MDS, sont désormais légèrement séparés dans l'espace PCA. Cette différence peut être expliquée par le fait que PCA capture davantage les variations globales dans les données, ce qui peut entraîner des ajustements dans la représentation des relations sémantiques.

Le choix entre MDS et PCA affecte la manière dont les distances entre les points sont perçues et les relations entre les mots sont projetées. MDS se concentre sur la conservation des distances entre les points, tandis que PCA maximise la variance expliquée, ce qui peut conduire à des représentations légèrement différentes dans les deux techniques.

6.2.3 Avantages et limites de cooccurrence linéaire

La méthode de cooccurrence linéaire, associée à des techniques de réduction dimensionnelle comme MDS et PCA, présente plusieurs avantages notables. Tout d'abord, elle permet une représentation efficace des relations sémantiques entre les mots dans un espace réduit, facilitant ainsi leur visualisation et leur interprétation. L'utilisation du score PPMI améliore la détection de relations significatives en minimisant l'impact des cooccurrences trop fréquentes, ce qui permet de mieux saisir les liens rares mais importants. De plus, l'algorithme de clustering K-means permet de regrouper les mots en clusters sémantiquement cohérents, offrant une vue claire de la structure du corpus.

Cependant, cette méthode présente aussi quelques inconvénients. L'un des principaux défis réside dans le choix des paramètres, comme la taille de la fenêtre de cooccurrence et le nombre de clusters, qui peuvent grandement influencer les résultats. Un choix inadéquat de ces paramètres peut entraîner des regroupements peu pertinents ou une perte d'information importante. De plus, la méthode de cooccurrence se limite souvent à la capture des relations immédiates entre mots dans le texte, négligeant les relations plus complexes ou distantes. Enfin, la réduction dimensionnelle, bien qu'efficace pour visualiser les données, peut parfois perdre des informations cruciales lors de la compression des données dans un espace à faible dimension, ce qui pourrait affecter la qualité du

clustering. Ainsi, bien que cette méthode soit puissante, elle nécessite une calibration soignée des paramètres et peut ne pas toujours capter la complexité complète des relations sémantiques dans des corpus vastes ou très variés.

6.3 Word2Vec

6.3.1 Visualisation des regroupements lexicaux

Afin d’analyser les structures sémantiques apprises par le modèle Word2Vec, deux formes de visualisation ont été réalisées : une liste thématique des mots regroupés par cluster, et une représentation graphique bidimensionnelle basée sur la réduction par ACP.

Figure textuelle : aperçu sémantique par cluster.

La première représentation (Figure 17) consiste en une sélection des mots les plus fréquents pour chacun des 10 clusters. Ces regroupements permettent une interprétation qualitative des pôles sémantiques extraits automatiquement par la méthode hiérarchique de Ward. On y observe par exemple :

- **Cluster 0** : vocabulaire lié à l’économie européenne, l’agriculture, les projets de développement.
- **Cluster 1** : lexique budgétaire et financier (emploi, fiscalité, logement...).
- **Cluster 2** : cœur législatif (pouvoir, droit, lois, devoir, cas...).
- **Cluster 3** : interactions orales au sein des débats (amendement, ministre, avis, groupe...).
- **Cluster 4** : registres de l’argumentation et de la prise de position (agir, vouloir, raison...).
- **Cluster 5** : champ lexical du droit, des mineurs et de la justice (protéger, juger, procédure...).
- **Cluster 6** : institutions, citoyenneté et vie politique (France, président, parlement...).
- **Cluster 7** : santé, accompagnement social et jeunesse (service, santé, école...).
- **Cluster 8** : vocabulaire de l’action gouvernementale (projet_loi, débat, commission...).
- **Cluster 9** : aménagement du territoire, environnement, patrimoine.

* Cluster 0 (2076 mots):
européen, projet, économique, qualité, développement, Europe, économie, agriculteur, investissement, produit, secteur, développer, union_européenne, prix, ligne, marché, acteur, outil, agriculture, international

* Cluster 1 (4246 mots):
entreprise, année, moyen, euro, budget, emploi, amendement_viser, logement, million_euro, risque, salarié, million, financement, activité, fiscal, augmenter, coût, milliard_euro, supplémentaire, financier

* Cluster 2 (6981 mots):
pouvoir, faire, état, falloir, proposer, loi, texte, français, droit, devoir, politique, cas, public, aujourd, grand, prendre, important, prévoir, dispositif, social

* Cluster 3 (2629 mots):
amendement, article, groupe, applaudissement_banc, parole_mme, ministre, soutenir_amendement, groupe_laREM, avis_commission, collègue, parole, disposition, monsieur_ministre, avis_gouvernement, défendre, avis, banc

* Cluster 4 (6384 mots):
bien, avoir, agir, vouloir, non, savoir, raison, venir, souhaiter, rappeler, temps, Monsieur_ministre, donner, voir, heure, fois, cher_collègue, passer, ici, dire

* Cluster 5 (2113 mots):
procédure, étranger, protection, protéger, délai, femme, juge, victime, règlement, égard, recours, administratif, interdire, durée, relation, mineur, violence, accueillir, accueil, demandeur_asile

* Cluster 6 (4928 mots):
France, pays, personne, national, jour, exemple, contre, parlementaire, information, bénéficier, parlement, président, assemblée, petit, aide, vivre, conséquence, famille, sein, difficulté

* Cluster 7 (2084 mots):
perspective, nouveau, cadre, service, action, formation, enfant, santé, vie, plan, renforcer, jeune, accompagner, grâce, accès, adapter, lutte_contre, établissement, mettre_place, école

* Cluster 8 (2395 mots):
être, gouvernement, question, mesure, travail, commission, projet_loi, sujet, débat, ailleurs, rapport, répondre, accord, viser, député, dernier, proposition, adopter, proposition_loi, présent

* Cluster 9 (1244 mots):
territoire, mer, population, ville, construire, construction, circonscription, Paris, zone, habitant, environnement, environnemental, vente, quartier, situer, métropole, aménagement, territoire_rural, patrimoine, t

FIGURE 17 – Mots les plus fréquents par cluster (Ward, $k = 10$)

Figure graphique : projection des clusters.

La seconde visualisation (Figure 18) repose sur la projection en deux dimensions des vecteurs Word2Vec réduits par ACP, puis coloriés selon leur appartenance aux 10 clusters. Chaque couleur correspond à un groupe identifié par l'algorithme de Ward.

Cette représentation spatiale permet de vérifier la bonne séparation des groupes lexicaux : les clusters forment des zones denses et distinctes, suggérant une structuration sémantique claire et cohérente du vocabulaire parlementaire.




FIGURE 18 – Projection ACP des clusters Ward ($k = 10$), chaque point représente un mot

6.3.2 Détermination du nombre de clusters

L'identification du nombre optimal de clusters a été conduite selon une approche croisée combinant deux méthodes complémentaires : la méthode du coude et l'analyse hiérarchique par regroupement.

Méthode du coude.

La Figure 19 présente l'évolution de l'inertie intra-classe en fonction du nombre de clusters. Une inflexion nette est observable à $k = 3$, indiquant une forte baisse de l'inertie jusqu'à ce seuil, suivie d'un ralentissement de la diminution. Cette transition caractérise le point de coude classique, à partir duquel l'ajout de nouveaux clusters n'apporte plus de gain significatif en termes de compacité intra-classe.

Analyse hiérarchique (Ward).

En complément, une classification hiérarchique a été réalisée à l'aide de la mé-




FIGURE 19 – Inertie intra-classe selon le nombre de clusters (méthode du coude)

thode de Ward, appliquée sur les vecteurs lexicaux réduits à 20 dimensions via ACP. Le dendrogramme obtenu (Figure 20) révèle une structure arborescente du lexique, dans laquelle plusieurs niveaux de regroupement sont possibles. Une coupe à $k = 3$ permet de dégager trois grands pôles thématiques, chacun bien distinct.




FIGURE 20 – Dendrogramme hiérarchique construit avec la méthode de Ward

Validation visuelle (ACP).

La Figure 21 illustre la répartition des mots dans un espace réduit à deux dimensions par ACP, coloriés selon leur attribution à l'un des trois clusters. Les groupes apparaissent bien délimités, ce qui valide empiriquement la cohérence sémantique de la partition.




FIGURE 21 – Clusters hiérarchiques (Ward) coupés à $k = 3$ visualisés en 2D via ACP

En somme, le choix de $k = 3$ repose sur une convergence méthodologique entre compacité optimale et lisibilité sémantique. Cette configuration permet une synthèse efficace des champs lexicaux dominants du corpus parlementaire, tout en conservant une robustesse interprétative.

6.3.3 Analyse des clusters

Chaque cluster a été caractérisé selon deux dimensions :

- **Le représentant** : le mot le plus proche du centroïde du cluster dans l'espace vectoriel. Il incarne le vocabulaire typique du groupe. La Figure 22 représente les 5 mots représentants de chaque cluster, ce qui conforte l'idée que ça soit le vocabulaire typique du cluster, comme le cluster 1 qui regroupe les figures connues du parlement. Tandis que le cluster 2, porte sur l'économie et les actions ayant un lien avec cette dernière et pour finir le cluster 3 tourne autour des sujets de société.
- **Le paragon** : le mot le plus éloigné des centroïdes des autres clusters, c'est-à-dire le plus spécifique au cluster. La figure 16 représente la listes des cinq parangons des clusters, qui eux reflètent la spécificité des clusters, on remarque que "Collard" est le plus spécifique dans le cluster 1, et ce à cause de l'année 2018, où une plainte pour viol a été déposée contre ce député, ce qui a été repris longtemps dans le parlement.

Nous avons fait le choix de prendre les cinq représentants et parangons de chaque clusters, pour une analyse plus fine et plus cohérente.

Cluster	Mot	Similarité au centroïde
1	Elimas_rapporteure	0.9322275
1	Christophe_Jerretie	0.9291595
1	Monica_Michel	0.9234616
1	Deprez_Audebert	0.9187125
1	mme_Sandra	0.9176735
2	réindexation	0.9058646
2	plafond_exonération	0.8808417
2	plafond_affectation	0.8777672
2	abaisser_plafond	0.87746674
2	cotisation_chômag	0.8653048
3	éligible_CPF	0.8253838
3	discriminatoirer	0.8152453
3	coparentalité	0.81228185
3	second_degrer	0.8119795
3	obligatoire_avocat	0.80881953

FIGURE 22 – La liste des 5 représentants spécifiques de chaque cluster

Cluster	Mot	Similarité autres centres
1	Collard	0.25309473
1	parole_Hervé	0.25804436
1	Marie	0.26063538
1	entendre_orateur	0.26145414
1	Éric_Ciotti	0.26971555
2	flamber	0.24831331
2	Faut_rappeler	0.2512516
2	anner_année	0.26467758
2	ratio	0.26537564
2	fortune	0.27524847
3	forum	0.2020441
3	science	0.21310833
3	hautement	0.22801948
3	contournement	0.23274797
3	radicalisation	0.23331073

FIGURE 23 – La liste des 5 parangons de chaque cluster

6.3.4 Apports et limites du modèle Word2Vec

Le modèle Word2Vec, en représentant les mots par des vecteurs appris à partir de leur contexte d'apparition, capte efficacement les régularités sémantiques de surface. Il permet de détecter automatiquement des proximités lexicales difficiles à formaliser manuellement, notamment dans des corpus volumineux.

Cependant, il convient de noter certaines limites :

- les représentations sont insensibles à la polysémie (chaque mot n'a qu'un vecteur) ;
- la qualité dépend fortement de la taille et de la représentativité du corpus [2] ;
- l'interprétation des regroupements reste en partie subjective.

6.4 Comparaison des résultats

Les trois méthodes explorées — cooccurrence syntaxique (inspirée par Pêcheux), cooccurrence linéaire, et Word2Vec — permettent de représenter les relations lexicales dans le corpus parlementaire, mais elles diffèrent sensiblement par leurs principes, leurs effets sur la structuration des clusters et les types de proximités qu'elles révèlent.

6.4.1 Organisation syntaxique vs. sémantique

L'approche syntaxique (Pêcheux) oriente les regroupements vers des régularités grammaticales : les clusters reflètent en grande partie les rôles syntaxiques des mots (verbes d'action, auxiliaires, noms de fonctions, etc.). À l'inverse, la cooccurrence linéaire capte des régularités de surface : elle regroupe les mots qui apparaissent proches dans le texte, sans distinction de fonction syntaxique. Word2Vec, enfin, dépasse ces deux types de relations en apprenant des représentations sémantiques denses, ce qui permet de regrouper des mots sémantiquement proches, même s'ils ne coapparaissent pas directement ou régulièrement dans le corpus.

6.4.2 Qualité des regroupements

Les clusters issus de Word2Vec sont globalement les plus cohérents sur le plan thématique. Ils révèlent des pôles sémantiques nets et alignés sur les grandes thématiques du corpus (budget, droit, institutions, opinion, etc.). L'approche syntaxique, elle, excelle à identifier les fonctions grammaticales. Cependant, la fenêtre de cooccurrence étant pour l'instant limitée aux 4 éléments que sont le déterminant, le nom sujet, l'auxiliaire et le verbe, cela limite fortement la finesse du clustering et de l'analyse possible. Il s'agirait maintenant d'étendre le contenu des énoncés élémentaires récupérés. La cooccurrence linéaire, bien que moins fine, permet une visualisation simple des proximités immédiates, mais ses regroupements sont souvent plus bruités et sensibles au choix de la fenêtre.

7 Conclusions

Ce projet nous a permis d’explorer un **large éventail de techniques issues de la sémantique distributionnelle**, en mettant en œuvre **une chaîne complète de traitement** allant du prétraitement linguistique à la visualisation de clusters sémantiques. Nous avons ainsi expérimenté des étapes clés comme l’extraction de cooccurrences, le choix de mesures d’association, la réduction de dimensionnalité et l’application d’algorithmes de clustering.

L’approche fondée sur la cooccurrence syntaxique, inspirée des travaux de Pêcheux, s’est révélée particulièrement exigeante, notamment pour ce qui concerne l’identification et la formalisation des structures discursives profondes. Contrairement aux approches classiques basées sur des fenêtres linéaires, il s’agit ici de rendre compte de relations syntaxiques et argumentatives plus abstraites, qui ne sont pas directement visibles dans la surface textuelle. Cette difficulté, loin d’être un simple obstacle, a mis en lumière la richesse de l’analyse syntaxico-discursive et la complexité de sa mise en œuvre automatique.

Le projet a nécessité la mobilisation d’un large éventail d’outils techniques et théoriques, dans plusieurs langages et disciplines. Nous avons utilisé :

- **Des langages de programmation** : **Python** (prétraitement, vectorisation, parsing, Word2Vec), **R** (réduction de dimension, visualisation, clustering).
- **Des bibliothèques et frameworks** : **gensim** pour Word2Vec (modèle fondé sur PyTorch ou C), **factoextra** et **cluster** en R, **pandas** / **numpy** en **Python** ainsi que **GrewPy** (extractions syntaxiques en SUD).. Nous avons aussi testé mais non retenu dans la version finale : **Stanza** (parsing UD), **spaCy** (segmentation, parsing plus léger).
- **Des ressources linguistiques** : les annotations syntaxiques en **UD** et **SUD**, les formats **CoNLL-U** pour les données, le corpus **ParlaMint-FR** comme base textuelle.
- **Des cadres mathématiques** : vectorisation (fréquences, MI, PPMI), réduction de dimensionnalité (PCA, t-SNE), et clustering (K-means, hiérarchique), ainsi que des réflexions sur l’espace vectoriel (distances, densité, interprétabilité).
- **Des notions linguistiques avancées** : fonctions syntaxiques, structures argumentatives, relations discursives (ϕ , δ), structures énonciatives, etc.

Cette pluralité d’outils a enrichi notre compréhension des méthodes, tout en posant des défis en termes de cohérence, d’intégration et d’interopérabilité entre les environnements. Elle reflète bien la réalité du travail en TAL, où le croisement des disciplines (linguistique, mathématiques, informatique) est permanent.

Ce travail a illustré concrètement les enjeux de l’analyse sémantique en traitement automatique du langage, en soulignant à quel point les choix méthodologiques (types de cooccurrence, taille de fenêtre, nombre de dimensions, etc.) influencent les résultats finaux. Il montre qu’au-delà des outils, c’est une véritable réflexion linguistique et technique qu’il faut conduire pour produire des représentations utiles et interprétables du sens lexical.

Annexes

- Code source du projet : <https://github.com/lucilebessac/AAD69-synonymie-contextuelle>
- Corpus ParlaMint-FR : [https://github.com/clarin-eric/ParlaMint?](https://github.com/clarin-eric/ParlaMint?tab=readme-ov-file)
[tab=readme-ov-file](https://github.com/clarin-eric/ParlaMint?tab=readme-ov-file)

Références

- [1] Stefan EVERT. « The Statistics of Word Cooccurrences : Word Pairs and Collocations ». PhD dissertation. University of Stuttgart, 2005.
- [2] Yoav GOLDBERG et Omer LEVY. « word2vec Explained : Deriving Mikolov et al.'s Negative-Sampling Word-Embedding Method ». In : *arXiv preprint arXiv :1402.3722* (2014).
- [3] Zellig HARRIS. « Distributional Structure ». In : *Word* 10.2-3 (1954), p. 146-162.
- [4] Thomas K. LANDAUER et Susan T. DUMAIS. « A solution to Plato's problem : The latent semantic analysis theory of acquisition, induction, and representation of knowledge ». In : *Psychological Review* 104.2 (1997), p. 211-240.
- [5] Tomas MIKOLOV et al. « Efficient Estimation of Word Representations in Vector Space ». In : *arXiv preprint arXiv :1301.3781* (2013).
- [6] Michel PÊCHEUX. *Analyse automatique du discours*. Paris : Dunod, 1969.
- [7] Peter D. TURNEY et Patrick PANTEL. « From frequency to meaning : Vector space models of semantics ». In : *Journal of Artificial Intelligence Research* 37 (2010), p. 141-188.